

UNIVERSITÀ DEGLI STUDI DI ROMA “TOR VERGATA”

Macroarea di Ingegneria
Corso di Laurea Magistrale in Ingegneria Informatica

Prodotto matrice densa per multivettore in MPI e CUDA

Progetto di fine corso

Sistemi di Calcolo Parallelo e Applicazioni
A.A. 2025/2026

Autori

Alessandro Vassallo
0366572

Andrea Galluzzi
0365026

Codice sorgente: <https://github.com/AleVassa00/parallel-computing-project>

Versione della relazione del 16 settembre 2026

Bozza di lavoro. I marcatori in rosso segnalano i punti che dipendono da campagne di misura non ancora concluse. Per la versione di consegna, commentare `\todovisibiletrue` in `preambolo.tex`.

Indice

1	Introduzione	1
1.1	Obiettivo	1
2	Il kernel di calcolo	2
2.1	Che cosa calcola il nucleo	2
2.1.1	Conteggio delle operazioni	2
2.2	Come vengono memorizzati i dati	3
2.3	Ordine dei cicli: schema A contro schema B	3
2.3.1	Gli schemi candidati	4
2.3.2	La quantificazione: intensità aritmetica	4
2.3.3	Un limite che non si può superare	5
2.3.4	Una proprietà che conta sull'hardware reale	5
2.4	Precisione	5
2.5	Generazione riproducibile dei dati	6
2.5.1	Il generatore	6
2.5.2	Le tre conseguenze, tutte usate dal progetto	6
2.5.3	Perché i valori hanno media nulla	6
2.6	L'interfaccia unica del kernel locale	7
2.6.1	Ciclo di vita del kernel	7
2.6.2	Contesto opaco del backend	8
2.6.3	Configurazione delle build	8
3	Parallelizzazione MPI	9
3.1	Che cosa significa parallelizzare in MPI	9
3.2	Perché si taglia A , e perché in due direzioni	10
3.2.1	Che cosa tagliare	10
3.2.2	Come tagliare: due possibilità monodimensionali	10
3.2.3	Il taglio bidimensionale	10
3.2.4	Perché i processi vengono organizzati a griglia	11
3.3	Decomposizione a griglia bidimensionale	11
3.3.1	I due sotto-comunicatori	12
3.3.2	Chi fa da root, e perché la scelta è verificata	12
3.4	Partizionamento degli indici	13
3.4.1	Le funzioni	13
3.5	Layout dei blocchi locali	13
3.5.1	Perché i conteggi delle collettive tornano	13
3.5.2	Chi contiene che cosa, e quando	14
3.5.3	Perché il multivettore non viene mai tagliato lungo k	14
3.6	Distribuzione iniziale dei dati	14
3.7	L'algoritmo distribuito	15

3.8	Modello di costo della comunicazione	16
4	Il nucleo di CPU	18
4.1	Tre backend, una sola idea	18
4.2	Il backend di riferimento	18
4.2.1	Perché specializzare k a compile-time	18
4.2.2	Il fallback generico, e perché la traccia lo richiede	19
4.3	Perché $KB = 32$	20
4.4	Ciò che il compilatore vede	20
4.5	Il primo limite: la rilettura di X	20
4.6	Secondo backend: X mattonellata in cache	21
4.7	Terzo backend: register blocking sulle righe	21
5	I backend CUDA	23
5.1	Struttura comune	24
5.2	Misurazione del backend CUDA	25
5.3	Preprocessing e occupazione della GPU	26
5.3.1	Gestione della memoria disponibile	26
5.4	<code>cuda_naive</code>	26
5.5	<code>cuda_warp</code> : un warp per riga	28
5.5.1	Gestione di k	29
5.5.2	La maschera dello shuffle	29
5.5.3	Il problema residuo: gli accessi a X	29
5.6	Primo rimedio: cambio di layout di X	30
5.7	<code>cuda_warp_smem</code> : staging di X in shared memory	30
5.7.1	Caricamento cooperativo di X	31
5.7.2	Riutilizzo del tile fra i warp del blocco	31
5.7.3	Bank conflict e padding della shared memory	32
5.7.4	Scelta della dimensione del tile	33
5.7.5	Sincronizzazione e warp inattivi	34
5.8	Due rimedi allo stesso problema	34
5.9	<code>cublas</code> : il riferimento esterno	35
5.9.1	Adattamento fra row-major e column-major	35
5.9.2	Significato del confronto	36
5.10	Più rank MPI sulla stessa GPU	36
6	Metodologia sperimentale	38
6.1	Ambiente sperimentale	38
6.2	Protocollo di misura	39
6.3	Definizione della metrica di prestazione	40
6.4	Costi esclusi dalla metrica ufficiale	42
6.5	Ripetizioni e stabilità statistica	42
6.6	Disegno sperimentale: le fasi	43
6.6.1	Criterio di selezione dei parametri	44
6.7	Fase 1 — Tuning dei backend CUDA	45
6.7.1	Campagna 1.1 — Dimensione del blocco	45
6.7.2	Campagna 1.2 — Layout in memoria di X	45
6.7.3	Campagna 1.3 — Padding del tile in shared memory	46
6.7.4	Campagna 1.4 — Granularità del tile	46
6.7.5	Campagna 1.5 — Confronto fra i kernel a configurazione fissata	46
6.8	Fase 2 — Caratterizzazione dimensionale	47
6.9	Fase 3 — Precisione numerica	47

6.10	Fase 4 — Decomposizione MPI sui backend di CPU	48
6.11	Fase 5 — MPI + CUDA	49
7	Risultati	50
7.1	Stato della raccolta dati	50
7.2	Fase 1 — Tuning dei backend CUDA	50
7.2.1	Campagna 1.1 — Dimensione del blocco	51
7.2.2	Campagna 1.2 — Layout in memoria di X	54
7.2.3	Campagna 1.3 — Padding del tile in shared memory	55
7.2.4	Campagna 1.4 — Granularità del tile	56
7.2.5	Campagna 1.5 — Confronto fra i kernel	57
7.3	Fase 2 — Scala del problema e forma di A	59
7.4	Fase 3 — FP32 contro FP64	61
7.5	Fase 4 — Strong scaling MPI sui backend di CPU	63
7.5.1	Il nucleo di CPU a rank singolo	64
7.5.2	Scaling a problema fisso	65
7.6	Il costo dei dati: trasferimenti e preprocessing	67
7.7	Sintesi	68
8	Conclusioni	69
8.1	Che cosa è stato realizzato	69
8.2	Che cosa dicono i dati finora	69
8.3	Lavori futuri	70
A	Interfaccia a riga di comando e formato dei dati	71
A.1	Opzioni del driver	71
A.2	Colonne del CSV	71
A.3	Opzioni di build	72
B	Riproduzione dei risultati	74
B.1	Build	74
B.2	Validazione	74
B.3	Esecuzione singola	74
B.4	Campagne	75
B.5	Unione dei CSV di una campagna	75
B.6	Note operative sul server	75
B.7	Compilazione di questa relazione	76

Capitolo 1

Introduzione

1.1 Obiettivo

Il progetto realizza un nucleo di calcolo per il prodotto fra una matrice densa e un multivettore,

$$Y \leftarrow AX, \quad A \in \mathbb{R}^{M \times N}, \quad X \in \mathbb{R}^{N \times k}, \quad Y \in \mathbb{R}^{M \times k}, \quad (1.1)$$

con k *piccolo*: il multivettore è una matrice densa alta e strettissima. Il codice funziona per k generico ed è collaudato sui cinque valori richiesti dalla traccia, $k \in \{3, 6, 8, 20, 32\}$.

La parallelizzazione è ibrida a due livelli:

- **MPI (Message Passing Interface)** costituisce il livello esterno, responsabile della distribuzione dei dati su una griglia di processi bidimensionale e della comunicazione fra processi
- la parallelizzazione interna al singolo processo è affidata a **CUDA (Compute Unified Device Architecture)**, che costituisce il backend di accelerazione su GPU NVIDIA.

I due livelli non sono alternativi ma sovrapposti: ogni processo MPI possiede un blocco di A e delega il calcolo del proprio contributo parziale a un *backend* locale, che può essere un kernel CUDA oppure un nucleo di CPU.

Capitolo 2

Il kernel di calcolo

Questo capitolo fissa tre cose che il resto della relazione dà per acquisite: che cosa il nucleo calcola e come se ne contano le operazioni, in che ordine conviene scandire i tre cicli, e da dove vengono i dati. Sono scelte fatte una volta sola, prima di qualunque backend: i capitoli su MPI, CPU e CUDA le ereditano senza rimetterle in discussione.

2.1 Che cosa calcola il nucleo

Il nucleo calcola $Y \leftarrow AX$, con A densa $M \times N$ e X multivettore $N \times k$. Elemento per elemento:

$$Y[i][c] = \sum_{j=0}^{N-1} A[i][j] X[j][c], \quad 0 \leq i < M, \quad 0 \leq c < k. \quad (2.1)$$

La traccia fissa i gradi di libertà: M ed N sono scelte dall'utente a runtime, k deve funzionare per valore *generico* e il collaudo deve coprire almeno $k = 3, 6, 8, 20, 32$. Il progetto rispetta entrambe le richieste, ma con una distinzione che conviene anticipare subito: sui cinque k del collaudo il nucleo di CPU usa funzioni specializzate a tempo di compilazione, mentre ogni altro k passa da un percorso generico con prestazioni diverse (capitolo 4).

2.1.1 Conteggio delle operazioni

Il conteggio si costruisce in due passi.

Passo 1 - un singolo elemento. Ogni $Y[i][c]$ è una somma di N prodotti: servono N moltiplicazioni e $N - 1$ addizioni, ma la convenzione standard, e quella imposta dalla traccia, arrotonda a 2 FLOP per termine.

Passo 2 - tutta la matrice. Gli elementi di Y sono $M \cdot k$.

Quindi:

$$\text{FLOP}(M, N, k) = 2 M N k, \quad \text{GFLOPS} = \frac{2 M N k}{T \cdot 10^9}. \quad (2.2)$$

Su questa formula la traccia impone tre vincoli, che vale la pena enunciare qui perché condizionano tutta la metodologia di misura:

1. T è il tempo **medio per invocazione**, ottenuto ripetendo il nucleo più volte sulla stessa matrice.

2. In T entra **solo il calcolo**: preprocessing, I/O ed eventuali trasferimenti da e verso la scheda CUDA restano fuori. La traccia consente però di misurarli e discuterli a parte, ed è quello che il progetto fa. Che cosa esattamente venga cronometrato, e con quale orologio, è trattato in sezione 6.3.
3. M ed N sono le dimensioni della matrice **globale**, anche quando l'esecuzione è distribuita. È proprio questo che rende leggibile lo speedup: il lavoro totale non cambia con il numero di processi, cambia solo T .

2.2 Come vengono memorizzati i dati

Tutte e tre le matrici sono **row-major**: *gli elementi di una stessa riga sono adiacenti*.

La matrice A ha inoltre una propria *leading dimension* lda , cioè la distanza in elementi fra l'inizio di una riga e l'inizio della successiva nella rappresentazione in memoria. La leading dimension è stata introdotta per permettere *padding* fra righe consecutive e per ricevere direttamente blocchi non contigui mediante datatype MPI derivati. In realtà, le matrici X e Y la leading dimension è *sempre* fissata a k , che è il numero di colonne, e quindi le righe sono compatte. La leading dimension è sfruttata:

$$A[i][j] = A_loc[i \cdot \text{lda} + j], \quad X[j][c] = X_loc[j \cdot \text{ldx} + c], \quad Y[i][c] = Y_loc[i \cdot \text{ldy} + c].$$

Quando lda coincide con il numero di colonne il buffer è compatto; quando è maggiore, fra una riga e l'altra restano delle celle inutilizzate, per l'appunto il *padding*.

Perché lda è separata da n_loc . Il blocco che un processo possiede è una sottomatrice di A , quindi **non è contiguo nella matrice globale**: le sue righe sono distanti N elementi l'una dall'altra. La distribuzione usa per questo un datatype derivato `MPI_Type_vector`, con stride N dal lato del mittente e stride lda dal lato del ricevente, così il blocco viene depositato direttamente nel buffer locale senza copie intermedie (capitolo 3). Tenere lda come parametro indipendente aggiunge a questo la possibilità di avere padding fra le righe locali.

Perché ldx e ldy invece sono fissate a k . L'interfaccia del kernel (??) le espone e ogni backend le onora, ma il driver distribuito impone $\text{ldx} = \text{ldy} = k$, cioè buffer compatti. La ragione è nelle collettive: il `MPI_Bcast` di X e il `MPI_Reduce` di Y lavorano con conteggi contigui, e descrivere uno stride richiederebbe di costruire un datatype derivato a ogni invocazione, *dentro* la regione cronometrata. A invece non attraversa nessuna collettiva, ed è per questo che è l'unica delle tre a potersi permettere il padding.

Il fatto che le k colonne di X siano adiacenti in memoria non è un dettaglio di comodo: è la proprietà su cui si regge tutta la sezione 2.3.

Ipotesi:

Un backend CUDA prevede in alternativa una disposizione **column-major** di X , ma come opzione di build e con effetti discussi al momento giusto (??); il default, e tutto ciò che segue, è row-major.

2.3 Ordine dei cicli: schema A contro schema B

La eq. (2.1) contiene tre indici, i , j e c . Indipendentemente dall'ordine in cui viene scelto di scandire gli indici, l'operazione produce lo stesso risultato, ma il diverso ordine con il quale vengono scanditi non danno affatto le stesse prestazioni. È il primo punto in cui il progetto si allontana da una trascrizione letterale della definizione.

2.3.1 Gli schemi candidati

I due candidati sono:

Schema A ($i \rightarrow j \rightarrow c$)

```
for i:
    acc[0..k) = 0
    for j:
        a = A[i][j]
        for c:
            acc[c] += a * X[j][c]
Y[i][0..k) = acc[0..k)
```

Schema B ($i \rightarrow c \rightarrow j$)

```
for i:
    for c:
        s = 0
        for j:
            s += A[i][j] * X[j][c]
        Y[i][c] = s
```

Lo schema B è la trascrizione letterale della definizione, ed è esattamente l'esecuzione di k prodotti matrice-vettore indipendenti, uno per colonna. Lo schema A scambia i due cicli interni, cambiando anche il “ruolo” della matrice A .

Si segua una singola riga i .

Schema B. Il ciclo su c sta fuori e quello su j dentro, quindi per ogni colonna c il ciclo interno percorre l'intera riga $A[i][0 \dots N-1]$. Finita una colonna si ricomincia da capo con la successiva, sulle stesse celle. La riga viene dunque letta k volte, per un totale di kN letture di A a fronte delle N celle che la riga contiene.

Schema A. Il ciclo su j sta fuori e quello su c dentro. Il valore $a = A[i][j]$ viene letto una volta sola e consumato subito da tutti e k gli accumulatori, con gli aggiornamenti $\text{acc}[c] += a \cdot X[j][c]$ per $c = 0 \dots k-1$; poi si passa a $j+1$ e quel valore di A non serve più. La riga viene letta una volta sola, per un totale di N letture. Il riuso di A vale quindi esattamente k , e vale per costruzione: non dipende dalla taglia del problema né da condizioni sul valore di k .

Perché il risparmio sia reale gli accumulatori devono stare in registro, e perché il compilatore possa tenerceli deve conoscerne il numero a tempo di compilazione: è il motivo delle specializzazioni su k descritte in sezione 4.2.1.

Si potrebbe obiettare che le riletture dello schema B le assorbe la cache, e in parte è così, ma solo finché la dimensione della riga è contenibile nella cache. Una riga di A occupa Ns byte, dove s è la dimensione in byte di ogni elemento della matrice e N è la dimensione che la traccia chiede di far crescere: il caso interessante è proprio quello in cui la riga eccede i livelli di cache vicini al calcolo o, sulla GPU, quello in cui la riga eccede la shared memory di un blocco. Il modello che segue conta perciò il traffico verso la memoria principale, che è il livello che finisce per determinare il tempo.

2.3.2 La quantificazione: intensità aritmetica

L'*intensità aritmetica* I è il rapporto fra i FLOP eseguiti e i byte che attraversano il livello di memoria considerato. Detta s la dimensione in byte dello scalare, e contando il solo traffico su A come giustificato in ??:

$$I_A = \frac{2MNk}{MNs} = \frac{2k}{s}, \quad I_B = \frac{2MNk}{kMNs} = \frac{2}{s}. \quad (2.3)$$

Il numeratore è lo stesso: i FLOP da fare sono fissati dal problema. Cambia il denominatore, perché lo schema B legge gli MN elementi di A una volta per ciascuna delle k colonne.

In FP64 ($s = 8$) questo significa $I_A = k/4$ contro $I_B = 1/4$ FLOP/B: lo schema A guadagna esattamente un fattore k , e a $k = 32$ porta l'intensità da 0,25 a 8 FLOP/B.

È questo salto che sposta il nucleo da un regime saldamente memory-bound a un regime in cui, sulla GPU in doppia precisione, il limite può diventare il calcolo. La discussione quantitativa, con i picchi reali della scheda, è nel ??.

2.3.3 Un limite che non si può superare

$I_A = 2k/s$ è il **massimo** ottenibile: gli MN elementi di A vanno letti almeno una volta e i FLOP sono fissati, quindi nessuna riorganizzazione ulteriore può migliorare il rapporto. Tutto il lavoro di ottimizzazione successivo, su CPU come su GPU, riguarda allora il traffico su X e la capacità di tenere i k accumulatori in registro, non l'intensità rispetto ad A , che è già al suo limite.

Con un'eccezione, che la traccia rende rilevante chiedendo k generico. Tenere k accumulatori in registro è possibile finché k è abbastanza piccolo: oltre una certa ampiezza il nucleo di CPU blocca le colonne a gruppi di $KB = 32$ e rilegge A una volta per gruppo, cosicché in generale

$$I_A(k) = \frac{2k}{s \cdot \lceil k/KB \rceil}.$$

Per i cinque k del collaudo il ciclo sui blocchi è degenerare, A viene letta una volta sola e si ricade nella eq. (2.3); per $k = 64$ i passaggi sono due e l'intensità si ferma al valore che aveva a $k = 32$. Il dettaglio, con il microbenchmark che lo misura, è in sezione 4.2.1.

2.3.4 Una proprietà che conta sull'hardware reale

Nello schema A entrambi i flussi di lettura sono a **passo unitario**. La riga di A è contigua per costruzione e la riga di X lo è perché X è row-major con le k colonne adiacenti (sezione 3.5). Nessuno dei due accessi ha stride, quindi i prefetcher hardware lavorano nelle condizioni migliori e, sulla GPU, gli accessi delle lane di uno stesso warp sono coalescibili. Lo schema B, per ottenere la stessa proprietà sull'accesso a X , richiederebbe X column-major, cioè un layout diverso da quello che serve altrove.

2.4 Precisione

Tutto il codice usa un unico tipo `scalar_t`, definito in `src/common/scalar.h`, che vale `double` per default e `float` compilando con `PREC=float` (il Makefile traduce la variabile nella macro `-DUSE_FLOAT`). Anche il tipo MPI segue lo scalare, attraverso la macro `SCALAR_MPI_TYPE`, così le collettive non vanno toccate.

Il confronto FP64/FP32 è quindi un flag di compilazione e non una seconda copia dei sorgenti: le due build eseguono esattamente lo stesso codice, che è la sola condizione in cui il confronto misura la precisione e non due implementazioni diverse.

Effetto sul modello roofline. La scelta della precisione non è neutra, e agisce in **due modi opposti**:

- dimezzando s la eq. (2.3) *raddoppia* l'intensità aritmetica, da $k/4$ a $k/2$. Da solo, questo avvicinerebbe il nucleo al regime compute-bound;
- ma il punto di crossover del roofline vale P_{picco}/B , e su una GPU Turing il picco FP32 è 32 volte il picco FP64. Il crossover si sposta quindi a destra di un fattore 32.

Il secondo effetto è 16 volte più forte del primo e prevale nettamente: in singola precisione il nucleo finisce **saldamente memory-bound** su tutto l'intervallo di k della traccia, mentre in doppia precisione è compute-bound già da $k = 6$. I due regimi sono qualitativamente diversi,

ed è questo il vero argomento con cui il progetto discute la precisione: la doppia non costa il fattore 2 del traffico, costa il fattore 32 del picco. I numeri sono in ??.

Effetto sulla validazione. `scalar.h` deriva dal tipo anche `SCALAR_EPS` e la tolleranza del confronto con l'oracolo seriale, che non è una costante ma cresce con la lunghezza della riduzione. Il modello e la costante misurata sono discussi in ??.

2.5 Generazione riproducibile dei dati

Le matrici di test sono generate, non lette da file. La traccia lo consente esplicitamente, elencando la generazione fra le strategie di collaudo, e in cambio chiede che sia **ripetibile**.

2.5.1 Il generatore

Il generatore è `splitmix64`, un mixer a 64 bit **senza stato**. La differenza rispetto a un generatore pseudocasuale ordinario è tutta qui: un generatore con stato produce una *sequenza*, e per ottenere l'elemento in posizione p bisogna averlo fatto avanzare p volte. Un mixer stateless va da (seed, chiave) al valore in un passo solo. La chiave scelta è l'**indice lineare globale** dell'elemento:

$$A[i][j] = g(\text{seed}, \Sigma_A, i \cdot N + j), \quad X[j][c] = g(\text{seed}, \Sigma_X, j \cdot k + c), \quad (2.4)$$

dove Σ_A e Σ_X sono due identificatori di *stream* distinti, che servono a evitare che A e X abbiano lo stesso pattern di valori. Il seed viene mescolato prima con lo stream e poi con la chiave: due passaggi, perché uno solo lascerebbe correlati i valori di chiavi vicine. Dei 64 bit prodotti si usano i 53 alti, che danno un `double` esatto in $[0, 1)$, riscaldato poi in $[-1, 1)$.

Il valore di un elemento dipende dunque *solo* dalla sua posizione globale: mai dal processo che lo calcola, mai dall'ordine in cui viene generato, mai dalla forma della griglia.

2.5.2 Le tre conseguenze, tutte usate dal progetto

1. ogni processo può generare **direttamente** il proprio blocco locale, senza che una copia globale della matrice esista mai in memoria. È ciò che permette di misurare taglie che su un solo nodo non starebbero;
2. la stessa matrice globale si ottiene con *qualunque* griglia di processi e con qualunque modalità di inizializzazione. Due configurazioni diverse sono quindi confrontabili elemento per elemento;
3. l'esecuzione seriale di ??, usata come oracolo, può ricostruire da sé la porzione che gli serve, senza ricevere dati dagli altri processi.

2.5.3 Perché i valori hanno media nulla

I valori sono distribuiti in $[-1, 1)$ a media nulla, e questa non è una scelta estetica. Ogni elemento di Y è una riduzione su N termini, e l'errore di arrotondamento di una riduzione dipende da come si compongono i segni: con termini a media nulla gli arrotondamenti hanno segno indipendente e l'errore cresce come $\varepsilon\sqrt{N}$, non come il pessimistico εN del caso in cui tutti i termini abbiano lo stesso segno. È questa proprietà dei dati che rende possibile una tolleranza di validazione stretta invece di una soglia fissa e generosa (??).

Una nota utile per il confronto fra precisioni: il generatore calcola sempre in `double` e converte in `scalar_t` solo alla fine. Le build FP64 e FP32 lavorano quindi sugli stessi dati a meno del solo arrotondamento della conversione, ed è la condizione che rende confrontabili i loro tempi.

2.6 L'interfaccia unica del kernel locale

Ogni backend implementa tre operazioni fondamentali per la gestione e l'esecuzione del kernel locale, oltre ad alcune funzioni ausiliarie utilizzate per la raccolta delle metriche sperimentali.

2.6.1 Ciclo di vita del kernel

```
/* esecuzione */
local_gemm_t *local_gemm_create(int m, int n, int k,
                                const scalar_t *A_loc,
                                int lda, int ldx, int ldy);
void local_gemm(local_gemm_t *ctx,
                const scalar_t *RESTRICT X, int ldx,
                scalar_t *RESTRICT Y, int ldy);

void local_gemm_destroy(local_gemm_t *ctx);
```

Listato 2.1: Interfaccia di src/kernel/kernel.h.

L'interfaccia segue un ciclo di vita composto da tre fasi rappresentate da altrettante funzioni che definiscono il ciclo di vita del kernel locale:

- `local_gemm_create` ne inizializza il contesto,
- `local_gemm` esegue il calcolo e
- `local_gemm_destroy` rilascia le risorse associate.

Inoltre l'interfaccia espone alcune funzioni di introspezione utilizzate dal driver di benchmark per raccogliere separatamente tempi di calcolo, trasferimenti, costi di inizializzazione e parametri di esecuzione del backend. Tali metriche vengono descritte nella sezione dedicata alla metodologia sperimentale.

La separazione tra `local_gemm_create`, `local_gemm` e `local_gemm_destroy` deriva dal diverso ciclo di vita dei dati e delle risorse coinvolte nel calcolo.

La matrice A rimane invariata durante tutte le ripetizioni, mentre X e Y sono coinvolte in ogni esecuzione del prodotto locale. Questa differenza permette di separare le operazioni eseguite una sola volta da quelle necessarie a ogni invocazione.

1. **Inizializzazione (`local_gemm_create`).** Viene creato il contesto del backend e vengono predisposte le risorse riutilizzabili durante le successive esecuzioni.

Nei backend CUDA vengono allocati i buffer sul device e A viene trasferita una sola volta nella memoria della GPU.

2. **Esecuzione (`local_gemm`).** Questa fase viene ripetuta per ogni invocazione del prodotto locale. La matrice X , precedentemente distribuita tra i processi tramite `MPI_Bcast`, viene utilizzata insieme al blocco locale di A per produrre il contributo locale a Y .

Nei backend CUDA vengono riutilizzati i buffer allocati durante l'inizializzazione: la matrice X viene trasferita sul device, viene eseguito il kernel e il risultato Y viene riportato in memoria host.

I contributi prodotti dai processi vengono successivamente combinati tramite `MPI_Reduce`.

3. **Finalizzazione (`local_gemm_destroy`).** Al termine delle ripetizioni vengono rilasciate le risorse associate al contesto, comprese le eventuali allocazioni sulla GPU.

Questa organizzazione evita di ripetere a ogni invocazione le operazioni associate ad A e separa il costo di inizializzazione dal costo delle successive esecuzioni del prodotto locale.

2.6.2 Contesto opaco del backend

Lo stato specifico di ciascun backend è mantenuto all'interno del tipo opaco `local_gemm_t`. La struttura concreta è definita separatamente da ogni implementazione e può quindi contenere informazioni differenti senza modificare l'interfaccia comune.

Ad esempio, un backend CPU può memorizzare le dimensioni del problema e il riferimento ad A , mentre un backend CUDA mantiene anche i puntatori alla memoria del device e le risorse necessarie all'esecuzione.

2.6.3 Configurazione delle build

Le principali scelte sperimentali, tra cui backend di calcolo, precisione numerica e alcuni parametri dei kernel CUDA, vengono selezionate a tempo di compilazione tramite il `Makefile`.

Le principali varianti di configurazione utilizzate nelle campagne sperimentali vengono associate a binari distinti, evitando che build differenti si sovrascrivano e rendendo immediatamente identificabile la configurazione utilizzata.

Capitolo 3

Parallelizzazione MPI

Fino a questo punto il prodotto è stato descritto come se avvenisse dentro un unico spazio di memoria: i cicli di sezione 2.3 leggono A e X e scrivono Y come se tutte e tre fossero lì, a disposizione. Questo capitolo rimuove quell'ipotesi. Il problema diventa far collaborare più processi che non condividono niente, e le scelte che ne derivano condizionano tutto il resto della relazione: la forma dei blocchi, che cosa viene cronometrato, e perfino quali configurazioni ha senso misurare.

3.1 Che cosa significa parallelizzare in MPI

MPI (*Message Passing Interface*) è uno standard per programmare macchine a **memoria distribuita**. Il modello di esecuzione è il seguente: lo stesso programma viene avviato in P copie, ciascuna un processo del sistema operativo a sé stante, con il proprio spazio di indirizzi **privato**. Nessun processo può leggere o scrivere una variabile di un altro. L'unico modo perché un dato passi da un processo all'altro è che qualcuno lo invii esplicitamente, con una chiamata di libreria, e qualcun altro lo riceva.

È una differenza sostanziale rispetto a un modello a memoria condivisa, dove i thread vedono gli stessi indirizzi e la parallelizzazione consiste essenzialmente nel ripartire le iterazioni di un ciclo. Qui ripartire le iterazioni non basta, e non è nemmeno la prima cosa da decidere: prima bisogna stabilire **chi possiede quale dato**. Da questa scelta discende tutto il resto, perché un processo può calcolare solo ciò per cui possiede gli ingredienti, e ogni ingrediente mancante è un messaggio da far viaggiare.

La parallelizzazione del nucleo si articola quindi in tre domande, in quest'ordine:

1. **decomposizione** - come si tagliano A , X e Y fra i processi;
 2. **località** - quale parte del risultato ciascun processo riesce a calcolare con i soli dati che possiede;
 3. **comunicazione** - che cosa manca, e in quale direzione deve viaggiare perché il risultato locale diventi il risultato giusto.
- Il **rank** è l'identificatore intero di un processo all'interno di un gruppo: è ciò che permette a un programma unico di comportarsi diversamente su processi diversi.
 - Un **comunicatore** è un gruppo di processi assieme a un contesto di comunicazione isolato. Ogni operazione MPI avviene *dentro* un comunicatore, e i rank hanno senso solo rispetto a quello: `MPI_COMM_WORLD` è il comunicatore predefinito che contiene tutti i processi, ma se ne possono costruire altri più piccoli, ed è esattamente ciò che il progetto fa.

- Un'operazione **collettiva** è un'operazione che tutti i processi di un comunicatore devono chiamare. Il progetto ne usa due: il *broadcast*, in cui un processo possiede un dato e al termine lo possiedono tutti; e la *reduce*, in cui ogni processo possiede un array della stessa forma, gli array vengono combinati elemento per elemento con un operatore associativo — qui la somma — e il risultato finisce su un solo processo.
- Il **root** è quel processo designato: la sorgente nel broadcast, il destinatario nella reduce.

3.2 Perché si taglia A , e perché in due direzioni

3.2.1 Che cosa tagliare

La prima decisione riguarda quale delle tre matrici vada distribuita. La risposta viene da ???: A ha MN elementi, X e Y ne hanno rispettivamente Nk e Mk , e con k piccolo per definizione A è più grande delle altre due di un fattore che cresce con la taglia del problema.

Replicare A su ogni processo sarebbe quindi la scelta peggiore possibile, e per due ragioni indipendenti: ogni nodo dovrebbe contenerla per intero, mettendo un tetto alla taglia massima trattabile a prescindere da quanti processi si usino; e ogni processo la rileggerebbe tutta, quando è proprio il traffico su A a determinare il tempo. A va dunque **tagliata**. X e Y , che sono piccole, possono invece permettersi di essere replicate lungo un asse, e vedremo che è esattamente ciò che conviene fare.

3.2.2 Come tagliare: due possibilità monodimensionali

Tagliare A significa assegnare a ogni processo una sottomatrice. Le decomposizioni più semplici la tagliano lungo una sola dimensione, e la eq. (2.1) dice subito che cosa comportano.

Taglio a bande di righe. Ogni processo possiede righe *interi* di A . Per calcolare $Y[i][c]$ serve tutta la riga i di A e tutte le righe di X : un processo che possiede righe intere possiede quindi tutti i fattori del primo tipo, ma gli serve X per intero. Il vantaggio è che il risultato che calcola è già *definitivo*: nessuna somma finale fra processi. Il costo è che X deve essere replicata su tutti i P processi.

Taglio a bande di colonne. Ogni processo possiede colonne di A , cioè, per ciascuna riga, solo una parte degli addendi della sommatoria. Gli basta quindi la porzione di X corrispondente alle proprie colonne — X viene tagliata e non replicata — ma ciò che produce è un risultato **parziale**, che riguarda tutte le righe di Y e va sommato con i parziali di tutti gli altri. La somma finale coinvolge P processi su un oggetto della taglia piena di Y .

Le due alternative sono speculari: la prima paga la replicazione di X su tutti, la seconda la riduzione di Y su tutti. In entrambe la comunicazione coinvolge sempre l'intero insieme dei processi, e questo è il difetto strutturale: aumentare P non rende i messaggi più piccoli, li rende soltanto più numerosi.

3.2.3 Il taglio bidimensionale

La terza possibilità taglia A in entrambe le direzioni: ogni processo possiede un *rettangolo* della matrice. Le due necessità di prima compaiono ora entrambe — servono le righe di X corrispondenti alle proprie colonne di A , e il proprio contributo a Y è parziale e va sommato — ma ciascuna coinvolge soltanto un **sottoinsieme** dei processi: quelli che condividono le stesse colonne di A per la prima, quelli che condividono le stesse righe per la seconda. Nessuna delle due comunicazioni è più globale.

È questa la decomposizione richiesta dalla traccia, ed è quella che il progetto implementa. Che sia effettivamente superiore alle due monodimensionali non è però qualcosa da accettare sulla fiducia: è una proprietà quantificabile, e la sezione 3.8 la dimostra con un modello di costo, mostrando che le due decomposizioni 1D ne sono i casi degeneri. Il confronto viene poi misurato direttamente in capitolo 7.




Figura 3.1: Decomposizione dei dati su una griglia 2×3 . Ogni processo possiede un *rettangolo* di A , individuato dalle sue coordinate nella griglia. Il multivettore X è tagliato per bande di righe, una per ciascuna banda di colonne di A ; Y per bande di righe, una per ciascuna banda di righe di A . Nessuna delle due è mai tagliata lungo k .

3.2.4 Perché i processi vengono organizzati a griglia

Resta un ultimo passaggio, che è di comodità ma non solo. Se il taglio del dato è bidimensionale, conviene che lo sia anche il modo in cui si identificano i processi: un processo individuato da una coppia di coordinate (r, c) invece che da un intero rende immediate le due relazioni che servono di continuo. «I processi che possiedono le stesse colonne di A » diventa «i processi della stessa colonna della griglia», e non un calcolo aritmetico sui rank da rifare ogni volta.

MPI offre questa struttura nativamente, sotto il nome di **topologia virtuale cartesiana**. È virtuale nel senso che non descrive come i nodi sono fisicamente cablati: descrive come il programma vuole *pensare* all'insieme dei propri processi, lasciando però all'implementazione la possibilità di sfruttare quell'informazione per disporli meglio sulla macchina reale.

3.3 Decomposizione a griglia bidimensionale

I P processi vengono organizzati in una griglia cartesiana $P_r \times P_c = P$, costruita con `MPI_Cart_create`. La chiamata restituisce un nuovo comunicatore nel quale ogni processo ha, oltre al proprio rank, una coppia di coordinate recuperabile con `MPI_Cart_coords`: sono le (r, c) della sezione precedente, ed è su di esse che il codice ragiona da qui in avanti.

Due parametri della chiamata meritano una nota:

- la griglia è dichiarata **non periodica**. La periodicità serve agli schemi in cui ogni processo comunica con i propri vicini e il bordo deve richiudersi sul lato opposto; qui le comunicazioni sono collettive lungo un'intera riga o colonna, e un collegamento fra l'ultimo processo e il primo non avrebbe alcun significato;
- `reorder = 1` autorizza l'implementazione a **rinumerare** i processi rispetto a `MPI_COMM_WORLD`, per far corrispondere meglio la griglia logica alla topologia fisica della macchina. È la libertà che rende utile una topologia virtuale, ma ha una conseguenza da non dimenticare: da quel momento l'unico rank valido è quello del nuovo comunicatore, e assumere che coincida con quello di partenza sarebbe un errore.

La forma della griglia può essere imposta dall'utente con i flag `-pr` e `-pc`. In assenza di indicazione, `grid_default_shape` sceglie la fattorizzazione più vicina alla forma quadrata, prendendo come P_r il più grande divisore di P non superiore a $\sqrt{P}$; ne segue $P_r \leq P_c$, e nel caso limite di P primo la griglia degenera in $1 \times P$. La ragione per cui il quadrato è un buon default, e i casi in cui non lo è, sono in sezione 3.8.

3.3.1 I due sotto-comunicatori

La griglia da sola non basta: le collettive vanno eseguite lungo una riga o lungo una colonna, non sull'insieme di tutti i processi, e una collettiva agisce su un comunicatore intero. Servono quindi comunicatori più piccoli, uno per ogni riga e uno per ogni colonna della griglia.

Li produce `MPI_Cart_sub`, a cui si indica quali dimensioni lasciar variare e quali tenere fisse. Fissando la coordinata di riga e lasciando variare quella di colonna si ottiene `row_comm`, che raccoglie i processi di una stessa *riga*; fissando la colonna si ottiene `col_comm`, che raccoglie quelli di una stessa *colonna*. Ogni processo appartiene esattamente a un `row_comm` e a un `col_comm`, e sono i due assi lungo cui viaggiano le uniche due collettive del cammino cronometrato.

3.3.2 Chi fa da root, e perché la scelta è verificata

Entrambe le collettive hanno bisogno di un root, e in entrambi i casi il processo giusto è determinato dal problema, non arbitrario: il broadcast di X deve partire dal processo di riga 0, che è l'unico a possedere inizialmente quella fetta, e la reduce di Y deve arrivare al processo di colonna 0, che è il proprietario designato di quella porzione del risultato.




Figura 3.2: La stessa griglia, raggruppata nei due modi. Fissando la coordinata di riga si ottengono i comunicatori `row_comm`, fissando quella di colonna i comunicatori `col_comm`. Ogni processo appartiene a esattamente uno di ciascun tipo, e i due si intersecano soltanto in lui.

Indicare il root a una collettiva significa però indicarne il *rank nel sotto-comunicatore*, non le coordinate nella griglia. Il codice sfrutta allora una proprietà di `MPI_Cart_sub`: in un sotto-comunicatore con una sola dimensione residua i rank risultano ordinati per coordinata crescente. Ne segue che il rank 0 di `col_comm` è il processo di riga 0, e il rank 0 di `row_comm` è il processo di colonna 0: in entrambi i casi il root cercato, e le due collettive possono usare semplicemente 0.

La proprietà viene comunque **verificata** in `grid_create`, confrontando il rank in ciascun sotto-comunicatore con la coordinata cartesiana corrispondente. Il motivo è la libertà concessa da `reorder = 1`: se l'ipotesi cadesse, le collettive continuerebbero a funzionare regolarmente, ma con il root sbagliato, e il programma produrrebbe risultati errati senza segnalare nulla.

3.4 Partizionamento degli indici

Decidere la forma della griglia non basta: bisogna ancora stabilire, per ciascuna delle due dimensioni, quali indici globali finiscano su quale parte. La regola è una sola e viene applicata due volte — alle righe di A fra le P_r righe della griglia, alle colonne fra le P_c colonne — ed è una partizione **a blocchi**: ogni parte riceve un intervallo contiguo di indici, e il resto della divisione viene distribuito un elemento per volta sulle prime parti.

Il blocco contiguo non è una scelta di comodo. L'alternativa naturale sarebbe una distribuzione ciclica, che assegna gli indici a turno; ma qui il lavoro per elemento è uniforme, quindi il ciclico non bilancerebbe nulla che il blocco già non bilanci, e in cambio distruggerebbe la contiguità — cioè proprio la proprietà da cui dipendono sia il datatype derivato della distribuzione (sezione 3.6) sia il passo unitario degli accessi dello schema A (sezione 2.3).

3.4.1 Le funzioni

Posti $q = \lfloor n/p \rfloor$ e $r = n \bmod p$, le prime r parti hanno $q + 1$ elementi e le restanti q . Da qui le prime due funzioni, che dicono *quanti* elementi tocchino alla parte i e *da dove* cominci:

$$\text{size}(n, p, i) = q + \begin{cases} 1 & i < r \\ 0 & \text{altrimenti} \end{cases} \quad \text{start}(n, p, i) = i q + \min(i, r). \quad (3.1)$$

Il $\min(i, r)$ nell'offset conta quante parti *lunghe* precedono la parte i : finché $i < r$ sono tutte lunghe e se ne accumula una per ciascuna, dopo il loro numero resta fermo a r . La funzione è definita anche per $i = p$, dove vale n : una sentinella che rende l'ultima parte un caso come gli altri.

Lo sbilanciamento massimo è di un elemento per dimensione: fra due blocchi locali qualsiasi c'è al più una riga e una colonna di differenza.

3.5 Layout dei blocchi locali

Applicando la partizione alle due dimensioni si ottiene la forma dei tre blocchi che ogni processo possiede:

$$A_{\text{loc}} : m_{\text{loc}} \times n_{\text{loc}}, \quad X_{\text{loc}} : n_{\text{loc}} \times k, \quad Y_{\text{loc}} : m_{\text{loc}} \times k, \quad (3.2)$$

con $m_{\text{loc}} = \text{size}(M, P_r, \text{my_row})$ e $n_{\text{loc}} = \text{size}(N, P_c, \text{my_col})$.

3.5.1 Perché i conteggi delle collettive tornano

Nelle due formule qui sopra c'è una proprietà che vale la pena rendere esplicita, perché è la condizione di consistenza delle due collettive: m_{loc} dipende **solo** da `my_row` e n_{loc} **solo** da `my_col`.

Ne segue che tutti i processi di una stessa riga della griglia concordano su m_{loc} , e tutti quelli di una stessa colonna concordano su n_{loc} . Sono esattamente i due gruppi su cui agiscono le collettive: il broadcast lungo `col_comm` usa un conteggio di $n_{\text{loc}} \cdot k$ elementi, e i suoi partecipanti condividono la colonna, dunque n_{loc} ; la reduce lungo `row_comm` usa $m_{\text{loc}} \cdot k$, e i suoi partecipanti condividono la riga, dunque m_{loc} . Nessuno dei due conteggi va negoziato o comunicato: viene dalla stessa formula, valutata su coordinate che i partecipanti hanno in comune.

3.5.2 Chi contiene che cosa, e quando

Il buffer X_{loc} esiste su *tutti* i processi — il broadcast deve avere dove scrivere — ma prima del broadcast contiene dati significativi soltanto sui processi della riga 0. Dopo il prodotto locale ogni processo possiede un contributo *parziale* a Y , che riguarda le proprie righe ma soltanto le proprie colonne di A ; la `MPI_Reduce` lungo `row_comm` li somma e produce il blocco definitivo sui processi della colonna 0.

3.5.3 Perché il multivettore non viene mai tagliato lungo k

Le k colonne restano indivise su tutti i processi. Tre ragioni, in ordine di peso:

- **costringerebbe a replicare A .** Per calcolare un qualunque sottoinsieme di colonne di Y serve comunque *tutta* A : i processi di una stessa partizione lungo k vorrebbero perciò lo stesso identico blocco di A . Si duplicherebbe il dato dominante (`??`), che è l'opposto di ciò per cui la decomposizione esiste;
- **ridurrebbe il riuso di A in registro.** Nello schema A il fattore di riuso è pari al numero di colonne che il processo possiede localmente (sezione 2.3): frazionare k lo frazionerebbe nella stessa misura, abbassando l'intensità aritmetica del nucleo;
- **produrrebbe messaggi troppo piccoli.** k è piccolo per definizione del problema, e frammentarlo ulteriormente darebbe comunicazioni dominate dalla latenza invece che dalla banda.

Invariante critico

Il numero di righe locali di X deve venire dalla *stessa* partizione con cui si tagliano le colonne di A , e il numero di righe locali di Y dalla stessa con cui se ne tagliano le righe. Non è un controllo da eseguire, è una proprietà garantita *per costruzione*: esistono soltanto m_{loc} e n_{loc} , calcolati una volta sola in `layout_init`, e non due coppie di valori da tenere allineate. La struttura `layout_t` è il punto unico di verità sulla forma dei blocchi, e finché resta tale l'invariante non può essere violato senza modificarla.

3.6 Distribuzione iniziale dei dati

Le modalità di inizializzazione di A e X sono indipendenti (`-a-mode`, `-x-mode`), e tutte e quattro le combinazioni sono valide. Le due modalità di ciascuna matrice producono gli stessi elementi globali a parità di seed, per la proprietà del generatore discussa in sezione 2.5.

-a-mode global. Il grid rank 0 materializza A completa e la distribuisce. È il caso interessante dal punto di vista MPI: i sottoblocchi 2D **non sono contigui** nella matrice row-major globale. Il mittente descrive il blocco da inviare con un `MPI_Type_vector` di m_{loc} blocchi da n_{loc} elementi e stride N . Il destinatario ne descrive uno con stride `lda`, che può essere diverso: è il caso generale - due layout differenti sui due lati della stessa comunicazione - e non richiede nessun buffer intermedio né nessuna copia manuale. Il rank 0 fa eccezione per il proprio blocco, che copia direttamente senza passare da MPI.

-a-mode local. Ogni processo genera direttamente il proprio blocco 2D di A dagli indici globali. In questo modo non è necessario materializzare una copia globale aggiuntiva della matrice su un singolo processo.

-x-mode global Il grid rank 0 materializza la X compatta $N \times k$ e un `MPI_Scatterv` sul `row_comm` della riga 0 ne distribuisce i blocchi di righe: entrambi i lati sono contigui, perché $ldx = k$ ovunque, quindi non serve nessun datatype derivato.

-x-mode local I processi della riga 0 generano direttamente le proprie righe di X . Il successivo broadcast lungo `col_comm` è identico alla modalità `global`.

Generazione e distribuzione iniziale fanno parte del **preprocessing**, perciò sono escluse dai tempi ufficiali. La modalità `global` rappresenta uno scenario in cui l'input è inizialmente centralizzato.

3.7 L'algoritmo distribuito

Un'invocazione del prodotto esegue tre passi:

```
MPI_Bcast(X_loc, n_loc*k, SCALAR_MPI_TYPE, 0, grid->col_comm);

local_gemm(local_gemm_context, X_loc, layout->ldx, Y_loc_part, layout->ldy);

MPI_Reduce(Y_loc_part, Y_row_col0, m_loc*k, SCALAR_MPI_TYPE,
           MPI_SUM, 0, grid->row_comm);
```

Listato 3.1: Il corpo di `mpi_matmul`, senza i cronometri.

1. **Broadcast di X lungo `col_comm`:** tutti i processi di una colonna della griglia lavorano sulle stesse colonne di A , quindi servono loro le stesse righe di X . Il root è il processo di riga 0, l'unico che possiede inizialmente quella fetta, ne è il *responsabile*.
2. **Prodotto locale:** il risultato è *parziale*: il processo in posizione (r, c) calcola il contributo delle sole colonne $[col_0, col_0 + n_{loc})$ di A alle righe $[row_0, row_0 + m_{loc})$ di Y (dove row_0 e col_0 sono gli offset globali del blocco locale).
3. **Reduce lungo `row_comm`:** i P_c contributi parziali della stessa banda di righe vivono sui processi di una stessa riga della griglia: sommandoli tra loro si ottiene Y . Il count è $m_{loc} \cdot k$ (e non 1) dato che la riduzione agisce lungo la dimensione dei processi e preserva la posizione, producendo dunque $m_{loc} \cdot k$ somme indipendenti. Il root è il processo di colonna 0, che è già il *responsabile* designato di quella porzione di Y : nessuna ridistribuzione finale è necessaria.




Figura 3.3: Le due collettive di una singola invocazione. Il broadcast fa scendere la fetta di X dal processo di riga 0 a tutti i processi della sua colonna, che ne hanno bisogno perché condividono le stesse colonne di A . Dopo il prodotto locale ogni processo possiede un contributo *parziale* a Y : la reduce somma i P_c parziali di una stessa banda di righe e deposita il risultato sul processo di colonna 0, che ne è il proprietario designato.

3.8 Modello di costo della comunicazione

Il costo di un messaggio di n byte fra due processi si modella, seguendo le dispense del corso, come

$$T(n) = \lambda + \frac{n}{B}, \quad (3.3)$$

dove λ è la *latenza*, un costo fisso che si paga per ogni messaggio indipendentemente dalla sua taglia, e B è la *banda*. In letteratura lo stesso modello compare spesso nella forma $\alpha + \beta n$: il dizionario è $\alpha \equiv \lambda$ e $\beta \equiv 1/B$.

Le due collettive non sono però messaggi singoli. Il costo logaritmico che segue è quello del *recursive doubling*, l'algoritmo di broadcast visto a lezione, che al posto dei $p-1$ invii sequenziali della versione ingenua costa $T(p) = \lceil \log_2 p \rceil$ tempi di messaggio. Il logaritmo si ottiene grazie a un'ipotesi precisa sulla rete — che essa sostenga più messaggi contemporaneamente, purché le coppie di nodi coinvolte non si sovrappongano — ed è quell'ipotesi, più che la struttura ad albero, a rendere possibile il guadagno.

Detti s i byte per scalare, il costo di comunicazione per invocazione è quindi

$$T_{\text{comm}} \approx \underbrace{\lceil \log_2 P_r \rceil \left(\lambda + \frac{s k N / P_c}{B} \right)}_{\text{broadcast di } X} + \underbrace{\lceil \log_2 P_c \rceil \left(\lambda + \frac{s k M / P_r}{B} + \gamma k \frac{M}{P_r} \right)}_{\text{reduce di } Y}, \quad (3.4)$$

dove γ è il costo per elemento della somma eseguita dalla reduce. Il termine in γ non compare nel modello del corso, che descrive il costo del solo trasferimento: lo aggiungiamo perché la reduce, a differenza del broadcast, a ogni livello dell'albero esegue anche $m_{\text{loc}} \cdot k$ addizioni.

Il modello va letto per quello che è: i fattori logaritmici valgono se l'implementazione usa il recursive doubling, ma le librerie MPI cambiano algoritmo al crescere del messaggio e per messaggi grandi passano a schemi a pipeline o scatter/allgather, nei quali il termine di banda perde il fattore logaritmico e resta proporzionale al solo volume trasferito.

Il modello va letto per quello che è: i fattori logaritmici valgono se l'implementazione usa il recursive doubling, ma — come le dispense stesse osservano — una buona libreria MPI commuta internamente fra algoritmi diversi a seconda dell'operazione, della rete e soprattutto della quantità di dati. Per messaggi grandi si passa a schemi a pipeline o scatter/allgather, nei quali ogni byte attraversa la rete una volta sola invece di $\log_2 p$ volte: il termine di banda perde il fattore logaritmico e resta proporzionale al solo volume, al prezzo di un numero maggiore di messaggi e quindi di più latenza.

Alle taglie della campagna i messaggi cadono in quel regime, quindi il $\log_2$ va inteso come limite superiore sui termini di latenza più che come andamento atteso della banda. Questo non intacca però la conclusione che segue: il *volume*, cioè l'unica quantità da cui dipende la scelta della forma della griglia, è lo stesso per qualunque algoritmo collettivo, perché è quanto ciascun processo deve comunque ricevere o inviare.

Il termine che decide la forma ottima della griglia è il volume:

$$V(P_r, P_c) = k \left(\frac{N}{P_c} + \frac{M}{P_r} \right), \quad P_r P_c = P. \quad (3.5)$$

Minimizzando con il vincolo $P_r P_c = P$ si ottiene

$$P_r^* = \sqrt{P \frac{M}{N}}, \quad P_c^* = \sqrt{P \frac{N}{M}}, \quad V^* = \frac{2k\sqrt{MN}}{\sqrt{P}}. \quad (3.6)$$

Due letture, entrambe verificate sperimentalmente in capitolo 7:

- **Perché 2D e non 1D.** Le due decomposizioni monodimensionali sono i casi degeneri $P_r = 1$ (volume kM , nessun broadcast ma reduce su tutti i P processi) e $P_c = 1$ (volume kN , nessuna reduce ma broadcast su tutti i P). In entrambi il volume *non decresce* con P , mentre la griglia 2D lo fa scendere come $1/\sqrt{P}$. È il motivo per cui la traccia richiede una griglia bidimensionale, ed è ciò che la campagna C6 misura direttamente confrontando tutte le fattorizzazioni di P , forme degeneri comprese.
- **Perché la forma ottima dipende da $M:N$.** Per $M = N$ la griglia migliore è quella quadrata, cioè proprio quella che `grid_default_shape` sceglie da sé — ed è anche quella che lo standard MPI sceglierebbe da sé, visto che `MPI_Dims_create` costruisce la griglia più vicina possibile alla forma quadrata. La eq. (3.6) dice però che quel default è ottimo *soltanto* per $M = N$; per $M = 3N$ conviene invece $P_r > P_c$. La campagna C1 varia il rapporto $M:N$ a lavoro costante e rende visibile questo effetto separandolo da quello della taglia.

Un'osservazione che va tenuta presente leggendo il weak scaling (campagna C5): su una griglia 2D con blocco locale costante, M segue P_r e N segue P_c , quindi cambiare P cambia *anche* il rapporto $M:N$. È inerente alla decomposizione, ed è la ragione per cui l'effetto della forma viene misurato separatamente in C1 e C6.

Capitolo 4

Il nucleo di CPU

Il nucleo di CPU non è la parte più veloce del progetto, ma è quella di cui tutto il resto ha bisogno per essere giudicato: è il denominatore di ogni speedup, ed è l'unica implementazione che gira ovunque, anche su una macchina senza `nvcc`. Merita quindi lo stesso lavoro dei backend CUDA, e per le stesse ragioni.

4.1 Tre backend, una sola idea

Tutti e tre i backend di CPU implementano lo schema A di sezione 2.3: cambia come il lavoro viene organizzato attorno a quell'ordine dei cicli, non l'ordine. Si scelgono a tempo di compilazione con la variabile `KERNEL` del `Makefile`, espongono la stessa interfaccia (??) e i binari coesistono, così un confronto è una sola campagna sugli stessi dati.

- **scheme_a**: l'implementazione di riferimento, quella che corrisponde alla consegna;
- **scheme_a_jblock**: l'implementazione di riferimento è la stessa del caso precedente, ma con X in cui è stato applicato un meccanismo di *tiling* in cache;
- **scheme_a_jblock_rb**: come sopra, ma all'implementazione è stato aggiunto il *register blocking* sulle righe di A .

I tre non sono tre implementazioni alternative, ma riflettono la **catena** di sviluppo: ciascuno rimuove il collo di bottiglia che il precedente lascia scoperto. Il capitolo li presenta in quest'ordine, e ogni sezione si apre con il limite che motiva il backend successivo.

4.2 Il backend di riferimento

4.2.1 Perché specializzare k a compile-time

Nello schema A i k accumulatori sono variabili locali del ciclo su j , e tutto il vantaggio dello schema dipende dal fatto che questi accumulatori vivano nei **registri**: è lì che il valore $A[i][j]$, letto una volta sola, può essere riutilizzato k volte.

Affinché il compilatore possa rappresentare gli accumulatori come un insieme fisso di valori scalari candidati a vivere nei registri, il numero di accumulatori deve essere *noto a compile-time*. Con un array dimensionato dinamicamente, invece, l'accesso `acc[c]` conserva un indice runtime e il compilatore non dispone della stessa struttura esplicita.

Se il numero di accumulatori è noto solo quando il programma parte, la variabile `acc` diventa un array in memoria e ogni operazione di accumulazione (`acc[c] += ...`) è un accesso a quella memoria: esattamente il traffico che lo schema A serviva a evitare.

Il codice risolve generando **cinque funzioni specializzate**, per $k \in 3, 6, 8, 20, 32$, cioè per i cinque valori richiesti dalla traccia, a partire da una sola definizione via macro:

```
#define COLS_8(M) COLS_6(M) M(6) M(7)
#define DECLARE_ACC(c) scalar_t acc##c = (scalar_t)0;
#define UPDATE_ACC(c) acc##c += a * xrow[c];
#define STORE_ACC(c) yrow[c] = acc##c;

/* per ogni riga i: */
COLS(DECLARE_ACC)
for (j = 0; j < n_loc; j++) {
    const scalar_t a = arow[j];          /* letto UNA volta */
    const scalar_t *restrict xrow = X_loc + (size_t)j * ldx;
    COLS(UPDATE_ACC)                     /* k aggiornamenti espliciti */
}
COLS(STORE_ACC)
```

Listato 4.1: Generazione delle specializzazioni (estratto di `src/kernel/scheme_a.c`).

Vale la pena leggere che cosa producono queste righe: `COLS_8` è un elenco di indici, applicarlo a `DECLARE_ACC` genera 8 dichiarazioni di variabili scalari *distinte* (`acc0`, `acc1`, ...), non un array, mentre applicarlo a `UPDATE_ACC` genera 8 aggiornamenti scritti per esteso, senza alcun ciclo interno con estremo runtime.

L'hot path che il compilatore vede non contiene quindi nessuna indicizzazione su `c`: contiene k istruzioni indipendenti su k variabili indipendenti, che fornisce al compilatore una forma particolarmente favorevole all'allocazione degli accumulatori nei registri e alla successiva vettorizzazione.

La generazione effettiva di codice vettoriale e l'eventuale uso di FMA sono proprietà del codice macchina prodotto dal compilatore e vengono quindi verificate separatamente tramite profilazione.

In questo contesto, vettorizzare un ciclo significa che il compilatore riesce a trasformare le k istruzioni indipendenti in un'unica istruzione vettoriale, che opera su W scalari per volta, dove W è la larghezza del registro vettoriale della CPU, utilizzando istruzioni SIMD. Se k è minore di W , il compilatore può comunque generare un'istruzione vettoriale, ma non sarà completamente utilizzata. Se k è maggiore di W , il compilatore genererà più istruzioni vettoriali per coprire tutti gli accumulatori.

4.2.2 Il fallback generico, e perché la traccia lo richiede

La traccia chiede però che il codice funzioni per k *generico*, e cinque specializzazioni non possono coprire tutti i valori possibili. Per ogni altro k interviene un **fallback generico**, che non tenta di tenere k accumulatori distinti, perché sarebbero troppi e finirebbero in memoria, ma lavora a gruppi di al più $KB = 32$ colonne per volta. Ogni gruppo richiede una passata completa su A , con un numero di passaggi pari a:

$$\text{passaggi su } A = \left\lceil \frac{k}{KB} \right\rceil. \quad (4.1)$$

Per $k \leq KB$ il ciclo esterno sui gruppi è *degenere*: esiste nel codice ma gira una volta sola, A viene letta una volta sola e il fallback si differenzia dalle specializzazioni soltanto per l'array di accumulatori invece delle variabili distinte. Per $k > 32$ il numero di passaggi cresce secondo $\lceil k/32 \rceil$, ad esempio tra 33 e 64 sono necessari due passaggi, tra 65 e 96 tre, e così via.

La conseguenza va tenuta presente leggendo i risultati: le righe dei k oltre la soglia e quelle dei k entro la soglia **non sono direttamente confrontabili**, perché non stanno facendo la stessa quantità di lavoro di memoria.

4.3 Perché $KB = 32$

Il valore copre tutti i k del collaudo, ma questa da sola non è una ragione sufficiente. La ragione vera è un budget di registri.

Infatti con KB accumulatori il compilatore deve tenere KB valori vivi attraverso l'intero ciclo su j . Vettorizzati, occupano KB/W registri vettoriali, dove W è il numero di scalari che entrano in un registro, a fronte di 16 registri vettoriali sulle configurazioni AVX2 e 32 sulle configurazioni AVX-512. Al crescere di KB il riuso di A migliora, perché i passaggi della eq. (4.1) diminuiscono, ma cresce la pressione sui registri fino al fenomeno del *register spilling*, cioè fino al punto in cui il compilatore è costretto a parcheggiare in memoria gli accumulatori che non stanno più nei registri e a quel punto si va a perdere più di quanto si guadagni.

Il valore 32 è quindi il compromesso scelto dall'implementazione: è sufficiente a coprire in un solo passaggio tutti i 5 k richiesti dalla traccia, ma mantiene il numero di accumulatori entro una dimensione compatibile con un'implementazione a registri. Il fatto che tale scelta eviti effettivamente lo spilling e sia ottimale sulla macchina di riferimento non è assunto come proprietà teorica: viene verificato sperimentalmente nella campagna C3 (sezione 7.5).

4.4 Ciò che il compilatore vede

Affinché questo basti, il codice deve rispondere da sé alle tre domande che un compilatore si pone prima di vettorizzare un ciclo.

- «**Questi puntatori possono riferirsi alla stessa memoria?**» No: A , X e Y sono dichiarati **restrict**. La garanzia va però *ripristinata* dentro `local_gemm`, con copie locali dei puntatori: il contesto opaco tiene il puntatore ad A come membro di una struttura, e senza quella copia i kernel specializzati perderebbero l'informazione di non aliasing che avevano quando A era un parametro. Se l'aliasing fosse possibile, ogni scrittura su Y potrebbe invalidare A e il ciclo andrebbe eseguito in ordine.
- «**Le iterazioni dipendono l'una dall'altra?**» No: i k aggiornamenti `acc[c] += a * X[j][c]` riguardano accumulatori distinti e sono indipendenti fra loro. Essendo già srotolati dalle macro, si presentano come catene di moltiplicazione-accumulo indipendenti, che è la forma che una unità FMA può eseguire in parallelo.
- «**Gli accessi sono regolari?**» Sì, e a passo unitario: come osservato in sezione 2.3, sia la riga di A sia la riga di X sono contigue in memoria.

Da completare con i dati della campagna

Verificare sul server l'effettiva vettorizzazione del percorso caldo, per esempio con `gcc -fopt-info-vec` oppure ispezionando l'assembly di `kernel_k8` e `kernel_k32`. Il punto da documentare è se e a quale k compaiano spill degli accumulatori.

4.5 Il primo limite: la rilettura di X

Lo schema A legge A una volta sola, ed è il suo pregio. Ma per ogni riga i di A percorre **tutta** X , e questo è il suo prezzo: il traffico in lettura su X vale

$$\text{elementi di } X \text{ letti} = m_{\text{loc}} \cdot n_{\text{loc}} \cdot k, \quad (4.2)$$

cioè k volte il traffico su A .

Finché X resta in una cache vicina al calcolo questo traffico non raggiunge la memoria centrale e semplicemente non si vede. Quando X non ci sta più, viene ristreamata da un livello più lontano una volta per ogni riga di A , e il tempo per elemento smette di essere governato dal calcolo per essere governato dalla banda di quel livello.

La soglia è esplicita e dipende da entrambi i parametri del problema: il blocco locale X_{loc} occupa $n_{\text{loc}} \cdot k \cdot s$ byte. A parità di matrice, quindi, è k **che decide da che parte della soglia ci si trova**, ed è per questo che l'effetto si manifesta come un calo dei GFLOPS al crescere di k — cioè nella direzione opposta a quella che l'intensità aritmetica della eq. (2.3) lascerebbe prevedere. È la chiave di lettura dei risultati di sezione 7.5, ed è il limite che il backend successivo rimuove.

4.6 Secondo backend: X mattonellata in cache

L'idea di `scheme_a_jblock` è di non percorrere più tutta X per ogni riga di A , ma di prenderne un **tile** — un blocco di righe consecutive — e di applicarlo a tutte le righe di A prima di passare al successivo:

```
for j0 (tile di X di BJ righe):
  for i (TUTTE le righe di A):
    acc = (primo tile) ? 0 : Y[i][*]
    for j nel tile: a = A[i][j]; acc[c] += a * X[j][c]
    Y[i][*] = acc
```

Listato 4.2: Struttura di `src/kernel/scheme_a_jblock.c`.

Il tile viene caricato dalla memoria una volta e riusato m_{loc} volte restando in cache. A continua a essere letta *una volta sola*: ogni sua riga viene semplicemente consumata a segmenti, uno per tile, invece che tutta di seguito.

Il prezzo. Y non può più vivere nei registri per tutta la durata di una riga, perché ci si torna sopra a ogni tile: va riletta e riscritta ogni volta. Il traffico aggiuntivo vale $2k$ scalari per riga e per tile, cioè un rapporto $2k/\text{BJ}$ rispetto al traffico su A . Il tile va quindi scelto *grande* abbastanza da rendere questo termine trascurabile e *piccolo* abbastanza da stare in cache: le due richieste tirano in direzioni opposte, e il punto di equilibrio non è deducibile a priori.

Per questo la dimensione del tile è un parametro di build, `JBLOCK_BYTES`, e non una costante scelta una volta per tutte: il codice ne ricava il numero di righe per tile dividendo per $k \cdot s$, il default è un valore che sta nella cache di secondo livello di qualunque core x86 recente, e quale sia il valore migliore è oggetto di misura.

Un principio già visto. È esattamente la stessa mossa del backend CUDA con tile in shared memory (??): portare un blocco di X in una memoria vicina al calcolo e riusarlo per molte righe prima di passare al blocco successivo. Cambia il nome della memoria vicina — lì la shared memory, qui la cache — non il ragionamento.

4.7 Terzo backend: register blocking sulle righe

Tolto il limite di banda, ne resta scoperto un altro, che si manifesta ai k *piccoli*: in tutti i backend visti finora ogni `acc[c]` è una catena *seriale* di moltiplicazioni-accumulo lungo j — ogni aggiornamento deve attendere il precedente — e l'unico parallelismo a livello di istruzione

disponibile è quello fra le k colonne. Poiché una unità FMA ha una latenza di diversi cicli e la CPU ne ha più di una, per tenerle occupate servono più catene indipendenti di quante k piccolo ne offra: il processore aspetta, e i GFLOPS crescono con k invece di essere costanti.

`scheme_a_jblock_rb` risolve lavorando su RB righe di A per volta:

```
for j0 (tile di X, come in scheme_a_jblock):
  for i a passi di RB:
    acc[r][c] = (primo tile) ? 0 : Y[i+r][c]
    for j nel tile:
      x[c] = X[j][c] /* caricato UNA volta */
      for r: a = A[i+r][j]; acc[r][c] += a * x[c] /* riusato RB volte */
    Y[i+r][c] = acc[r][c]
```

Listato 4.3: Struttura di `src/kernel/scheme_a_jblock_rb.c`.

Le righe di A sono indipendenti per costruzione — nessun elemento di Y dipende da un'altra riga — quindi il numero di catene indipendenti passa da $\lceil k/W \rceil$ a $RB \cdot \lceil k/W \rceil$. In più, ogni valore di X caricato viene riusato RB volte direttamente dai registri, quindi anche il traffico su X — già in cache grazie al tile — si riduce dello stesso fattore.

Chi sceglie RB. Anche qui il limite sono i registri: $RB \cdot \lceil k/W \rceil$ accumulatori più RB valori di A devono starci tutti, altrimenti si torna allo spill e si perde più di quanto si guadagni. Il codice sceglie perciò RB *a tempo di compilazione e per ogni k* , dal numero di registri vettoriali e dalla loro ampiezza dell'architettura di destinazione (`VEC_NREGS` e `VEC_W`, fissati dalle macro del compilatore), prendendo il più grande fra i valori ammessi che soddisfi il vincolo; la variabile di build `RB_ROWS` permette di forzarlo per misurarne l'effetto. Le righe che avanzano quando m_{loc} non è multiplo di RB sono chiuse dal kernel a una riga, che è il caso $RB = 1$ dello stesso schema.

I tre backend rispondono quindi a tre limiti diversi e successivi: il traffico su A , risolto dallo schema A stesso; la banda verso X , risolta dal tile in cache; il parallelismo di istruzione, risolto dal blocco di righe. Quanto ciascuno dei tre passi valga davvero sulla macchina di misura è ciò che la campagna riportata in capitolo 7 quantifica.

Capitolo 5

I backend CUDA

L'implementazione su GPU è stata sviluppata attraverso tre kernel CUDA, affiancati da un backend basato su cuBLAS, usato come riferimento esterno. Le diverse versioni non sono state progettate come soluzioni indipendenti: partono dalla stessa operazione locale, $Y = AX$, e introducono progressivamente modifiche mirate alla mappatura del lavoro e agli accessi alla memoria.

In particolare, il percorso seguito è il seguente:

- **cuda_naive** costituisce la baseline CUDA. A ciascun thread viene assegnato un singolo elemento Y_{ic} : il thread fissa quindi una riga i di A e una colonna c di X , e percorre l'intera dimensione interna j per calcolarne il prodotto scalare. La mappatura è semplice e offre un primo termine di confronto, ma non sfrutta il riuso della riga di A tra le k colonne del multivettore.
- **cuda_warp** cambia la granularità della parallelizzazione: non più un thread per elemento di Y , ma un *warp* per un'intera riga di Y . Le 32 lane del warp si suddividono gli elementi della corrispondente riga di A e ciascuna lane riutilizza il valore di A appena caricato per aggiornare i k risultati della riga. Al termine, i contributi prodotti dalle lane vengono sommati mediante primitive di warp shuffle.
 - **cuda_warp** nella variante **xcol** mantiene esattamente la stessa organizzazione del calcolo, ma modifica la rappresentazione di X . Il blocco locale del multivettore viene convertito una sola volta, durante il preprocessing, da una disposizione in memoria per righe (*row-major*) a una disposizione per colonne (*column-major*). In questo modo quando le lane del warp avanzano su indici j consecutivi, accedono anche a elementi consecutivi di X .
 - **cuda_warp_smem** affronta lo stesso problema degli accessi a X senza però andarne a modificare il layout. Un blocco di thread carica *cooperativamente* una porzione di X dalla memoria globale alla **shared memory**. I warp appartenenti allo stesso blocco possono quindi riutilizzare quella stessa porzione durante il calcolo delle rispettive righe di Y .

Il passaggio da **cuda_naive** a **cuda_warp** modifica la mappatura del lavoro e introduce il riuso di A all'interno del warp. A questo punto è emerso un problema: con X nel normale layout row-major, le lane che avanzano lungo j non leggono elementi consecutivi del multivettore.

La variante **xcol** interviene sulla *rappresentazione del dato*, convertendo preventivamente X in un layout più favorevole agli accessi del warp, mentre **cuda_warp_smem** conserva il layout originario e interviene sul *percorso del dato*, caricando e riutilizzando X attraverso la *shared*

memory. Le due versioni permettono così di studiare due strategie diverse per lo stesso collo di bottiglia, senza sovrapporle nello stesso kernel.

Infine, si propone anche un'implementazione su GPU basata su cuBLAS, la libreria NVIDIA per algebra lineare ottimizzata per GPU:

- **cublas** non rappresenta un'ulteriore ottimizzazione del kernel sviluppato nel progetto. È un riferimento esterno, inserito dietro la stessa interfaccia degli altri backend, che permette di confrontare le implementazioni precedenti con una libreria GPU general-purpose sulla stessa macchina e nelle stesse condizioni di misura.

5.1 Struttura comune

Tutti i backend GPU rispettano lo stesso ciclo di vita a tre fasi introdotto in sezione 2.6.1, che permette di confrontare le diverse implementazioni misurando, in ciascun caso, la stessa porzione dell'esecuzione.

La distinzione fondamentale deriva dal diverso ruolo dei dati. Il blocco locale di A non cambia tra un'invocazione del prodotto e la successiva e può quindi essere trasferito sulla GPU una sola volta. Al contrario, la fetta locale di X deve essere resa disponibile a ciascun processo a ogni invocazione del prodotto: le sue porzioni sono inizialmente collocate sulla prima riga della griglia di processi e vengono replicate lungo ciascuna colonna mediante `MPI_Bcast.`, mentre il risultato parziale Y deve essere riportato sull'host prima della successiva `MPI_Reduce.` Di conseguenza, le operazioni comuni ai backend CUDA sono distribuite nelle tre fasi nel modo seguente:

- **local_gemm_create** prepara il backend prima dell'inizio delle ripetizioni cronometrate. In questa fase viene inizializzato il contesto CUDA, vengono allocati in VRAM i buffer destinati ad A , X e Y , vengono creati gli eventi CUDA usati per le misure e il blocco locale di A viene copiato dall'host al device. Poiché A rimane invariata per tutte le invocazioni successive, questo trasferimento viene eseguito una sola volta. L'intera fase appartiene al preprocessing e non entra nel tempo ufficiale del prodotto. I suoi costi principali vengono comunque registrati separatamente come inizializzazione del device, allocazione della memoria e trasferimento H2D di A .
- **local_gemm** rappresenta invece il cammino percorso a ogni invocazione. Prima del calcolo, il nuovo blocco di X viene trasferito dall'host alla GPU. Segue l'esecuzione del kernel CUDA, oppure della chiamata cuBLAS nel backend di riferimento. Infine il risultato parziale Y viene copiato nuovamente verso l'host. Il tempo `t_local` comprende quindi l'intera sequenza H2D di X , calcolo e D2H di Y .

All'interno della stessa funzione, tre coppie distinte di `cudaEvent` delimitano separatamente il trasferimento H2D di X , il solo calcolo sul device e il trasferimento D2H di Y . Si ottengono in questo modo tre misurazioni: rispettivamente $t_{H2D X}$, t_{kernel} e $t_{D2H Y}$. Questa separazione è necessaria perché la specifica del progetto richiede di escludere dal tempo ufficiale i trasferimenti da e verso la scheda: per i backend CUDA è quindi t_{kernel} , e non l'intero t_{local} , a rappresentare il contributo del calcolo locale alla misura prestazionale.

- **local_gemm_destroy** conclude infine il ciclo di vita del backend, liberando i buffer allocati sulla GPU, gli eventi CUDA e il contesto mantenuto dall'implementazione. Anche questa fase avviene al di fuori delle ripetizioni misurate.

La stessa suddivisione viene mantenuta in tutti i backend GPU. Cambia quindi il modo in cui viene eseguito il prodotto all'interno della seconda fase, ma non cambiano né la posizione

dei trasferimenti né i confini delle misure. Il confronto tra i kernel può così essere effettuato sul solo t_{kernel} , mentre t_{local} rimane disponibile per osservare anche il costo reale dell'intera invocazione lato GPU.

5.2 Misurazione del backend CUDA

La natura asincrona dell'esecuzione CUDA richiede di distinguere il tempo osservato dall'host dal tempo trascorso effettivamente sul device. Il lancio di un kernel, infatti, restituisce il controllo alla CPU senza attendere necessariamente il completamento dell'operazione. Un cronometro host posto semplicemente prima e dopo il lancio misurerebbe semplicemente il costo della chiamata al runtime CUDA, non il tempo di esecuzione del kernel, ciò che invece ci interessa.

Per isolare le singole operazioni eseguite sul device, i backend CUDA utilizzano coppie di **cudaEvent** registrate sullo stesso stream delle operazioni misurate: in questo modo gli eventi permettono di determinare separatamente il tempo necessario al trasferimento H2D di X , all'esecuzione del calcolo e al trasferimento D2H di Y .

Il tempo della fase locale osservato dal driver, indicato con t_{local} , ha invece un significato diverso: misura l'intera invocazione del backend e comprende quindi sia il lavoro eseguito sul device sia l'overhead necessario per richiederlo e sincronizzarlo.

Schematizzando il calcolo, otteniamo:

$$t_{\text{local}} = t_{\text{H2D } X} + t_{\text{kernel}} + t_{\text{D2H } Y} + t_{\text{overhead}}, \quad (5.1)$$

dove t_{overhead} non viene misurato direttamente, ma rappresenta il residuo fra il tempo complessivo osservato dall'host e i tre intervalli misurati mediante eventi CUDA. Esso può comprendere il costo delle chiamate al runtime, delle sincronizzazioni e della gestione della strumentazione.

La distinzione è rilevante anche per la valutazione delle prestazioni, perché come richiesto dalla specifica del progetto, i trasferimenti tra host e device non devono contribuire al tempo utilizzato per calcolare i FLOPS. Per i backend CUDA il contributo computazionale è quindi t_{kernel} , mentre $t_{\text{H2D } X}$ e $t_{\text{D2H } Y}$ vengono conservati come misure separate e analizzati successivamente.

Oltre al tempo, il backend comunica al driver anche il numero di byte trasferiti nelle tre operazioni principali: la copia iniziale di A , la copia di X eseguita a ogni invocazione e la copia di ritorno di Y . Tempo e volume trasferito permettono di ricavare una **banda effettiva**, calcolata come:

$$B_{\text{eff}} = \frac{D}{t}, \quad (5.2)$$

dove D è il numero di byte trasferiti e t il tempo della corrispondente copia.

Il solo tempo di trasferimento sarebbe infatti poco informativo: una copia più grande richiede naturalmente più tempo di una più piccola. La banda effettiva permette invece di confrontare trasferimenti di dimensioni differenti e di valutare quanto efficacemente venga utilizzato il collegamento tra host e GPU.

5.3 Preprocessing e occupazione della GPU

Anche il costo di creazione del backend viene registrato, pur rimanendo esterno alla regione utilizzata per la misura ufficiale. Il tempo t_{setup} viene distinto in tre contributi, perché corrispondono a operazioni di natura differente.

Il primo è l'inizializzazione dell'ambiente CUDA, necessaria affinché il processo possa utilizzare il device. Si tratta principalmente di un costo di avvio e non dipende direttamente dalle dimensioni del prodotto da calcolare.

Il secondo contributo riguarda l'allocazione in memoria device dei buffer necessari per A , X e Y . Questo costo è legato alla preparazione delle risorse del backend e non rappresenta un trasferimento di dati.

Il terzo contributo è invece la copia H2D del blocco locale di A . Poiché A rimane invariata durante tutte le successive invocazioni del prodotto, questa copia viene effettuata una sola volta in `local_gemm_create`. Il suo costo viene quindi escluso dal cammino cronometrato, ma misurato separatamente.

Questa distinzione permette di quantificare direttamente il vantaggio della persistenza di A sul device: se il suo trasferimento fosse ripetuto a ogni chiamata di `local_gemm`, il relativo costo entrerebbe nel percorso critico insieme alla copia di X e a quella di Y .

5.3.1 Gestione della memoria disponibile

La disponibilità della memoria device non viene verificata mediante una stima preventiva utilizzata per decidere se procedere con il calcolo. Il backend tenta invece direttamente le allocazioni necessarie mediante `cudaMalloc` e, a questo punto, se si verifica un errore di allocazione, viene registrato un messaggio di errore e si procede con il fallimento della creazione del backend.

Questa scelta evita di basare la decisione su una precedente interrogazione della memoria libera: infatti, in presenza di più processi MPI che condividono la stessa GPU, il valore restituito da una precedente osservazione dello stato della memoria può cambiare prima dell'allocazione effettiva. In caso di errore, `cudaMemGetInfo` viene comunque utilizzata per produrre una diagnostica che riporta la memoria richiesta e quella disponibile.

I principali buffer persistenti richiedono complessivamente una quantità di byte pari a:

$$(m_{\text{loc}} \cdot \text{lda} + n_{\text{loc}} \cdot \text{ldx} + m_{\text{loc}} \cdot \text{ldy}) \cdot \text{sizeof}(\text{scalar_t}) \quad (5.3)$$

Poiché nel problema considerato k è piccolo rispetto alle dimensioni della matrice, il termine associato ad A è normalmente dominante.

Aumentare il numero di processi MPI e scegliere opportunamente la griglia bidimensionale riduce le dimensioni dei blocchi locali e, di conseguenza, la quantità di memoria device richiesta da ciascun processo.

5.4 `cuda_naive`

La prima implementazione CUDA adotta la mappatura più diretta possibile: a ciascun thread viene assegnato un singolo elemento del risultato locale Y .

Indicando con t l'identificativo globale del thread, gli indici dell'elemento da calcolare sono

$$i = \left\lfloor \frac{t}{k} \right\rfloor, \quad c = t \bmod k. \quad (5.4)$$

Il thread t è quindi responsabile di Y_{ic} e ne calcola il valore percorrendo interamente la dimensione interna del prodotto:

$$Y_{ic} = \sum_{j=0}^{n_{\text{loc}}-1} A_{ij} X_{jc}. \quad (5.5)$$

Ogni thread mantiene un unico accumulatore e non comunica con gli altri thread.

Il kernel costituisce per questo una baseline semplice, utile sia per verificare il corretto funzionamento dell'intera pipeline CUDA, sia come riferimento interno rispetto al quale valutare le ottimizzazioni successive.

La semplicità della mappatura comporta però una prima inefficienza fondamentale. Infatti, per una stessa riga i , gli elementi:

$$Y_{i0}, Y_{i1}, \dots, Y_{i,k-1}$$

vengono calcolati da thread distinti. Durante una stessa iterazione j , tutti questi thread hanno bisogno dello stesso coefficiente A_{ij} , ma ciascuno lo utilizza soltanto per la propria colonna di Y . Il kernel non esprime quindi alcun riuso di A_{ij} all'interno del thread: lo stesso elemento di A compare logicamente in k operazioni di caricamento differenti.

Questo è il principale limite che motiva il backend successivo: in `cuda_warp`, un valore di A viene invece caricato una volta da una lane e riutilizzato per aggiornare tutti i k risultati associati alla stessa riga.

La mappatura del kernel assegna thread consecutivi alle colonne consecutive di Y . Per un j fissato, tutte le lane che lavorano sulla stessa riga i di Y richiedono quindi lo stesso elemento A_{ij} . Le lane associate alla riga successiva richiedono invece $A_{i+1,j}$, che in memoria row-major si trova a distanza `lda` elementi da A_{ij} .

Per $k < 32$, cioè quando una riga di Y contiene meno elementi della dimensione di un warp, un singolo warp comprende lane associate a più righe di Y e coinvolge quindi più gruppi di accessi ad A distanziati tra loro.

Gli accessi a X hanno invece un comportamento differente. Per ogni gruppo di lane associato alla stessa riga di Y , thread consecutivi leggono gli elementi consecutivi

$$X_{j0}, X_{j1}, \dots, X_{j,k-1},$$

che sono contigui in memoria nel layout row-major. Se il warp comprende più righe di Y , questa stessa sequenza di accessi a X si ripete.

All'aumentare di k , un numero crescente di lane del warp lavora sulla stessa riga di Y , fino al caso $k = 32$, in cui un intero warp corrisponde esattamente a una riga. A ogni iterazione j , tutte le lane richiedono quindi lo stesso elemento A_{ij} e, contemporaneamente, leggono i 32 elementi consecutivi

$$X_{j0}, \dots, X_{j31}.$$

Il parametro k influenza quindi direttamente il pattern di accesso del kernel. Questo aspetto sarà utile nel confronto con `cuda_warp`, dove la mappatura viene rovesciata: un intero warp viene assegnato a una sola riga di Y e le lane vengono distribuite lungo la dimensione j .

5.5 `cuda_warp`: un warp per riga

Il secondo backend modifica radicalmente l'approccio alla parallelizzazione. In `cuda_naive` ogni thread era responsabile di un singolo elemento Y_{ic} , ma in `cuda_warp`, invece, un intero warp collabora ed è responsabile del calcolo di una riga di Y .

Fissata la riga i , le 32 lane del warp si dividono la dimensione interna j . La lane l visita gli indici:

$$j = l, l + 32, l + 64, \dots$$

fino a raggiungere n_{loc} .

A ogni iterazione, lane consecutive accedono quindi a elementi consecutivi della stessa riga della matrice A :

$$A_{i,j}, A_{i,j+1}, \dots, A_{i,j+31}.$$

La mappatura produce così un pattern di accesso contiguo, favorevole alla coalescenza delle letture dalla memoria globale. A differenza di quanto accadeva in `cuda_naive`, questo comportamento non dipende da k , perché è la dimensione j , e non quella delle colonne del multivettore, a essere distribuita fra le lane.

La nuova mappatura consente soprattutto di sfruttare esplicitamente il riuso degli elementi di A . Una volta caricato un elemento:

$$a = A_{ij},$$

la lane non lo utilizza per una sola colonna del risultato, ma per aggiornare tutti i k accumulatori associati alla riga di Y :

$$\begin{aligned} acc[0] &+= aX_{j0}, \\ acc[1] &+= aX_{j1}, \\ &\vdots \\ acc[k-1] &+= aX_{j,k-1}. \end{aligned}$$

Un singolo caricamento di A_{ij} viene quindi riutilizzato nelle k moltiplicazioni che coinvolgono lo stesso elemento della matrice, ed è questa la principale differenza rispetto al primo approccio.

Al termine del ciclo su j , ciascuna lane possiede però soltanto una parte del risultato. Per ogni colonna c , la lane l ha accumulato i termini corrispondenti agli indici:

$$j = l, l + 32, l + 64, \dots$$

e il valore completo può essere scritto come

$$Y_{ic} = \sum_{l=0}^{31} acc_l[c]. \quad (5.6)$$

I 32 contributi vengono quindi ridotti all'interno del warp mediante `__shfl_down_sync`. Al termine, la lane 0 possiede i k valori completi della riga e li scrive in Y .

5.5.1 Gestione di k

I valori di k richiesti dalla traccia, 3, 6, 8, 20 e 32, sono implementati mediante cinque istanze template distinte del kernel. In queste versioni k è quindi noto a compile time: la dimensione dell'array degli accumulatori è costante e i cicli sulle colonne possono essere srotolati dal compilatore.

La stessa interfaccia supporta comunque valori arbitrari di k . Quando k non appartiene all'insieme precedente viene utilizzato un kernel runtime che elabora quattro colonne alla volta (`RUNTIME_TILE = 4`). In questo modo il numero di accumulatori simultaneamente mantenuti da ciascuna lane rimane limitato, pur continuando a riutilizzare ogni elemento di A per più colonne.

5.5.2 La maschera dello shuffle

Un dettaglio di correttezza riguarda la maschera utilizzata nelle operazioni di shuffle. Il kernel usa la maschera completa `0xffffffff`, perché ogni warp valido porta tutte le 32 lane fino alla riduzione. Il controllo sul limite delle righe viene infatti eseguito uniformemente sull'intero warp: se la riga assegnata non esiste, tutte le lane terminano prima; altrimenti tutte raggiungono la `__shfl_down_sync`.

Questo rimane vero anche quando $n_{\text{loc}} < 32$: le lane il cui indice non corrisponde ad alcun j mantengono semplicemente accumulatori nulli, ma partecipano comunque alla riduzione.

5.5.3 Il problema residuo: gli accessi a X

La distribuzione di j fra le lane rende favorevoli gli accessi ad A , ma determina contemporaneamente un pattern meno favorevole per X quando il multivettore è memorizzato in row-major.

Consideriamo un'iterazione nella quale le 32 lane del warp stanno elaborando gli indici consecutivi

$$j_0, j_0 + 1, \dots, j_0 + 31.$$

Durante l'aggiornamento di una stessa colonna c , le lane leggono quindi

$$X_{j_0,c}, X_{j_0+1,c}, \dots, X_{j_0+31,c}.$$

Si tratta di elementi appartenenti alla stessa colonna di X , ma a 32 righe differenti. Poiché X è memorizzata in row-major, due elementi consecutivi di questa sequenza non sono adiacenti in memoria: i loro indirizzi distano `ldx` elementi, cioè una quantità di byte pari a:

$$\text{ldx} \cdot \text{sizeof}(\text{scalar_t})$$

dove ricordiamo che nel caso compatto, utilizzato dal progetto, si ha sempre $\text{ldx} = k$.

Il comportamento è quindi opposto a quello delle letture di A : per la matrice A , lane consecutive leggono elementi consecutivi della stessa riga, mentre per X durante il calcolo di una colonna c , lane consecutive leggono elementi della stessa colonna ma appartenenti a righe differenti.

All'aumentare di k aumenta anche la distanza in memoria fra gli elementi di X richiesti da lane consecutive. Le richieste del warp risultano quindi progressivamente più sparse e possono richiedere un numero maggiore di transazioni di memoria rispetto a un accesso contiguo.

Il kernel ha quindi risolto il principale limite di `cuda_naive`, cioè il mancato riuso esplicito di A , ma ha lasciato un nuovo collo di bottiglia nel pattern di accesso a X . Le due varianti introdotte nelle sezioni successive affrontano esattamente questo problema senza modificare la mappatura warp-per-row.

5.6 Primo rimedio: cambio di layout di X

Il problema descritto nella sezione precedente nasce dall'incompatibilità fra la mappatura delle lane e il layout row-major di X . Le lane di `cuda_warp` avanzano lungo la dimensione j , mentre nel layout row-major sono gli elementi che differiscono per l'indice di colonna c a essere contigui in memoria.

Il primo rimedio consiste quindi nel modificare la rappresentazione di X senza cambiare la mappatura del kernel. Durante il preprocessing, il blocco locale del multivettore viene riscritto per colonne, in modo che

$$X_{jc} = \mathbf{x_loc}[c \cdot n_{\text{loc}} + j]. \quad (5.7)$$

In questa rappresentazione, tutti gli elementi appartenenti a una stessa colonna di X sono consecutivi in memoria. Di conseguenza, quando le 32 lane del warp elaborano gli indici

$$j_0, j_0 + 1, \dots, j_0 + 31$$

per una stessa colonna c , leggono anche 32 posizioni consecutive del buffer:

$$X_{j_0,c}, X_{j_0+1,c}, \dots, X_{j_0+31,c}.$$

Lo stride fra gli indirizzi richiesti da lane consecutive passa quindi da k elementi (nel layout row-major) a un singolo elemento (in questo layout). La mappatura warp-per-row e il riuso di A introdotti da `cuda_warp` rimangono invariati: cambia esclusivamente il modo in cui X è organizzata e indirizzata in memoria.

5.7 `cuda_warp_smem`: staging di X in shared memory

Il secondo rimedio conserva sia la mappatura warp-per-row di `cuda_warp` sia il normale layout row-major di X . La differenza riguarda il percorso seguito dagli elementi del multivettore: invece di essere letti direttamente dalla global memory durante il calcolo, vengono prima caricati cooperativamente in **shared memory** e successivamente consumati dai warp del blocco.

Il percorso di un elemento di X diventa quindi:

global memory $\longrightarrow$ shared memory $\longrightarrow$ registri,

mentre in `cuda_warp` il passaggio intermedio non era presente.

La struttura del calcolo rimane per il resto invariata. Ogni warp è ancora responsabile di una riga di Y , le sue 32 lane si dividono gli indici j , ogni elemento di A viene riutilizzato per aggiornare i k accumulatori e la riduzione finale avviene mediante `__shfl_down_sync`.

5.7.1 Caricamento cooperativo di X

Il caricamento del tile di X non utilizza la stessa mappatura con cui viene successivamente eseguito il prodotto. In questa prima fase partecipano tutti i thread del blocco e gli elementi del tile vengono assegnati mediante un indice lineare.

Indicando con q tale indice, vengono ricavati

$$r = \left\lfloor \frac{q}{k} \right\rfloor, \quad c = q \bmod k,$$

e il thread carica l'elemento X_{rc} nella corrispondente posizione del tile in shared memory.

Con X compatta in row-major, thread consecutivi ricevono valori consecutivi di q e leggono quindi posizioni consecutive del buffer. Il caricamento dalla global memory segue così l'ordine naturale con cui X è memorizzata, evitando il pattern strided che caratterizzava `cuda_warp`.

Una volta completato il caricamento cooperativo, una `__syncthreads()` garantisce che il tile sia interamente disponibile prima che i warp inizino a utilizzarlo. La shared memory è infatti una risorsa comune a tutti i thread dello stesso blocco.

A questo punto il calcolo riprende la stessa struttura di `cuda_warp`. Per ogni warp, la lane l elabora gli indici

$$j = l, l + 32, l + 64, \dots$$

ma gli elementi di X corrispondenti vengono ora letti dal tile in shared memory anziché direttamente dalla global memory.

5.7.2 Riutilizzo del tile fra i warp del blocco

L'introduzione della shared memory produce inoltre un secondo effetto. I warp appartenenti allo stesso blocco calcolano righe differenti di Y , e utilizzano quindi righe differenti di A , ma tutti devono attraversare la stessa matrice X .

Nel backend `cuda_warp`, ciascun warp emette le proprie letture di X . In `cuda_warp_smem`, invece, un tile viene caricato una sola volta dall'intero blocco e viene poi utilizzato da tutti i suoi warp.

Se W indica il numero di warp per blocco, il numero di elementi di X caricati esplicitamente dalla global memory passa quindi, idealmente, da

$$m_{\text{loc}} n_{\text{loc}} k$$

a

$$\left\lceil \frac{m_{\text{loc}}}{W} \right\rceil n_{\text{loc}} k.$$

Per esempio, con il valore predefinito `BLOCK_THREADS=256`, il blocco contiene $W = 8$ warp.

Questa riduzione descrive il numero di letture esplicitamente richieste dal kernel alla gerarchia di memoria globale. Non implica però che il traffico effettivo verso la DRAM si riduca dello stesso fattore, perché una parte delle letture di `cuda_warp` può già essere servita dalle cache della GPU. Il vantaggio effettivo della shared memory deve quindi essere determinato sperimentalmente.

5.7.3 Bank conflict e padding della shared memory

Una volta caricato il tile, il problema non è più la coalescenza degli accessi alla global memory, ma il modo in cui gli indirizzi richiesti dalle lane vengono distribuiti sui banchi della shared memory.

La shared memory è organizzata in 32 banchi, e parole consecutive da 32 bit vengono assegnate a banchi consecutivi. Se più lane richiedono indirizzi differenti appartenenti allo stesso banco, gli accessi non possono essere serviti simultaneamente e vengono parzialmente serializzati.

Durante il caricamento cooperativo del tile, thread consecutivi scrivono elementi consecutivi della shared memory. Questo pattern segue linearmente il buffer e non introduce il problema che interessa il successivo consumo del tile.

Durante il calcolo, invece, la lane l accede alla posizione

$$X_{\text{tile}}[l \cdot \text{tile_row_stride} + c],$$

dove

$$\text{tile_row_stride} = k + \text{SMEM_PAD}.$$

Lane consecutive leggono quindi elementi separati da un'intera riga del tile. Se questo stride produce una mappatura periodica sugli stessi banchi, si genera un bank conflict.

Il caso $k = 32$ in doppia precisione è particolarmente sfavorevole senza padding. Con

$$\text{tile_row_stride} = 32,$$

la distanza fra gli elementi letti da lane consecutive corrisponde a 64 parole da 32 bit e quindi

$$64 \equiv 0 \pmod{32}.$$

Gli accessi ricadono così ripetutamente sugli stessi banchi.

Aggiungendo un elemento di padding per riga si ottiene invece

$$\text{tile_row_stride} = 33,$$

e la distanza diventa

$$66 \equiv 2 \pmod{32},$$

distribuendo gli accessi sui diversi banchi e rimuovendo il caso patologico precedente.

Il padding non rappresenta tuttavia una scelta universalmente ottimale per ogni k . Il suo effetto dipende dallo stride risultante. Per questo `SMEM_PAD` è un parametro di compilazione e il progetto mantiene separate le configurazioni con e senza padding, così da misurarne direttamente l'effetto.

5.7.4 Scelta della dimensione del tile

Il blocco locale di X non viene trasferito interamente in shared memory. La dimensione della shared memory disponibile per blocco è limitata e contribuisce, insieme ai registri e al numero di thread, a determinare quanti blocchi possono risiedere contemporaneamente su uno SM.

Il backend divide quindi X in tile contenenti `x_rows_per_tile` righe. Indicando questa quantità con R , la memoria richiesta da un tile è

$$R(k + \text{SMEM_PAD}) \text{sizeof}(\text{scalar_t}).$$

Il valore di R modifica la quantità di shared memory occupata da ogni blocco, ma non il volume complessivo di X che quel blocco deve attraversare. Un tile più piccolo produce semplicemente un numero maggiore di iterazioni del ciclo di tiling.

La dimensione del tile influenza invece direttamente la frequenza delle sincronizzazioni. Ogni tile richiede due chiamate a `__syncthreads()`: la prima impedisce che il tile precedente venga sovrascritto mentre qualche warp lo sta ancora utilizzando, la seconda garantisce che il nuovo tile sia stato completamente caricato prima di iniziare il calcolo. Aumentando il numero di righe per tile diminuisce quindi il numero di barriere incontrate durante l'attraversamento di X .

Non è tuttavia possibile aumentare arbitrariamente il tile. Una maggiore quantità di shared memory per blocco può ridurre il numero di blocchi residenti contemporaneamente su uno SM e quindi l'occupancy. La scelta implementata nel backend cerca perciò un compromesso: utilizzare un tile sufficientemente grande senza fare della shared memory un ulteriore vincolo alla residenza dei blocchi.

La funzione `plan_tile` esegue questa scelta una sola volta durante `local_gemm_create`, quindi fuori dalla regione cronometrata.

Come primo passo viene interrogata `cudaOccupancyMaxActiveBlocksPerMultiprocessor` assumendo nulla la shared memory dinamica. Il risultato rappresenta il numero di blocchi per SM consentito dal kernel compilato in assenza del vincolo aggiuntivo introdotto dal tile.

La shared memory disponibile per SM viene quindi suddivisa rispetto a questo numero di blocchi, ottenendo un budget iniziale per ciascun blocco. Da tale budget viene ricavato il numero di righe che possono essere contenute nel tile.

Il valore così ottenuto viene infine verificato interrogando nuovamente l'API di occupancy con la quantità effettiva di shared memory richiesta. Se il numero di blocchi residenti risulta inferiore all'obiettivo iniziale, la dimensione del tile viene progressivamente ridotta.

La pianificazione viene eseguita sull'istanza concreta del kernel specializzato per il valore di k corrente. Questa distinzione è necessaria perché le diverse istanze possono avere richieste differenti di registri e quindi differenti limiti di occupancy.

Il parametro `TILE_GRANULARITY` controlla infine l'arrotondamento del numero di righe scelto dal piano. Il valore predefinito è 32, pari alla dimensione del warp.

Un tile con un numero di righe multiplo di 32 permette a tutte le lane di partecipare a ciascun passo completo del ciclo su j . Questo non è però un requisito di correttezza: il kernel gestisce anche tile con un numero di righe non multiplo di 32.

L'arrotondamento introduce quindi un compromesso. Una granularità elevata può lasciare inutilizzata una parte del budget di shared memory e aumentare il numero di tile, mentre una granularità più fine può produrre un ultimo passo nel quale alcune lane non hanno elementi da elaborare. Il parametro viene mantenuto configurabile proprio per poter misurare questo compromesso.

5.7.5 Sincronizzazione e warp inattivi

L'uso di `__syncthreads()` introduce un vincolo di correttezza che non era presente in `cuda_warp`. La barriera coinvolge tutti i thread del blocco e può essere superata soltanto quando tutti i thread che partecipano al blocco l'hanno raggiunta.

L'ultimo blocco della griglia può contenere più warp di quanti siano necessari per coprire le ultime righe di Y . In `cuda_warp` questi warp possono terminare immediatamente quando la riga assegnata supera m_{loc} .

In `cuda_warp_smem` questo non è possibile prima del completamento del ciclo sui tile. Se alcuni warp uscissero mentre gli altri continuano a eseguire le `__syncthreads()`, i thread rimanenti potrebbero attendere indefinitamente a una barriera che gli altri non raggiungeranno mai.

Per questo il kernel associa a ciascun warp un flag `active`. Anche i warp ai quali non corrisponde una riga valida partecipano al caricamento cooperativo e attraversano tutte le sincronizzazioni del blocco. Soltanto l'accumulo dei prodotti e la successiva scrittura di Y vengono eseguiti dai warp attivi.

Terminato l'ultimo tile, quando non rimangono più barriere di blocco, i warp inattivi possono infine uscire prima della riduzione finale.

5.8 Due rimedi allo stesso problema

Le soluzioni descritte nelle sezioni 5.6 e 5.7 nascono dallo stesso problema: in `cuda_warp`, con X row-major, lane consecutive leggono elementi della stessa colonna di X separati da uno stride pari a k elementi.

I due approcci intervengono però in punti differenti.

La variante `X_LAYOUT=column` modifica la rappresentazione del dato prima dell'esecuzione del kernel. Disponendo consecutivamente gli elementi di una stessa colonna di X , la mappatura warp-per-row può essere mantenuta inalterata e le lane trovano direttamente in global memory gli elementi richiesti in posizioni consecutive. Il costo associato a questa soluzione è la conversione preliminare del multivettore.

`cuda_warp_smem`, invece, conserva X nel normale layout row-major e modifica il percorso attraverso il quale i dati raggiungono le lane. Gli elementi vengono prima caricati cooperativamente e in modo contiguo dalla global memory alla shared memory, quindi letti dal tile durante il calcolo. Questa soluzione evita la conversione del dato, ma introduce il costo dello staging, delle sincronizzazioni e dell'utilizzo della shared memory.

Le due implementazioni rappresentano quindi due strategie alternative studiate separatamente nel progetto: la prima modifica il layout del dato, la seconda modifica il meccanismo di accesso mantenendone invariata la rappresentazione.

La combinazione dei due approcci non è stata inclusa tra i backend sperimentali, poiché l'obiettivo del confronto è isolare separatamente l'effetto delle due strategie rispetto alla stessa baseline `cuda_warp`.

5.9 cublas: il riferimento esterno

L'ultimo backend GPU non introduce un nuovo kernel sviluppato nel progetto, ma utilizza la routine GEMM della libreria cuBLAS. Il suo ruolo è fornire un riferimento esterno con cui confrontare le implementazioni CUDA precedenti.

Perché il confronto sia significativo, cuBLAS viene inserita dietro la stessa interfaccia degli altri backend. La creazione del contesto, le allocazioni device e il trasferimento iniziale di A avvengono quindi in `local_gemm_create`, mentre ogni invocazione di `local_gemm` esegue, nello stesso ordine degli altri backend GPU, il trasferimento H2D di X , il prodotto sul device e il trasferimento D2H di Y .

Anche la misura segue gli stessi confini: il tempo del solo prodotto cuBLAS viene delimitato mediante `cudaEvent`, mentre i trasferimenti vengono misurati separatamente. Il confronto con i kernel sviluppati nel progetto avviene quindi nelle stesse condizioni sperimentali.

5.9.1 Adattamento fra row-major e column-major

Il progetto memorizza le matrici in row-major, mentre l'interfaccia GEMM tradizionale di cuBLAS interpreta i propri operandi in column-major. Non è tuttavia necessario convertire o trasporre fisicamente i dati.

Cioè gli stessi dati che rappresentano una matrice in row-major, se interpretati come column-major senza modificarne il contenuto in memoria, rappresentano la sua trasposta. Cambia soltanto la convenzione con cui gli indici vengono associati agli indirizzi.

Di conseguenza, i buffer del progetto possono essere reinterpretati da cuBLAS come

$$A_{\text{cm}} = A_{\text{rm}}^T, \quad X_{\text{cm}} = X_{\text{rm}}^T, \quad Y_{\text{cm}} = Y_{\text{rm}}^T.$$

Applicando questa reinterpretazione al prodotto desiderato si ottiene:

$$Y_{\text{cm}} = Y_{\text{rm}}^T = (A_{\text{rm}} X_{\text{rm}})^T = X_{\text{rm}}^T A_{\text{rm}}^T = X_{\text{cm}} A_{\text{cm}}.$$

Quindi la chiamata cuBLAS deve utilizzare X come primo operando e A come secondo. Nella convenzione utilizzata internamente da cuBLAS si ha:

$$C_{M \times N} = A_{M \times K} B_{K \times N},$$

con:

$$C_{M \times N} = Y_{\text{cm}}^T, \quad A_{M \times K} = X_{\text{cm}}^T, \quad B_{K \times N} = A_{\text{cm}}^T$$

e le dimensioni passate alla libreria sono:

$$M = k, \quad N = m_{\text{loc}}, \quad K = n_{\text{loc}}.$$

Entrambi gli operandi vengono utilizzati con `CUBLAS_OP_N`: la trasposizione non viene eseguita dalla libreria, ma è già implicita nella reinterpretazione column-major degli stessi buffer.

5.9.2 Significato del confronto

Il backend cuBLAS costituisce un riferimento esterno e non un ulteriore passo della sequenza di ottimizzazione sviluppata nel progetto. La libreria sceglie internamente l'implementazione del prodotto e il progetto non controlla direttamente parametri quali tiling, distribuzione del lavoro od occupancy.

Il confronto viene quindi utilizzato in senso sperimentale: permette di stabilire quale prestazione ottengano i kernel specializzati del progetto rispetto a una routine GEMM di libreria eseguita sulla stessa GPU e con gli stessi dati.

Nel problema considerato una delle dimensioni del prodotto, k , è intenzionalmente piccola rispetto a m e n . Questo rende il confronto particolarmente interessante, perché i kernel sviluppati nel progetto sono costruiti esplicitamente attorno alla struttura di un multivettore stretto, mentre cuBLAS riceve il problema attraverso la propria interfaccia GEMM generale. L'eventuale vantaggio di una delle due soluzioni deve però essere stabilito dalle misure, non assunto a priori.

5.10 Più rank MPI sulla stessa GPU

La piattaforma utilizzata per le misure dispone di una sola GPU e i backend CUDA del progetto selezionano esplicitamente il device 0. Quando l'applicazione viene eseguita con più rank MPI sullo stesso nodo, ogni processo crea quindi il proprio contesto CUDA sulla medesima scheda.

In assenza di NVIDIA Multi-Process Service (MPS), il lavoro proveniente da contesti CUDA appartenenti a processi differenti non viene eseguito contemporaneamente sugli SM, ma viene alternato mediante time slicing. I rank possono quindi procedere contemporaneamente sul lato CPU, ma competono per l'esecuzione sulla stessa GPU.

Questa situazione modifica il significato delle misure ottenute mediante `cudaEvent`. Per ciascun rank, t_{kernel} misura l'intervallo compreso fra gli eventi che delimitano il proprio kernel. Se il contesto viene sospeso durante tale intervallo per consentire l'esecuzione di un altro rank, il tempo osservato risente anche della contesa per la GPU.

Di conseguenza, con più rank per GPU, t_{kernel} non deve essere interpretato come il tempo che lo stesso kernel otterrebbe disponendo della scheda in modo esclusivo.

Il driver conserva due prospettive differenti sulla fase locale.

La prima è il tempo del kernel restituito dal backend CUDA. Al termine delle ripetizioni, come per le altre fasi, viene considerato il massimo fra i rank, poiché l'operazione distribuita non può essere considerata conclusa prima del processo più lento. Questa misura rimane utile per osservare il comportamento dei singoli backend, ma con più contesti sulla stessa GPU è influenzata dalla loro contesa.

Per misurare invece il tempo effettivamente richiesto dall'intero gruppo di rank per completare la fase locale, il benchmark mette a disposizione la modalità `-group-timing`. In questo caso

una barriera MPI viene posta immediatamente prima di `local_gemm` e una seconda subito dopo:

$$\text{barriera} \longrightarrow \text{fase locale dei rank} \longrightarrow \text{barriera}.$$

L'intervallo fra le due barriere misura quindi il tempo trascorso dal momento in cui tutti i rank sono pronti fino al completamento dell'ultimo. È questo il denominatore utilizzato per la metrica `gflops_local_group`, che descrive il throughput complessivo del gruppo durante la fase locale.

Per le campagne dedicate alla caratterizzazione del kernel viene quindi utilizzato un solo rank MPI. In questo modo il backend dispone esclusivamente della GPU e differenze dovute, per esempio, alla dimensione del blocco CUDA, al padding della shared memory o alla scelta del layout di X non vengono confuse con la schedulazione fra contesti differenti.

A parità di dimensioni globali M , N e k , il numero complessivo di operazioni rimane lo stesso, ma con un solo rank cambia naturalmente la dimensione del blocco locale assegnato al processo. Le misure a rank singolo devono quindi essere interpretate come caratterizzazione del backend sulla GPU dedicata, mentre quelle multi-rank descrivono l'esecuzione della configurazione MPI effettiva sulla piattaforma disponibile.

Capitolo 6

Metodologia sperimentale

6.1 Ambiente sperimentale

Tutte le misure riportate nella relazione sono state eseguite sul server di calcolo del Dipartimento. La configurazione hardware e software rilevante ai fini delle misure è riassunta in tabella 6.1.

Tabella 6.1: Configurazione dell'ambiente sperimentale.

Componente	Configurazione
CPU	[DA FARE: modello CPU]
Socket / core	[DA FARE: numero socket e core]
Memoria principale	[DA FARE: quantità di RAM]
Gerarchia di cache	[DA FARE: L1d/L2 per core, L3 per socket]
GPU	NVIDIA Quadro RTX 5000
Memoria GPU	15,56 GiB
Compute Capability	7.5 (Turing)
Streaming Multiprocessor (SM)	48
Compilatore GNU	GCC 13.3.0
Open MPI	5.0.9
CUDA Toolkit	12.8 (V12.8.61)
Architettura CUDA	sm_75

L'ambiente software viene predisposto tramite il sistema di moduli del server, utilizzando versioni fissate della toolchain GNU, di Open MPI e di CUDA:

```
module purge
module load gnu/13.3.0
module load openmpi/5.0.9
module load cuda/12.8
```

In questo modo tutte le campagne vengono compilate ed eseguite utilizzando la stessa toolchain software.

Le implementazioni CPU sono compilate con ottimizzazione `-O3` e ottimizzazioni specifiche per l'architettura host tramite `-march=native`; viene inoltre abilitata la contrazione delle operazioni floating-point mediante `-ffp-contract=fast`. Le implementazioni CUDA sono compilate con `-O3` per l'architettura `sm_75`, corrispondente alla Compute Capability 7.5 della GPU utilizzata. La precisione numerica, singola o doppia, viene selezionata a tempo di compilazione.

Per le esecuzioni MPI multi-processo i rank vengono vincolati ai core mediante le opzioni `-bind-to core -map-by core`. Il placement esplicito riduce la variabilità dovuta alla migrazione dei processi e rende più controllabile la località degli accessi alla memoria durante il confronto tra configurazioni.

Il nodo dispone di una singola GPU e tutti i rank CUDA utilizzano il device 0. Di conseguenza, quando più rank MPI eseguono contemporaneamente un backend CUDA, essi condividono la stessa GPU e i tempi del kernel possono includere effetti di contesa e alternanza tra i diversi contesti CUDA (sezione 5.10). Per questo motivo tutte le campagne che caratterizzano i kernel GPU vengono eseguite con un solo rank MPI ($P = 1$), mentre lo studio della decomposizione MPI viene condotto sui backend di CPU, dove il numero di processi non introduce contesa su un acceleratore condiviso.

Per ogni campagna il runner registra nei metadati il comando eseguito, il file di configurazione, i principali parametri sperimentali, il commit Git, lo stato del working tree, le versioni di CUDA e Open MPI e le informazioni sulla GPU. Tali informazioni consentono di associare ogni insieme di misure alla configurazione software con cui è stato prodotto.

6.2 Protocollo di misura

Le misure vengono raccolte durante l'esecuzione del prodotto distribuito, separando le tre fasi principali dell'algoritmo: distribuzione del blocco locale di X , calcolo locale e riduzione dei contributi di Y .

Prima di ogni repetition misurata viene eseguita una barriera sul comunicatore della griglia MPI, in modo che tutti i rank inizino l'operazione dalla stessa fase dell'esecuzione. La barriera precede l'avvio del cronometro e non è quindi inclusa nei tempi riportati.

Per ciascun rank, una repetition segue la sequenza

$$\text{MPI_Bcast} \longrightarrow \text{local_gemm} \longrightarrow \text{MPI_Reduce}. \quad (6.1)$$

Il broadcast rende disponibile a tutti i processi interessati il blocco di X necessario al calcolo locale; il risultato parziale prodotto da `local_gemm` viene successivamente combinato mediante la reduce. Le due operazioni collettive utilizzano rispettivamente i comunicatori di colonna e di riga della griglia bidimensionale.

I quattro istanti temporali vengono acquisiti mediante `MPI_Wtime`:

$$t_0 : \text{inizio del broadcast}, \quad (6.2)$$

$$t_1 : \text{fine del broadcast}, \quad (6.3)$$

$$t_2 : \text{fine della fase locale}, \quad (6.4)$$

$$t_3 : \text{fine della reduce}. \quad (6.5)$$

Da essi vengono ricavati i tempi

$$t_{\text{bcast}} = t_1 - t_0, \quad (6.6)$$

$$t_{\text{local}} = t_2 - t_1, \quad (6.7)$$

$$t_{\text{reduce}} = t_3 - t_2, \quad (6.8)$$

$$t_{\text{total}} = t_3 - t_0. \quad (6.9)$$

Il tempo t_{total} rappresenta quindi il tempo wall-clock dell'intera invocazione distribuita, dall'inizio del broadcast alla conclusione della reduce. Le operazioni di preparazione del problema e di inizializzazione del backend vengono eseguite prima delle repetition e non appartengono a tale intervallo temporale.

Misura della fase CUDA. Nei backend CPU la fase `local_gemm` coincide con il calcolo locale. Nei backend CUDA, invece, la stessa fase comprende il trasferimento del blocco di X dalla memoria host alla GPU, l'esecuzione del kernel e il trasferimento del risultato locale Y dalla GPU alla memoria host:

$$t_{\text{local}} \simeq t_{\text{H2D},X} + t_{\text{kernel}} + t_{\text{D2H},Y} + t_{\text{overhead}}. \quad (6.10)$$

I tre intervalli GPU principali vengono misurati separatamente mediante CUDA events. In particolare vengono registrati il tempo del trasferimento H2D di X , il tempo di esecuzione del kernel e il tempo del trasferimento D2H di Y . La sincronizzazione associata al completamento dell'ultimo trasferimento garantisce che la fase locale sia conclusa prima che venga eseguita la successiva `MPI_Reduce`.

La copia iniziale della matrice locale A verso la memoria della GPU avviene invece durante l'inizializzazione del backend e non viene ripetuta a ogni invocazione del prodotto.

6.3 Definizione della metrica di prestazione

I tempi descritti nella sezione precedente vengono misurati separatamente da ciascun rank MPI. Poiché l'esecuzione distribuita può proseguire solo alla velocità del processo più lento, il tempo associato a una repetition viene definito considerando il massimo tra i rank.

Indicando con i la repetition e con p il rank MPI, il tempo ufficiale locale della repetition è definito in modo diverso per i backend CPU e CUDA.

Per i backend CPU:

$$T_{i,p}^{\text{CPU}} = t_{\text{bcast},i,p} + t_{\text{local},i,p} + t_{\text{reduce},i,p}. \quad (6.11)$$

Poiché in questo caso l'intera fase locale coincide con il calcolo eseguito dalla CPU, tale quantità corrisponde anche al tempo wall-clock t_{total} misurato dall'inizio del broadcast alla fine della reduce.

Per i backend CUDA la metrica richiesta esclude invece i trasferimenti tra memoria host e device. La fase locale viene pertanto rappresentata dal solo tempo di esecuzione del kernel:

$$T_{i,p}^{\text{CUDA}} = t_{\text{bcast},i,p} + t_{\text{kernel},i,p} + t_{\text{reduce},i,p}. \quad (6.12)$$

Il tempo rappresentativo della repetition i è quindi

$$T_i = \max_{0 \leq p < P} T_{i,p}, \quad (6.13)$$

dove P è il numero complessivo di processi MPI.

La composizione delle diverse fasi viene effettuata localmente prima dell'operazione di massimo. In particolare, nel caso CUDA viene calcolato

$$\max_p (t_{\text{bcast},p} + t_{\text{kernel},p} + t_{\text{reduce},p}), \quad (6.14)$$

e non la somma

$$\max_p t_{\text{bcast},p} + \max_p t_{\text{kernel},p} + \max_p t_{\text{reduce},p}. \quad (6.15)$$

La seconda espressione potrebbe infatti combinare tempi appartenenti a rank differenti e non rappresenterebbe il percorso temporale di alcun processo reale.

Dopo aver ottenuto un valore T_i per ciascuna delle R repetition misurate, il tempo medio utilizzato per valutare le prestazioni è

$$\bar{T} = \frac{1}{R} \sum_{i=1}^R T_i. \quad (6.16)$$

Il prodotto tra una matrice $A \in \mathbb{R}^{M \times N}$ e un multivettore $X \in \mathbb{R}^{N \times k}$ richiede approssimativamente

$$2MNk \quad (6.17)$$

operazioni floating-point. La prestazione viene quindi espressa come

$$\text{GFLOP/s} = \frac{2MNk}{\bar{T}} \cdot 10^{-9}. \quad (6.18)$$

Questa quantità costituisce la metrica principale utilizzata per il confronto tra le diverse configurazioni sperimentali.

Metriche ausiliarie. Oltre alla metrica complessiva, il programma calcola una misura della sola fase computazionale. Per i backend CPU essa utilizza t_{local} , mentre per i backend CUDA utilizza t_{kernel} :

$$T_{\text{compute}} = \begin{cases} t_{\text{local}}, & \text{CPU,} \\ t_{\text{kernel}}, & \text{CUDA.} \end{cases} \quad (6.19)$$

La corrispondente prestazione è riportata come `gflops_compute`. Nei backend CUDA la stessa quantità è riportata anche come `gflops_kernel`.

La colonna `gflops` rimane invece la metrica di riferimento, poiché comprende anche il costo delle comunicazioni MPI previste dal prodotto distribuito. Nelle campagne a rank singolo le due colonne differiscono solo per il costo residuo delle due collettive degeneri, e il confronto fra kernel viene quindi condotto su `gflops_kernel`; nella campagna MPI, dove il costo delle collettive è parte del fenomeno studiato, si usa `gflops`.

6.4 Costi esclusi dalla metrica ufficiale

La metrica di prestazione definita nella sezione precedente considera esclusivamente il prodotto distribuito vero e proprio. Restano quindi esclusi dal tempo ufficiale i costi di preparazione del problema, l'I/O e, nel caso dei backend CUDA, le operazioni di trasferimento tra memoria host e memoria device.

In particolare, il preprocessing comprende l'allocazione dei buffer locali, la generazione o distribuzione iniziale dei dati, l'eventuale conversione del layout di X e l'inizializzazione del backend. Tali operazioni vengono eseguite prima delle repetition misurate e non contribuiscono quindi a T_{official} .

Per i backend CUDA, anche il trasferimento iniziale della matrice locale A verso la memoria della GPU appartiene alla fase di setup e viene eseguito una sola volta. Durante ciascuna invocazione di `local_gemm` vengono invece eseguiti il trasferimento H2D del blocco di X , il kernel CUDA e il trasferimento D2H del risultato locale Y .

La metrica ufficiale utilizza, per la fase locale CUDA, il solo tempo del kernel. Di conseguenza i trasferimenti H2D e D2H, insieme all'eventuale overhead residuo lato host/runtime, non entrano in T_{official} . Essi vengono tuttavia misurati separatamente, così da poter distinguere il costo computazionale del kernel dal costo complessivo necessario a utilizzare l'acceleratore.

Il programma registra inoltre il tempo wall-clock completo della fase locale CUDA:

$$t_{\text{local}} \simeq t_{\text{H2D},X} + t_{\text{kernel}} + t_{\text{D2H},Y} + t_{\text{overhead}}, \quad (6.20)$$

dove t_{overhead} rappresenta un termine residuo ottenuto per differenza e comprende costi host/runtime non attribuiti direttamente ai tre intervalli misurati mediante CUDA events. Tale quantità non deve quindi essere interpretata come una misura diretta del solo costo di kernel launch.

Anche l'I/O necessario alla produzione dei file di output viene mantenuto fuori dai tempi del prodotto. In questo modo le scritture su file non influenzano le misure di prestazione, pur rimanendo disponibili per la successiva analisi dei risultati.

La separazione tra tempo ufficiale e costi accessori consente quindi di utilizzare una metrica coerente per il confronto tra implementazioni, senza rinunciare alla possibilità di valutare il costo reale del trasferimento dei dati e dell'inizializzazione dell'acceleratore. I valori effettivamente misurati sono riportati e discussi in sezione 7.6.

6.5 Ripetizioni e stabilità statistica

Ogni configurazione sperimentale viene eseguita più volte all'interno della stessa esecuzione del programma. Prima delle repetition utilizzate per le statistiche vengono effettuate alcune invocazioni di warm-up, i cui tempi non vengono registrati.

Le invocazioni di warm-up hanno lo scopo di portare l'esecuzione in una condizione più rappresentativa prima della raccolta dei campioni, evitando che la prima misura sia influenzata da costi transitori. Al termine dei warm-up vengono eseguite le R repetition misurate secondo il protocollo descritto nelle sezioni precedenti.

Prima di ciascuna repetition viene eseguita una `MPI_Barrier` sul comunicatore della griglia. La barriera è esterna all'intervallo cronometrato e serve esclusivamente ad allineare l'inizio della nuova repetition tra i rank.

Per ciascuna repetition viene ottenuto il tempo globale T_i definito in eq. (6.13). L'insieme

$$\{T_1, T_2, \dots, T_R\} \quad (6.21)$$

costituisce il campione utilizzato per l'analisi statistica della configurazione.

Il valore principale riportato nei confronti prestazionali è la media aritmetica

$$\bar{T} = \frac{1}{R} \sum_{i=1}^R T_i. \quad (6.22)$$

Alla media vengono affiancate misure di dispersione e statistiche descrittive, tra cui deviazione standard campionaria, mediana e minimo. La deviazione standard è calcolata come

$$s = \sqrt{\frac{1}{R-1} \sum_{i=1}^R (T_i - \bar{T})^2}. \quad (6.23)$$

Per confrontare la variabilità di misure aventi scale temporali differenti viene inoltre utilizzato il coefficiente di variazione

$$CV = 100 \frac{s}{\bar{T}}, \quad (6.24)$$

espresso in percentuale.

Il numero di repetition non viene considerato, da solo, una garanzia di stabilità della misura. La dispersione viene invece verificata a posteriori attraverso il coefficiente di variazione e, nei casi in cui questo evidenzia una variabilità significativa, mediante l'ispezione dei singoli campioni. Differenze prestazionali dello stesso ordine della dispersione osservata non vengono considerate sufficienti, da sole, per trarre conclusioni sul confronto tra due configurazioni.

Oltre ai valori aggregati, il programma produce un file CSV contenente una riga per ciascuna repetition misurata. I campioni raw consentono di individuare eventuali outlier, variazioni sistematiche nel corso dell'esecuzione o altri comportamenti che potrebbero essere nascosti dalla sola media. Le invocazioni di warm-up non vengono incluse nei file raw né nelle statistiche finali.

Tutte le campagne descritte nel seguito utilizzano lo stesso protocollo statistico: $R = 20$ repetition misurate precedute da 5 warm-up, con seme fissato a 20 252 026. L'uniformità non è un dettaglio organizzativo: è ciò che rende confrontabili fra loro misure appartenenti a fasi diverse senza dover riesaminare ogni volta le condizioni in cui sono state prese.

6.6 Disegno sperimentale: le fasi

Il codice consegnato espone un numero elevato di parametri: la dimensione del blocco CUDA, il layout in memoria di X , il padding del tile in shared memory, la granularità con cui il tile viene dimensionato, il backend locale, la precisione numerica, il numero di processi MPI e la forma della griglia. Una campagna unica che li facesse variare tutti insieme produrrebbe un numero di configurazioni ingestibile e, soprattutto, non permetterebbe di attribuire una differenza osservata a una causa precisa.

L'impianto sperimentale è quindi organizzato in **fasi successive**, dove ogni fase riceve in ingresso le decisioni prese dalla precedente e le tratta come costanti. Il principio che le ordina è uno solo:

prima si fissa la configurazione di ciascun kernel, poi si misura; confrontare kernel non ancora configurati significherebbe misurare la qualità del tuning e non quella dell'implementazione.

Una sintesi delle fasi è riportata in tabella 6.2.

Tabella 6.2: Le fasi dell'impianto sperimentale, nell'ordine in cui sono state eseguite e in cui sono discusse.

Fase	Oggetto	Variabili controllate	Esito
1	Tuning dei backend CUDA	BLOCK, layout di X , SMEM_PAD, TILE_GRANULARITY	una configurazione per kernel
2	Robustezza dimensionale	scala S e forma $M:N$, a lavoro MN costante	dipendenza da taglia e forma
3	Precisione numerica	FP32 contro FP64, tutto il resto invariato	verifica del roofline
4	Decomposizione MPI su CPU	numero di processi P e backend di CPU	strong scaling ed efficienza
5	MPI + CUDA	non eseguita — vedi sezione 6.11	

Ogni campagna è definita da uno o più file `.conf` raccolti in una *suite* `.txt`, eseguita dal runner `script/run_cuda_experiments.sh`. I file di configurazione rendono espliciti tutti i parametri e sono versionati insieme al codice, sotto `experiments/fase_<n>_<nome>/`; i risultati finiscono nella cartella corrispondente sotto `results/`, accompagnati dai metadati descritti in sezione 6.1. Il percorso di ogni tabella dei risultati è quindi ricostruibile a partire dal nome della campagna.

6.6.1 Criterio di selezione dei parametri

Le campagne della prima fase producono, per ciascun parametro, una griglia di misure indicizzata dal valore del parametro e da k . Occorre quindi un criterio esplicito per passare dalla griglia a una scelta.

Il criterio non può essere “il valore migliore”, perché il valore migliore dipende da k mentre il binario consegnato ha un unico valore fissato a tempo di compilazione. Ciò che serve è il valore che si comporta meglio nel caso peggiore fra i k richiesti dalla traccia.

Indicando con $P(v, k)$ la prestazione (in `gflops_kernel`) del parametro al valore v per un dato k , si definisce la prestazione normalizzata

$$R(v, k) = \frac{P(v, k)}{\max_{v'} P(v', k)}, \quad (6.25)$$

cioè la frazione della prestazione del miglior valore *per quello stesso* k , e la perdita corrispondente

$$L(v, k) = 1 - R(v, k). \quad (6.26)$$

Da queste si ricavano le due statistiche usate per decidere:

$$L_{\text{media}}(v) = \frac{1}{5} \sum_{k \in \{3,6,8,20,32\}} L(v, k), \quad (6.27)$$

$$L_{\text{max}}(v) = \max_k L(v, k). \quad (6.28)$$

Un valore è considerato **robusto** quando entrambe sono piccole, e in caso di quasi-parità si privilegia L_{max} : una configurazione che perde poco in media ma crolla su un singolo k è peggiore, ai fini della consegna, di una che perde uniformemente un poco ovunque.

6.7 Fase 1 — Tuning dei backend CUDA

La prima fase fissa, per ciascun kernel CUDA, i parametri che ne governano la geometria di lancio e l'uso della memoria. Tutte le campagne della fase condividono lo stesso problema e lo stesso protocollo: $M = N = 16\,384$, doppia precisione, $P = 1$, $k \in \{3, 6, 8, 20, 32\}$, 20 repetition dopo 5 warm-up. L'unica cosa che cambia da una campagna all'altra è il parametro studiato.

La taglia $16\,384 \times 16\,384$ non è arbitraria: è la più grande che, in doppia precisione, lascia margine sufficiente nei 15,56 GiB della scheda (A occupa 2 GiB) e che quindi fornisce parallelismo abbondante, evitando che il tuning sia influenzato da una GPU non satura.

6.7.1 Campagna 1.1 — Dimensione del blocco

Suite `experiments/fase_1_tuning/campagna_VAS_block_k_tuning.txt`.

La campagna misura i tre kernel CUDA custom (`cuda_naive`, `cuda_warp` con X column-major e `cuda_warp_smem`) facendo variare la sola dimensione del blocco

$$\text{BLOCK} \in \{64, 128, 192, 256, 384, 512, 1024\}, \quad (6.29)$$

per un totale di $3 \times 7 \times 5 = 105$ configurazioni. I valori sono tutti multipli di 32, cioè della dimensione del warp; l'insieme comprende intenzionalmente sia divisori di 1024 (64, 128, 256, 512, 1024) sia due valori che non lo sono (192 e 384), perché l'argomento teorico sull'occupancy (sezione 5.5) prevede che questi ultimi siano penalizzati e tale previsione va messa alla prova invece che assunta.

La selezione avviene con il criterio di sezione 6.6.1. Il valore scelto per ciascun kernel viene poi mantenuto fisso in tutte le fasi successive.

6.7.2 Campagna 1.2 — Layout in memoria di X

Suite `experiments/fase_1_tuning/campagna_VAS_2_row_major.txt`.

La campagna confronta le due varianti di `cuda_warp` descritte in sezione 5.6: X row-major, cioè nel layout naturale del progetto, e X column-major, ottenuta con una conversione eseguita in preprocessing.

È un confronto controllato nel senso stretto del termine: problema, precisione, topologia MPI, valori di k , protocollo di misura e `BLOCK` restano identici, e l'unica differenza è da dove il kernel legge gli elementi di X . La misura column-major di riferimento è quella già raccolta nella campagna 1.1 allo stesso `BLOCK`, e non una nuova esecuzione.

Il costo della conversione non entra nella metrica: è preprocessing, viene cronometrato a parte nella colonna `t_prep_convert_X_s` e discusso in sezione 7.6.

6.7.3 Campagna 1.3 — Padding del tile in shared memory

Suite `experiments/fase_1_tuning/campagna_VAS_4_smem_pad_tuning.txt`.

La campagna riguarda il solo `cuda_warp_smem` e fa variare

$$\text{SMEM_PAD} \in \{0, 1\}, \quad (6.30)$$

cioè la colonna aggiuntiva che separa due righe consecutive del tile di X in shared memory. `BLOCK` è fissato al valore selezionato nella campagna 1.1.

L'analisi di sezione 5.7.3 formula una previsione puntuale e falsificabile: in doppia precisione, senza padding, la riga del tile è lunga k scalari e lo stride fra righe vale $2k$ banchi, quindi per $k = 32$ lo stride è $0 \bmod 32$ e tutte e 32 le lane insistono sullo stesso banco. Il padding deve perciò produrre un guadagno *massimo* a $k = 32$ e *nullo* a $k = 3$, dove nessun conflitto è previsto. Una campagna che mostrasse un guadagno uniforme su tutti i k falsificherebbe la spiegazione, anche se il padding risultasse comunque conveniente.

6.7.4 Campagna 1.4 — Granularità del tile

Suite `experiments/fase_1_tuning/campagna_VAS_5_smem_granularity_tuning.txt`.

Il numero di righe di X che entrano nel tile non è una costante: viene scelto a runtime dal budget di shared memory (sezione 5.7.4) e poi arrotondato verso il basso a un multiplo di `TILE_GRANULARITY`. La campagna fa variare

$$\text{TILE_GRANULARITY} \in \{1, 8, 16, 32\}. \quad (6.31)$$

Granularità e dimensione del blocco non sono indipendenti, perché entrambe concorrono a determinare quante righe di X ogni warp riusa prima di passare al tile successivo. Per questo motivo la campagna non fissa `BLOCK` al valore della campagna 1.1, ma ripete l'intero sweep su `BLOCK` per ogni granularità: $4 \times 7 \times 5 = 140$ configurazioni, di cui la selezione individua la coppia (BLOCK, g) migliore invece dei due parametri separatamente.

6.7.5 Campagna 1.5 — Confronto fra i kernel a configurazione fissata

Suite `experiments/fase_1_tuning/campagna_VAS_6_kernel_comparison.txt`.

La campagna chiude la fase: ogni backend viene eseguito con la configurazione selezionata dalle campagne precedenti, mentre M , N , k , precisione, numero di processi e protocollo di misura restano identici fra i quattro. I backend confrontati sono `cuda_naive`, `cuda_warp`, `cuda_warp_smem` e `cublas`, quest'ultimo nel ruolo di riferimento esterno e non di proposta (sezione 5.9).

È qui che il tuning paga: poiché ciascun kernel corre nella propria configurazione migliore, una differenza osservata è attribuibile all'implementazione e non alla sfortuna di un parametro mal scelto. Le tre domande a cui la campagna deve rispondere sono:

1. quanto vale il passaggio da un thread per elemento di Y (`cuda_naive`) a un warp per riga con riuso di A in registro (`cuda_warp`), cioè il salto di intensità aritmetica della eq. (2.3);

2. se la shared memory guadagni qualcosa in doppia precisione — il roofline di ?? prevede di no per $k \geq 6$, e la conferma di una previsione negativa è a tutti gli effetti un risultato;
3. quanto dista una libreria general-purpose dal kernel specializzato quando $k \leq 32$.

6.8 Fase 2 — Caratterizzazione dimensionale

Suite `experiments/fase_2_caratterizzazione_dimensionale/campagna_VAS_7_shape_robustness.txt`.

La seconda fase verifica che le configurazioni scelte nella prima non siano valide soltanto sul problema su cui sono state scelte. È anche la campagna esplicitamente richiesta dalla traccia: misure ripetute per M ed N crescenti, su almeno tre rapporti fra M ed N , con $M = N$ incluso e sui cinque k del collaudo.

Il disegno è fattoriale con due variabili controllate:

$$S \in \{4096, 8192, 16384\} \quad (\text{scala nominale}), \quad (6.32)$$

$$\text{forma} \in \{M = N, N = 2M, M = 3N\} \quad (\text{rapporto } M:N). \quad (6.33)$$

Il punto delicato è che cambiare forma a S fissato non deve cambiare la quantità di lavoro, altrimenti l'effetto della forma e quello della taglia risulterebbero confusi. Le dimensioni dei casi rettangolari sono quindi scelte in modo che MN resti prossimo a S^2 , come riportato in tabella 6.3: lo scarto è di $-1,12\%$ per il caso $N = 2M$ e di $+0,27\%$ per il caso $M = 3N$, cioè entro lo stesso ordine della dispersione delle misure.

Tabella 6.3: I nove punti del disegno fattoriale della Fase 2. A parità di scala il prodotto MN è costante entro l'1,2%.

Scala	$M = N$	$N = 2M$	$M = 3N$	MN nominale
$S = 4096$	4096×4096	2880×5760	7104×2368	$1,68 \cdot 10^7$
$S = 8192$	8192×8192	5760×11520	14208×4736	$6,71 \cdot 10^7$
$S = 16384$	16384×16384	11520×23040	28416×9472	$2,68 \cdot 10^8$

Ogni punto viene misurato con i quattro backend nelle configurazioni fissate nella Fase 1 e sui cinque k , in doppia precisione e con $P = 1$: in totale $3 \times 3 \times 4 \times 5 = 180$ configurazioni.

Le due domande sono distinte e la campagna le separa per costruzione. La prima riguarda la *taglia*: al crescere di S i costi fissi si ammortizzano e la GPU dispone di più warp residenti, quindi ci si attende una crescita del throughput che si satura. La seconda riguarda la *forma*: a lavoro costante, un rapporto $M:N$ diverso cambia il numero di righe di Y e quindi il numero di warp disponibili, che con lo schema a un warp per riga è esattamente il parallelismo del kernel (??). Uno scostamento verticale fra le tre curve alla stessa scala è quindi effetto della sola forma.

6.9 Fase 3 — Precisione numerica

Suite `experiments/fase_3_precision/campagna_VAS_8_fp32_comparison.txt`.

La terza fase confronta singola e doppia precisione sui quattro backend CUDA, sul caso quadrato più grande ($M = N = 16384$, $P = 1$) e sui cinque k .

La suite raccoglie soltanto le venti nuove misure FP32: il riferimento FP64 è il punto $S = 16384$, forma $M = N$ della Fase 2, misurato con le stesse configurazioni dei kernel e lo stesso protocollo. Riutilizzarlo invece di rieseguirlo non è solo un risparmio di tempo macchina — garantisce che le due precisioni siano confrontate su misure prodotte dalla stessa campagna e non da due sessioni diverse.

Lo speedup dovuto alla precisione è definito sul solo tempo di kernel:

$$S_{32/64}(k) = \frac{t_{\text{kernel}}^{\text{FP64}}(k)}{t_{\text{kernel}}^{\text{FP32}}(k)}. \quad (6.34)$$

La previsione del modello di ?? è netta e falsificabile: in FP64 il nucleo è compute-bound per $k \geq 6$, quindi il tetto non dipende da k ; in FP32 resta memory-bound su tutto l'intervallo della traccia, quindi il tetto cresce linearmente con k . Il rapporto fra i due deve di conseguenza **crescere con k** . Uno speedup piatto e vicino a 2 — cioè il solo rapporto fra le dimensioni degli scalari, quello che si otterrebbe se entrambe le precisioni fossero limitate dalla banda — falsificherebbe il modello.

Caratterizzazione delle risorse. Al confronto temporale dovrebbe affiancarsi una caratterizzazione delle risorse richieste dai kernel nelle due precisioni, ricavata dall'output di `ptxas`: registri per thread, eventuali spill, stack frame e shared memory statica. Non si tratta di un benchmark, ma della verifica di quale meccanismo produca lo speedup misurato.

Da completare con i dati della campagna

Le compilazioni con `-Xptxas -v` non sono ancora state eseguite. Comando: `make -B KERNEL=<nome> PREC=<double|float> EXTRA_NVCCFLAGS='-Xptxas -v'` per i tre kernel custom nelle due precisioni. Da estrarre: registri per thread, spill store/load, shared memory statica. Due limiti da rispettare nella lettura: `ptxas` riporta la shared memory *statica* e non quella dinamica, quindi per `cuda_warp_smem` il dato va ricostruito dal piano runtime come `x_rows_per_tile · (k + SMEM_PAD) · s` byte; e `blocks_per_sm` è una capacità teorica dichiarata dall'API dell'occupancy, non l'occupancy raggiunta, che richiederebbe un profilo con `ncu`.

6.10 Fase 4 — Decomposizione MPI sui backend di CPU

Suite `experiments/fase_4_mpi_cpu/campagna_VAS_9_mpi_cpu_scaling.txt`.

La quarta fase studia la decomposizione MPI, e lo fa sui backend di CPU. La scelta è dettata dall'hardware: il nodo ha una sola GPU e, con MPS non attivo, più rank CUDA non eseguono in parallelo ma si alternano sulla scheda (sezione 5.10). Una campagna di scaling su GPU misurerebbe quindi l'alternanza dei contesti e non il parallelismo, mentre sui backend di CPU ciascun rank dispone di un core proprio e lo speedup misurato è quello vero.

Il problema globale resta fisso a $M = N = 16384$ in doppia precisione — è quindi uno studio di *strong scaling* — mentre variano

$$P \in \{1, 2, 4, 8\} \quad \text{e} \quad \text{backend} \in \{\text{scheme_a}, \text{scheme_a_jblock}, \text{scheme_a_jblock_rb}\}, \quad (6.35)$$

per $3 \times 4 \times 5 = 60$ configurazioni. I backend `jblock` usano i parametri predefiniti del codice (`JBLOCK_BYTES = 65536`, `RB_ROWS` automatico).

La griglia è $P \times 1$, cioè la decomposizione monodimensionale per righe: ogni rank riceve una banda distinta di righe di A e l'intera X , che viene propagata lungo la colonna della griglia. Il comunicatore di riga contiene allora un solo processo e la reduce degenera in una copia locale. La configurazione è voluta: isola il costo del broadcast di X e rende il tempo misurato quello del calcolo locale più una sola collettiva, che è il caso in cui l'effetto del backend sul calcolo è più leggibile.

Il caso $P = 1$ non è uno studio MPI ma la baseline interna necessaria a definire

$$S(P) = \frac{T(1)}{T(P)}, \quad E(P) = \frac{S(P)}{P}, \quad (6.36)$$

dove T è il tempo ufficiale della eq. (6.16). Poiché la baseline è presa nella stessa campagna e con lo stesso backend, $S(P)$ misura la qualità della parallelizzazione e non il confronto fra implementazioni diverse: quest'ultimo si legge orizzontalmente, confrontando i tre backend allo stesso P .

6.11 Fase 5 — MPI + CUDA

Da completare con i dati della campagna

La fase non è stata eseguita e non compare quindi in capitolo 7. Misurerebbe il prodotto distribuito con backend CUDA e $P > 1$ sull'unica GPU del nodo. Non è uno strong scaling su più acceleratori e non va letta come tale: con MPS non attivo i contesti si alternano, quindi t_{kernel} con $P > 1$ è il throughput aggregato della scheda sul problema globale. Il protocollo corretto per questa fase richiede l'opzione `-group-timing`, che racchiude `local_gemm` fra due barriere e produce un tempo di gruppo indipendente da come il driver ha alternato i contesti; le barriere entrano però in T_{official} , per cui la campagna va tenuta separata da quelle dei GFLOPS ufficiali. Il confronto informativo è fra $t_{\text{local}}^{\text{gruppo}}$, il massimo fra i rank di t_{kernel} e la somma dei t_{kernel} dei rank: vicino al massimo significa kernel sovrapposti, vicino alla somma significa kernel in fila.

Capitolo 7

Risultati

Il capitolo segue l'ordine delle fasi introdotte in sezione 6.6. Ogni sezione riporta prima i numeri misurati e poi, separatamente, la loro lettura: che cosa il singolo esperimento permette di concludere, e che cosa diventa invece leggibile solo mettendolo accanto agli esperimenti correlati. La separazione è voluta: le tabelle restano valide anche se una lettura viene in seguito rivista.

7.1 Stato della raccolta dati

Tabella 7.1: Stato delle campagne al momento di questa versione della relazione.

Fase	Campagna	Config.	Stato	Sezione
1	1.1 dimensione del blocco	105	eseguita	sezione 7.2.1
1	1.2 layout di X	5	eseguita	sezione 7.2.2
1	1.3 padding della shared memory	10	eseguita	sezione 7.2.3
1	1.4 granularità del tile	140	eseguita (132 riuscite)	sezione 7.2.4
1	1.5 confronto fra i kernel	20	eseguita	sezione 7.2.5
2	scala e forma di A	180	eseguita	sezione 7.3
3	FP32 contro FP64	20	eseguita	sezione 7.4
3	risorse dichiarate da <code>ptxas</code>	—	da eseguire	sezione 7.4
4	strong scaling MPI su CPU	60	eseguita	sezione 7.5
5	MPI + CUDA	—	non eseguita	sezione 6.11

Tutte le campagne eseguite condividono il protocollo di sezione 6.5: 20 repetition misurate dopo 5 warm-up, seme 20 252 026, generazione locale di A e X . I coefficienti di variazione osservati restano quasi ovunque sotto l'1% e sono riportati, campagna per campagna, insieme ai valori medi; dove superano tale soglia la circostanza viene dichiarata esplicitamente, perché è ciò che stabilisce quali differenze possano essere discusse e quali no.

7.2 Fase 1 — Tuning dei backend CUDA

Tutte le misure di questa sezione sono prese a $M = N = 16\,384$, doppia precisione, $P = 1$.

7.2.1 Campagna 1.1 — Dimensione del blocco

La tabella 7.2 riporta, per ciascun kernel e ciascun valore di **BLOCK**, le due statistiche di perdita definite nella eq. (6.28): quanto quella dimensione di blocco perde, in media e nel caso peggiore, rispetto al miglior blocco *per lo stesso* k .


Tabella 7.2: Campagna 1.1: perdita rispetto al miglior **BLOCK** per lo stesso k , in percentuale. In grassetto il valore selezionato per ciascun kernel.

BLOCK	cuda_naive		cuda_warp		cuda_warp_smem	
	media	max	media	max	media	max
64	1,13	3,85	0,41	1,32	13,79	38,78
128	0,92	1,69	0,42	0,74	1,31	3,68
192	3,55	8,21	0,98	1,99	4,64	18,35
256	1,09	4,56	1,19	3,95	0,56	1,46
384	3,84	9,71	1,27	1,78	8,27	19,38
512	5,64	10,23	3,17	5,89	7,08	9,33
1024	10,86	23,29	<i>lancio fallito per $k = 20$ e $k = 32$</i>			


I valori selezionati sono quindi **BLOCK** = 128 per `cuda_naive` e `cuda_warp`, **BLOCK** = 256 per `cuda_warp_smem`. Le prestazioni assolute corrispondenti sono riportate in tabella 7.3.

Tabella 7.3: Campagna 1.1: `gflops_kernel` al **BLOCK** selezionato.

Backend	$k = 3$	$k = 6$	$k = 8$	$k = 20$	$k = 32$
cuda_naive (BLOCK=128)	149,3	308,7	337,3	345,6	350,3
cuda_warp (BLOCK=128)	300,3	351,4	350,3	351,4	352,5
cuda_warp_smem (BLOCK=256)	289,3	337,2	346,9	346,3	338,4



(a) cuda_warp, X column-major.



(b) cuda_warp_smem.

Figura 7.1: Campagna 1.1: prestazione normalizzata per (BLOCK, k) a sinistra, perdita media e massima sui cinque k a destra. Le celle FAIL sono i lanci non riusciti a $\text{BLOCK}=1024$.




Figura 7.2: Campagna 1.1: stessa lettura per `cuda_naive`, l'unico kernel che completa anche a BLOCK= 1024.

Lettura

Il blocco conta poco, ma non conta zero, e conta in modo diverso per i tre kernel. Per `cuda_warp` l'intervallo fra il migliore e il peggiore dei sette valori è di appena 3,6 punti percentuali in media: è il kernel meno sensibile, e la ragione è strutturale. Un warp per riga di Y significa che il lavoro è già partizionato alla granularità del warp, e quanti warp stiano in un blocco cambia solo come vengono raggruppati, non che cosa ciascuno fa. `cuda_warp_smem` è invece il più sensibile (13,8% di perdita media a BLOCK= 64, con punte del 38,8%), ed è coerente con la sua struttura: il tile in shared memory è condiviso fra i warp del blocco, quindi il numero di warp per blocco è il fattore di riuso del tile. Con due soli warp per blocco il tile viene riletto da pochi consumatori e il vantaggio della shared memory si assottiglia.

L'argomento sull'occupancy regge, ma solo in parte. La previsione era che 192 e 384, non essendo divisori di 1024, fossero penalizzati. Lo sono: per `cuda_naive` la perdita media passa da 1,09% a BLOCK= 256 a 3,55% a 192 e 3,84% a 384, e per `cuda_warp_smem` da 0,56% a 4,64% e 8,27%. Ma BLOCK= 512, che è un divisore di 1024, è peggiore di entrambi per `cuda_warp`: il criterio dei divisori è quindi una condizione utile e non sufficiente, e il residuo va cercato altrove — in particolare nella pressione sui registri, che cresce con i thread per blocco.

I lanci falliti a BLOCK= 1024 sono essi stessi un dato. Con 1024 thread per blocco, `cuda_warp` e `cuda_warp_smem` non eseguono per $k = 20$ e $k = 32$, mentre `cuda_naive` completa. La differenza fra i kernel è esattamente il numero di accumulatori tenuti in registro: `cuda_naive` ne tiene uno per thread, gli altri due ne tengono k , che in doppia precisione valgono $2k$ registri a 32 bit.

Ipotesi: a BLOCK= 1024 il fabbisogno di registri supera il file di registri dello SM

Un blocco da 1024 thread può disporre al più di 64 registri per thread, perché il file di registri di uno SM Turing ne contiene 65536. Con $k = 20$ accumulatori `double` servono già 40 registri solo per gli accumulatori, ai quali si aggiungono indici, puntatori e registri temporanei; a $k = 32$ i soli accumulatori ne richiedono 64. Il superamento della soglia produce un errore di lancio a runtime, che è esattamente l'esito osservato (`exit_code 1`, nessuna misura prodotta).

Come falsificarla. È il controllo già previsto dalla caratterizzazione `ptxas` di sezione 7.4: compilare i due kernel con `-Xptxas -v` a BLOCK= 1024 e verificare che il numero di registri per thread dichiarato superi 64 per $k \geq 20$ e resti sotto per `cuda_naive`. Se non lo superasse, la causa del fallimento sarebbe un'altra e andrebbe cercata nel budget di shared memory.

In funzione delle campagne successive. Il risultato che conta per il seguito non è quale blocco vinca, ma che la scelta sia *quasi indifferente* nell'intorno del valore selezionato: con una perdita massima inferiore al 2% per tutti e tre i kernel, le differenze misurate nelle fasi 2, 3 e 4 — che sono di ordini di grandezza — non possono essere attribuite a un blocco mal scelto. È precisamente ciò che la fase di tuning doveva garantire.

7.2.2 Campagna 1.2 — Layout in memoria di X

Tabella 7.4: Campagna 1.2: `cuda_warp` con X row-major e column-major, BLOCK= 128. L'ultima colonna è il costo della conversione di X , che è preprocessing e non entra in T .

k	row-major [GFLOPS]	column-major [GFLOPS]	speedup col/row	$t_{\text{kernel row}}$ [ms]	t_{convert} [ms]
3	297,3	300,3	1,01	5,4	0,26
6	352,0	351,4	1,00	9,2	0,57
8	182,6	350,3	1,92	23,5	0,88
20	174,1	351,4	2,02	61,7	2,43
32	92,2	352,5	3,82	186,4	3,32




Figura 7.3: Campagna 1.2: prestazioni assolute (sinistra) e vantaggio del layout column-major (destra). CV massimo: 0,63% row-major, 0,67% column-major.

Lettura

La soglia è netta e cade fra $k = 6$ e $k = 8$. Fino a $k = 6$ i due layout sono indistinguibili entro la dispersione delle misure ($1,01\times$ e $1,00\times$, con CV sotto lo 0,7%): la differenza non è misurabile e non va discussa. Da $k = 8$ in poi il column-major vince, e il vantaggio cresce monotonamente fino a $3,82\times$ a $k = 32$.

La forma della curva identifica il meccanismo. Con X row-major le 32 lane di un warp, al passo j , leggono gli elementi $X[j][0..k-1]$ a distanza k l'una dall'altra: la richiesta di memoria non è coalescibile in una singola transazione e il controller deve emetterne fino a una per lane. Con X column-major gli stessi elementi diventano contigui e la richiesta collassa in poche transazioni. Il costo del layout sbagliato è quindi proporzionale al numero di transazioni sprecate, che cresce con k — ed è esattamente ciò che il fattore $1,00 \rightarrow 1,92 \rightarrow 2,02 \rightarrow 3,82$ mostra. Un guadagno costante su tutti i k avrebbe indicato un'altra causa.

La conversione non cambia il bilancio, e il dato lo dimostra. Portare X in column-major costa fra 0,26 e 3,32 ms, contro un risparmio sul kernel che a $k = 32$ vale $186,4 - 48,7 \approx 138$ ms per singola invocazione. La conversione si ripaga quindi entro la prima invocazione anche se la si contasse dentro la metrica, e la scelta di tenerla fuori (è preprocessing, sezione 6.4) non è ciò che rende il column-major conveniente.

In funzione delle campagne correlate. Questo risultato spiega perché `cuda_warp_smem` non abbia bisogno della conversione e lavori invece con X row-major: staging il tile in shared memory, la lettura da memoria globale viene fatta cooperativamente dai thread del blocco in forma già coalescente, e il layout di partenza smette di contare. I due kernel risolvono lo stesso problema — l'accesso non coalescente a X — per due strade diverse, e il confronto della campagna 1.5 misura quale delle due costi meno.

7.2.3 Campagna 1.3 — Padding del tile in shared memory

Tabella 7.5: Campagna 1.3: effetto di `SMEM_PAD` su `cuda_warp_smem`, `BLOCK=256`. `x_rows_per_tile` è il numero di righe di X che il pianificatore fa entrare nel tile.

k	PAD=0 [GFLOPS]	PAD=1 [GFLOPS]	guadagno	<code>x_rows</code> PAD=0	<code>x_rows</code> PAD=1
3	296,4	296,7	+0,1%	672	512
6	315,4	352,4	+11,7%	320	288
8	328,9	352,6	+7,2%	256	224
20	355,3	352,3	-0,9%	128	128
32	177,8	343,7	+93,3%	128	96

Lettura

La previsione di sezione 5.7.3 è confermata nel suo punto più specifico. L'analisi prevedeva un guadagno massimo a $k = 32$ e nullo a $k = 3$. Misurato: +93,3% a $k = 32$ e +0,1% a $k = 3$, cioè zero entro la dispersione. La conferma è forte perché la previsione era puntuale: non “il padding aiuta”, ma “il padding aiuta esattamente dove lo stride di riga è un multiplo di 32 banchi”. Con `SMEM_PAD=0` e $k = 32$ in doppia precisione lo stride vale $2 \cdot 32 = 64 \equiv 0 \pmod{32}$: tutte e 32 le lane insistono sullo stesso banco e la richiesta si serializza in 32 accessi. Il fattore misurato, poco meno di $2\times$, è inferiore al 32 teorico perché il conflitto riguarda solo le letture da shared memory e non l'intero kernel, ma il punto in cui compare è quello previsto.

I valori intermedi confermano la regola invece di contraddirla. A $k = 6$ lo stride vale 12 banchi e a $k = 8$ vale 16: entrambi dividono 32 in modo parziale e producono conflitti a 2 e

4 vie, ai quali corrispondono guadagni intermedi (+11,7% e +7,2%). A $k = 20$ lo stride vale 40, che è coprimo con 32 in modo sufficiente da distribuire le lane, e infatti il padding non serve — anzi costa lo 0,9%, cioè poco più della dispersione.

Il padding non è gratis, e la tabella dice quanto costa. Allungando la riga del tile di uno scalare, a parità di budget di shared memory entrano meno righe di X : da 672 a 512 a $k = 3$, da 128 a 96 a $k = 32$. È un fattore di riuso più basso, ed è la ragione per cui a $k = 20$ il padding risulta leggermente in perdita. La scelta `SMEM_PAD=1` è quindi un compromesso esplicito: si accetta un tile più piccolo su tutti i k per eliminare il crollo su uno solo di essi, coerentemente con il criterio di robustezza di sezione 6.6.1.

In funzione delle campagne correlate. Il fenomeno è lo stesso già incontrato sulla CPU con il padding di LDA contro i conflict miss di L1: stessa causa (un indirizzo periodico che collide con la periodicità della gerarchia), stessa cura (rompere la periodicità con una colonna in più), altra gerarchia. La campagna 1.4 mostrerà che la perdita di riuso qui quantificata è anche ciò che rende la granularità del tile un parametro non trascurabile.

7.2.4 Campagna 1.4 — Granularità del tile

Tabella 7.6: Campagna 1.4: prestazione normalizzata di `cuda_warp_smem` per ogni coppia (`BLOCK`, g), in percentuale dell'ottimo per lo stesso k . Media sui cinque k e caso peggiore. In grassetto la coppia selezionata.

BLOCK	$g = 1$		$g = 8$		$g = 16$		$g = 32$	
	media	peggiore	media	peggiore	media	peggiore	media	peggiore
64	83,6	54,7	82,7	53,8	77,4	46,2	86,8	61,0
128	88,0	51,3	84,3	50,5	82,2	50,4	98,7	97,1
192	79,0	67,4	76,5	66,4	87,7	71,9	94,9	81,1
256	85,0	65,5	98,1	94,4	96,7	87,8	99,0	98,5
384	89,1	80,0	89,9	78,6	89,5	76,0	90,5	80,2
512	91,9	82,8	92,3	90,7	90,6	86,0	92,2	89,7




Figura 7.4: Campagna 1.4: tuning congiunto di BLOCK e granularità. A sinistra la prestazione normalizzata media sui cinque k , a destra il caso peggiore.




Figura 7.5: Campagna 1.4: dettaglio a BLOCK= 256. A destra il piano di tiling effettivamente scelto a runtime, che dipende da k e non da g se non attraverso l'arrotondamento.

Lettura

Il tuning congiunto era necessario, e la tabella lo dimostra. Se BLOCK e g fossero indipendenti, la riga migliore sarebbe la stessa per ogni colonna. Non lo è: a $g = 1$ il valore migliore di BLOCK è 512 (91,9%), a $g = 8$ e $g = 32$ è 256, a $g = 16$ è ancora 256 ma con un margine molto più stretto su 192. Fissare BLOCK al valore trovato nella campagna 1.1 e cercare g separatamente avrebbe quindi prodotto una configurazione subottima.

La granularità grossa vince perché allinea il tile ai warp. $g = 32$ domina su cinque delle sei dimensioni di blocco, e il valore 32 non è casuale: è la dimensione del warp. Arrotondare il numero di righe del tile a un multiplo di 32 fa sì che il caricamento cooperativo del tile si distribuisca in modo uniforme fra i warp del blocco, senza un warp di coda che lavora a metà carico. Con $g = 1$ il tile ha una dimensione arbitraria e l'ultima porzione viene caricata da un sottoinsieme irregolare di lane: nel caso peggiore la prestazione scende al 51,3% dell'ottimo.

Il pannello destro di fig. 7.5 spiega perché il parametro non domina. Il numero di righe per tile effettivamente scelto a runtime è quasi identico per tutte e quattro le granularità (512, 288, 224, 128, 96 righe per $k = 3, 6, 8, 20, 32$): g non decide la dimensione del tile, che discende dal budget di shared memory, ma solo come essa viene arrotondata. È il motivo per cui l'effetto è grande nei casi patologici e trascurabile altrove, e il motivo per cui va scelto con il criterio del caso peggiore e non della media.

In funzione delle campagne correlate. Le campagne 1.3 e 1.4 agiscono sulla stessa risorsa — le righe di X che stanno nel tile — in direzioni opposte: il padding ne toglie, la granularità corretta evita di sprecarle. La configurazione finale (BLOCK, SMEM_PAD, g) = (256, 1, 32) perde l'1,5% nel caso peggiore, contro il 38,8% della peggiore combinazione misurata: il tuning di questo kernel vale, da solo, più di quanto valga la differenza fra i kernel che la campagna 1.5 sta per misurare.

7.2.5 Campagna 1.5 — Confronto fra i kernel

Configurazioni: `cuda_naive` con BLOCK= 128; `cuda_warp` con BLOCK= 128 e X column-major; `cuda_warp_smem` con BLOCK= 256, SMEM_PAD= 1, $g = 32$; `cublas` come riferimento esterno.

Tabella 7.7: Campagna 1.5: `gflops_kernel` e tempo di kernel, $M = N = 16384$, FP64, $P = 1$. L'ultima riga è la percentuale del tetto FP64 nominale di ?? raggiunta dal miglior kernel.

Backend	$k = 3$	$k = 6$	$k = 8$	$k = 20$	$k = 32$
<i>GFLOPS (kernel-only)</i>					
<code>cuda_naive</code>	150,3	309,3	347,0	349,2	353,7
<code>cuda_warp</code>	302,1	357,5	356,2	357,7	358,3
<code>cuda_warp_smem</code>	296,9	352,6	352,3	352,3	343,7
<code>cublas</code>	15,4	30,9	41,1	102,8	164,3
<i>t_{kernel} [ms]</i>					
<code>cuda_naive</code>	10,71	10,42	12,38	30,74	48,58
<code>cuda_warp</code>	5,33	9,01	12,06	30,02	47,95
<code>cuda_warp_smem</code>	5,43	9,13	12,19	30,48	49,99
<code>cublas</code>	104,46	104,22	104,50	104,46	104,59
% del tetto FP64 (<code>cuda_warp</code>)	86,3	102,1	101,8	102,2	102,4

Il coefficiente di variazione resta sotto lo 0,35% per `cublas`, `cuda_warp` e `cuda_warp_smem`, e sotto l'1,3% per `cuda_naive`: tutte le differenze discusse qui sotto, tranne quella fra `cuda_warp` e `cuda_warp_smem`, sono di ordini di grandezza superiori alla dispersione.




Figura 7.6: Campagna 1.5: confronto fra backend in doppia precisione. La distanza dal tetto, non il valore assoluto, è il risultato.

Lettura

Il roofline è confermato, e in modo quasi imbarazzante. Il modello di ?? prevedeva che in FP64 il nucleo fosse memory-bound solo a $k = 3$ e compute-bound per ogni $k \geq 6$, con un tetto costante a 350 GFLOP/s. Misurato: `cuda_warp` sta all'86,3% del tetto a $k = 3$ e fra il 101,8% e il 102,4% per tutti i $k \geq 6$. La curva si appiattisce esattamente dove il modello diceva e al valore che il modello diceva. Il superamento del 100% non è un errore di misura: il tetto di ?? è calcolato sul clock boost nominale, e uno scarto del 2% è nell'ordine dello scostamento fra clock nominale e clock sostenuto.

Il guadagno di `cuda_warp` su `cuda_naive` scompare al crescere di k , ed è la cosa giusta da aspettarsi. Lo speedup vale $2,01\times$ a $k = 3$, $1,16\times$ a $k = 6$ e poi 1,01–1,03 per $k \geq 8$. A prima vista è deludente; letto attraverso il roofline è inevitabile. Il riuso di A in registro alza l'intensità aritmetica, e alzare l'intensità aritmetica serve *soltanto* finché si è a sinistra del ginocchio. Da $k = 6$ in poi entrambi i kernel sono compute-bound e nessuno dei due può superare lo stesso tetto: quello che `cuda_warp` guadagna non ha più dove andare. Il

vero risultato è che `cuda_naive` non arriva al tetto a $k = 3$ (43,0%) mentre `cuda_warp` ci si avvicina, cioè che la differenza si manifesta tutta e sola nel regime dove il modello dice che può manifestarsi.

La shared memory non guadagna nulla in doppia precisione, come previsto. `cuda_warp_smem` resta fra il 96% e il 99% di `cuda_warp` su tutto l'intervallo, con l'unico scarto apprezzabile a $k = 32$ (−4,1%). È una previsione negativa confermata, e vale come risultato: il traffico su X che il tile riduce non è il collo di bottiglia quando il collo di bottiglia è il calcolo. Il kernel non è però inutile — è scritto per un regime che in FP64 non si presenta mai, e la sezione 7.4 lo misura nel regime in cui quel regime esiste.

cuBLAS è il risultato più istruttivo della campagna. Non tanto perché perda — da $19,6\times$ a $k = 3$ a $2,2\times$ a $k = 32$ — quanto per *come* perde: il suo tempo di kernel è costante, da 104,2ms a 104,6ms, su tutti e cinque i valori di k . Un tempo che non dipende da k significa che il costo non è determinato dal lavoro richiesto ($2MNk$ operazioni) ma dal percorso attraversato, cioè dallo streaming di A con una geometria di tile dimensionata per matrici quadrate grandi. Con $k \leq 32$ il multivettore riempie una frazione minima della mattonella, e il resto del lavoro pianificato viene speso su padding. Ne segue anche la previsione, verificabile, che i GFLOPS di cuBLAS crescano *linearmente* con k finché k resta sotto la dimensione della mattonella: e infatti $15,4 \rightarrow 30,9 \rightarrow 41,1 \rightarrow 102,8 \rightarrow 164,3$ sta su una retta entro l'1%. È la risposta quantitativa alla domanda “perché non avete chiamato una libreria”.

Configurazioni consolidate. La tabella 7.8 raccoglie quanto la fase 1 lascia in eredità alle fasi successive.

Tabella 7.8: Configurazione selezionata per ciascun backend CUDA, usata invariata nelle fasi 2 e 3.

Backend	BLOCK	Layout di X	Altro
<code>cuda_naive</code>	128	row	—
<code>cuda_warp</code>	128	column	—
<code>cuda_warp_smem</code>	256	row	SMEM_PAD=1, $g=32$
<code>cublas</code>	—	row	riferimento esterno

7.3 Fase 2 — Scala del problema e forma di A

I nove punti del disegno fattoriale sono quelli di tabella 6.3: tre scale nominali e, per ciascuna, tre forme a prodotto MN costante entro l'1,2%. Tutte le misure sono in doppia precisione, con $P = 1$ e con le configurazioni consolidate in tabella 7.8.

Tabella 7.9: Fase 2: `gflops_kernel` di `cuda_warp` su tutti i nove punti.


Scala	Forma	$k = 3$	$k = 6$	$k = 8$	$k = 20$	$k = 32$
$S = 4096$	$M = N$	269,6	275,7	277,4	279,8	281,5
	$N = 2M$	280,8	308,9	310,4	289,0	292,0
	$M = 3N$	285,7	330,0	330,5	278,0	281,4
$S = 8192$	$M = N$	297,5	348,4	347,8	347,5	354,1
	$N = 2M$	296,6	353,5	351,5	354,7	357,5
	$M = 3N$	297,8	343,1	342,7	345,9	347,6
$S = 16384$	$M = N$	302,0	354,3	353,2	354,6	354,9
	$N = 2M$	300,0	356,0	355,8	357,4	356,7
	$M = 3N$	301,7	349,6	349,8	351,9	352,4

Tabella 7.10: Fase 2: effetto della sola scala, caso quadrato, tutti i backend.

Backend	$k = 3$			$k = 32$		
	4096	8192	16384	4096	8192	16384
cuda_naive	162,3	187,3	151,5	287,7	354,5	349,7
cuda_warp	269,6	297,5	302,0	281,5	354,1	354,9
cuda_warp_smem	253,5	291,5	296,8	274,5	330,7	341,0
cublas	16,5	15,4	15,3	184,3	164,0	163,2

Tabella 7.11: Fase 2: effetto della sola forma a $k = 32$, a lavoro costante entro l'1,2%.

Backend	$S = 4096$			$S = 16384$		
	$M=N$	$N=2M$	$M=3N$	$M=N$	$N=2M$	$M=3N$
cuda_naive	287,7	300,7	295,8	349,7	347,6	346,1
cuda_warp	281,5	292,0	281,4	354,9	356,7	352,4
cuda_warp_smem	274,5	262,0	263,0	341,0	341,6	338,8
cublas	184,3	173,4	170,8	163,2	170,9	168,5

**Figura 7.7:** Fase 2: cuda_warp sul caso quadrato alle tre scale. La linea tratteggiata è il tetto FP64 nominale. A $S = 4096$ la curva non arriva al tetto per nessun k .

Lettura

La scala conta, la forma quasi no, e il rapporto fra i due effetti è di un ordine di grandezza. Passando da $S = 4096$ a $S = 16384$ a forma fissata, `cuda_warp` guadagna il 26% a $k = 32$ ($281,5 \rightarrow 354,9$); cambiando forma a scala fissata, lo scarto massimo fra le tre forme è del 3,7% a $S = 4096$ e dell'1,2% a $S = 16384$. Poiché il disegno tiene MN costante entro l'1,2%, quest'ultimo numero è al limite di ciò che la campagna può risolvere: la conclusione onesta è che **alla scala massima la forma non ha un effetto misurabile**, non che ne abbia uno piccolo.

Il deficit a $S = 4096$ è un problema di parallelismo, non di forma. A $S = 4096$ la curva di fig. 7.7 è piatta ben sotto il tetto e non lo raggiunge per nessun k : il kernel è compute-bound secondo il roofline, ma non ha abbastanza warp residenti per saturare i 48 SM. Con un warp per riga di Y , il caso quadrato a $S = 4096$ offre 4096 warp contro i 16384 del caso massimo. La previsione di ?? — che il tetto di calcolo presuppone parallelismo sufficiente — è quindi confermata dal lato in cui viene a mancare.

La forma agisce, quando agisce, nella direzione prevista. L'unico punto in cui le tre forme si separano in modo leggibile è $S = 4096$ ai k piccoli, dove `cuda_warp` passa da 269,6 ($M = N$) a 285,7 ($M = 3N$) a $k = 3$: la matrice alta e stretta triplica le righe di Y e quindi i warp disponibili, che è esattamente la risorsa scarsa in quel punto. Appena il parallelismo abbonda, il vantaggio svanisce. Va però detto che a $S = 4096$ il CV massimo osservato sale al 5,8% (`cublas`) e al 3,8% (`cuda_naive`), contro lo 0,6% a $S = 16384$: le differenze fra forme a piccola scala vanno prese come indicazioni, non come misure.

Il comportamento di cuBLAS chiude il cerchio aperto dalla campagna 1.5. Il suo tempo di kernel resta costante in k a *tutte* le scale (da 6,1 ms a 6,3 ms a $S = 4096$, da 24,5 ms a 26,2 ms a $S = 8192$, da 99,3 ms a 105,3 ms a $S = 16384$), e i tre valori stanno fra loro come $1 : 4 : 16$, cioè come MN . È la prova diretta che il costo di cuBLAS su questo problema è determinato dallo streaming di A e non dal lavoro $2MNk$: l'ipotesi formulata nella campagna 1.5 su un singolo punto è qui verificata su nove punti indipendenti. Ne segue anche il solo caso in cui cuBLAS migliora scendendo di scala (184,3 a $S = 4096$ contro 163,2 a $S = 16384$ per $k = 32$): a matrice più piccola la mattonella sprecata è meno sproporzionata.

In funzione delle fasi successive. La fase conferma che le configurazioni scelte nella fase 1 su un solo punto restano valide su due ordini di grandezza di MN e su tre forme: la gerarchia fra i kernel non si inverte mai. È la licenza a condurre le fasi 3 e 4 su un solo problema senza dover ogni volta ripetere lo sweep dimensionale.

7.4 Fase 3 — FP32 contro FP64

Il riferimento FP64 è il punto $S = 16384$, $M = N$ della Fase 2; le misure FP32 sono nuove, sulle stesse configurazioni e con lo stesso protocollo.

Tabella 7.12: Fase 3: `gflops_kernel` nelle due precisioni e speedup $S_{32/64}$ della eq. (6.34), $M = N = 16384$, $P = 1$.

Backend	$k = 3$	$k = 6$	$k = 8$	$k = 20$	$k = 32$
<i>GFLOPS in FP32</i>					
<code>cuda_naive</code>	198,3	386,8	522,0	791,6	1107,4
<code>cuda_warp</code>	604,4	1169,8	1414,3	1489,3	1945,9
<code>cuda_warp_smem</code>	601,2	1164,7	1457,2	1726,9	1473,0
<code>cublas</code>	426,7	861,1	1141,0	2962,3	4791,9
<i>GFLOPS in FP64 (riferimento, Fase 2)</i>					
<code>cuda_naive</code>	151,5	307,1	342,0	345,5	349,7
<code>cuda_warp</code>	302,0	354,3	353,2	354,6	354,9
<code>cuda_warp_smem</code>	296,8	349,8	349,6	349,5	341,0
<code>cublas</code>	15,3	30,7	40,8	102,0	163,2
$S_{32/64} = t_{kernel}^{FP64}/t_{kernel}^{FP32}$					
<code>cuda_naive</code>	1,31	1,26	1,53	2,29	3,17
<code>cuda_warp</code>	2,00	3,30	4,00	4,20	5,48
<code>cuda_warp_smem</code>	2,03	3,33	4,17	4,94	4,32
<code>cublas</code>	27,89	28,08	27,97	29,04	29,37

Tabella 7.13: Fase 3: percentuale del tetto pertinente. In FP64 il tetto è 350 GFLOP/s e non dipende da k ; in FP32 è $B \cdot k/2 = 224k$ GFLOP/s e cresce con k (??).

Backend	$k = 3$	$k = 6$	$k = 8$	$k = 20$	$k = 32$
tetto FP32 [GFLOPS]	672	1344	1792	4480	7168
cuda_naive	29,5	28,8	29,1	17,7	15,4
cuda_warp	89,9	87,0	78,9	33,2	27,1
cuda_warp_smem	89,5	86,7	81,3	38,5	20,6
cublas	63,5	64,1	63,7	66,1	66,9




Figura 7.8: Fase 3: guadagno della singola precisione al variare di k . La crescita con k dei kernel custom è la previsione del roofline; la piattezza di **cublas** intorno a 28 misura invece la lentezza del suo percorso FP64.

Tabella 7.14: Fase 3: piano di tiling scelto a runtime da **cuda_warp_smem** nelle due precisioni.

k	x_rows_per_tile		blocks_per_sm	
	FP64	FP32	FP64	FP32
3	512	1344	4	3
6	288	576	4	4
8	224	448	4	4
20	128	192	3	4
32	96	160	2	3

Lettura

La previsione centrale del modello è confermata. Il roofline prevedeva che $S_{32/64}$ dovesse *crescere* con k , e che uno speedup piatto vicino a 2 lo avrebbe falsificato. Misurato su **cuda_warp**: 2,00 a $k = 3$, poi 3,30, 4,00, 4,20 e 5,48 a $k = 32$. Il valore a $k = 3$ è particolarmente significativo perché è *esattamente* 2, cioè il rapporto fra le dimensioni degli scalari: a $k = 3$ entrambe le precisioni sono memory-bound — il crossover FP64 cade a $k \approx 3,1$ — e il guadagno si riduce al solo traffico risparmiato. Il modello non prevede solo l'andamento, prevede il punto di partenza.

La shared memory guadagna in FP32, esattamente dove il modello dice che può. **cuda_warp_smem** batte **cuda_warp** a $k = 20$ (1727 contro 1489 GFLOPS, +16%) dopo esserne stato indistinguibile in FP64 su tutto l'intervallo. È il controllo incrociato previsto nella campagna 1.5: in FP32 il nucleo resta memory-bound su tutta la traccia, quindi ridurre il traffico su X ha dove tradursi. Le due campagne, prese insieme, dicono una cosa che

nessuna delle due direbbe da sola: `cuda_warp_smem` non è un kernel inferiore, è un kernel il cui vantaggio è invisibile nel regime FP64 di questa scheda.

A $k = 32$ in FP32 qualcosa cambia di nuovo, e va detto invece di nascosto. Lì `cuda_warp_smem` crolla a 1473 GFLOPS, sotto `cuda_warp`, e la percentuale del tetto scende al 20,6%. Il piano di tabella 7.14 mostra che in FP32 il tile a $k = 32$ tiene 160 righe con 3 blocchi residenti per SM: rispetto a $k = 20$ il numero di accumulatori per lane sale da 20 a 32 e l'occupancy ne risente. La lettura completa richiederebbe i dati `ptxas` non ancora raccolti, e per questo resta un'indicazione e non una conclusione.

Nessun kernel avvicina il tetto FP32 ai k grandi. La tabella 7.13 è il risultato meno comodo del capitolo: in FP32 si parte dall'89,9% del tetto a $k = 3$ e si scende al 27,1% a $k = 32$. Il motivo è nel limite che ?? dichiarava per il proprio modello: l'intensità aritmetica conta il solo traffico su A verso la DRAM, mentre il traffico su X , pari a $m_{loc}n_{loc}k$ elementi, consuma banda L2 e non compare nel modello. In FP64 quel traffico è nascosto dal tetto di calcolo; in FP32, dove il tetto di calcolo è 32 volte più alto, diventa il limite vero. Il roofline a un solo livello ha quindi previsto correttamente il *regime* e sovrastimato il *tetto*, e la campagna individua esattamente dove va raffinato.

Il $28\times$ di cuBLAS non è uno speedup di precisione. È il rapporto fra un percorso FP64 patologicamente lento su questo problema e un percorso FP32 che invece raggiunge un ragionevole 63–67% del tetto, costante su tutti i k . Notevole è proprio la costanza: in FP32 cuBLAS è l'unico backend che mantiene la stessa frazione del tetto al crescere di k , ed è il segno che il suo tiling gestisce il traffico su X meglio dei kernel custom. Ai k grandi in singola precisione la libreria torna competitiva e, a $k = 32$, vince: 4792 GFLOPS contro i 1946 di `cuda_warp`. È il rovescio esatto del risultato FP64, e insieme i due dicono che la scelta “kernel custom” è giustificata dal regime del progetto, non in assoluto.

Da completare con i dati della campagna

La caratterizzazione delle risorse con `ptxas` non è stata eseguita (sezione 6.9). Senza di essa restano non decise due questioni aperte sopra: se il calo di `cuda_warp_smem` a $k = 32$ in FP32 sia dovuto a spill degli accumulatori, e se il fallimento dei lanci a `BLOCK=1024` della campagna 1.1 sia effettivamente un superamento del file di registri.

7.5 Fase 4 — Strong scaling MPI sui backend di CPU

Problema globale fisso a $M = N = 16\,384$, doppia precisione, griglia $P \times 1$. Il caso $P = 1$ è la baseline interna di ciascun backend.

7.5.1 Il nucleo di CPU a rank singolo

Tabella 7.15: Fase 4, $P = 1$: tempo ufficiale, throughput e le due bande effettive derivate. $\tau = T/(MN)$ è il costo per elemento di A ; $B_A = MNs/T$ e $B_X = MNks/T$ sono grandezze *derivate*, non misurate, definite come in sezione 4.5.

Backend	k	T [s]	GFLOPS	τ [ns]	B_A [GB/s]	B_X [GB/s]
scheme_a	3	0,3675	4,38	1,37	5,84	17,5
	6	0,3937	8,18	1,47	5,46	32,7
	8	0,5847	7,35	2,18	3,67	29,4
	20	2,1775	4,93	8,11	0,99	19,7
	32	3,3584	5,12	12,51	0,64	20,5
scheme_a_jblock	3	0,3823	4,21	1,42	5,62	16,9
	6	0,3906	8,25	1,46	5,50	33,0
	8	0,3772	11,39	1,41	5,69	45,5
	20	0,5989	17,93	2,23	3,59	71,7
	32	1,0679	16,09	3,98	2,01	64,4
scheme_a_jblock_rb	3	0,3313	4,86	1,23	6,48	19,4
	6	0,6909	4,66	2,57	3,11	18,6
	8	1,0980	3,91	4,09	1,96	15,6
	20	2,7827	3,86	10,37	0,77	15,4
	32	4,7773	3,60	17,80	0,45	14,4

La dimensione del blocco locale di X cresce linearmente con k : 0,39 MB a $k = 3$, 1,05 MB a $k = 8$, 2,62 MB a $k = 20$ e 4,19 MB a $k = 32$. I coefficienti di variazione restano sotto l'1,5% ovunque a $P = 1$.

Lettura

L'ipotesi sulla soglia di cache formulata per lo schema A è confermata, e lo è nel modo più diretto possibile: rimuovendo la causa. `scheme_a` mostra la discontinuità attesa — τ passa da 1,47 ns a $k = 6$ a 8,11 ns a $k = 20$, mentre il lavoro cresce solo di $3,3\times$ — e la firma è un B_X che si stabilizza intorno a da 17 GB/s a 20 GB/s ai due estremi dell'intervallo. `scheme_a_jblock` cambia una sola cosa, l'ordine di visita di X , e la discontinuità sparisce: τ passa da 1,46 a 2,23 ns fra $k = 6$ e $k = 20$, e il throughput invece di crollare cresce da 8,25 a 17,93 GFLOPS. Se il collo di bottiglia fosse stato il numero di accumulatori o la pressione sui registri, mattonellare X non avrebbe avuto alcun effetto.

Il guadagno del j-blocking è dove la teoria lo colloca e non altrove. Lo speedup di `scheme_a_jblock` su `scheme_a` vale $0,96\times$ a $k = 3$, $1,01\times$ a $k = 6$, poi $1,55\times$, $3,64\times$ e $3,14\times$. Ai k piccoli X_{loc} sta già nella cache privata e mattonellarla non serve — anzi costa un 4%, che è il prezzo di rileggere Y a ogni tile. Il pareggio cade fra $k = 6$ e $k = 8$, cioè fra 0,79 MB e 1,05 MB di X_{loc} : è una stima sperimentale della soglia, e restringe l'intervallo che l'analisi precedente lasciava aperto.

Il register blocking è una regressione, e va riportato come tale. `scheme_a_jblock_rb` è più veloce di `scheme_a` solo a $k = 3$ (+11%) e perde ovunque altrove, fino a -30% a $k = 32$; rispetto a `scheme_a_jblock` perde un fattore $4,5\times$ a $k = 32$. La direzione è coerente con l'intento — a $k = 3$ le catene di FMA indipendenti sono poche ed è lì che lavorare su più righe di A per volta può servire — ma l'entità della perdita agli altri k dice che il blocco di righe interferisce con il tile di X : lavorando su `RB_ROWS` righe contemporaneamente, il working set per tile si moltiplica per `RB_ROWS` e annulla il beneficio del j-blocking. La campagna non contiene l'esperimento che lo dimostrerebbe — uno sweep congiunto su `JBLOCK_BYTES` e

RB_ROWS, che questa campagna ha lasciato ai valori predefiniti — ed è il primo esperimento da aggiungere.

7.5.2 Scaling a problema fisso

Tabella 7.16: Fase 4: throughput ufficiale (gflops) al variare di P .

Backend	P	$k = 3$	$k = 6$	$k = 8$	$k = 20$	$k = 32$
scheme_a	1	4,38	8,18	7,35	4,93	5,12
	2	8,75	15,15	13,67	9,53	9,88
	4	15,86	27,13	24,81	18,46	17,17
	8	25,85	48,32	41,42	23,13	15,18
scheme_a_jblock	1	4,21	8,25	11,39	17,93	16,09
	2	8,23	15,87	20,94	34,59	30,37
	4	15,83	30,75	40,09	62,03	55,62
	8	24,19	45,01	58,37	105,46	101,80
scheme_a_jblock_rb	1	4,86	4,66	3,91	3,86	3,60
	2	8,89	8,84	7,42	7,50	6,93
	4	16,55	17,03	14,36	14,34	12,64
	8	22,49	31,16	27,29	27,86	24,07

Tabella 7.17: Fase 4: efficienza parallela $E(P) = S(P)/P$ della eq. (6.36), rispetto alla baseline $P = 1$ dello stesso backend.

Backend	P	$k = 3$	$k = 6$	$k = 8$	$k = 20$	$k = 32$
scheme_a	2	1,00	0,93	0,93	0,97	0,97
	4	0,90	0,83	0,84	0,94	0,84
	8	0,74	0,74	0,70	0,59	0,37
scheme_a_jblock	2	0,98	0,96	0,92	0,96	0,94
	4	0,94	0,93	0,88	0,86	0,86
	8	0,72	0,68	0,64	0,74	0,79
scheme_a_jblock_rb	2	0,91	0,95	0,95	0,97	0,96
	4	0,85	0,91	0,92	0,93	0,88
	8	0,58	0,84	0,87	0,90	0,84

Tabella 7.18: Fase 4: scomposizione del tempo a $k = 32$, in ms. La reduce è degenerare perché la griglia è $P \times 1$.

Backend	P	t_{bcast}	t_{local}	t_{reduce}	t_{total}
scheme_a	1	0,001	3357,4	1,035	3358,4
	2	0,461	1738,6	0,582	1739,6
	4	2,323	999,2	0,379	1000,6
	8	2,103	1129,9	0,278	1132,1
scheme_a_jblock	1	0,000	1067,1	0,719	1067,9
	2	0,883	564,3	0,480	565,7
	4	2,637	306,2	0,233	308,9
	8	1,374	167,3	0,111	168,8
scheme_a_jblock_rb	1	0,001	4776,4	0,914	4777,3
	2	0,916	2478,6	0,505	2480,0
	4	2,820	1357,7	0,263	1359,2
	8	2,254	711,3	0,135	713,6




Figura 7.9: Fase 4: strong scaling a $k = 32$. Lo speedup è calcolato sulla baseline $P = 1$ dello stesso backend, quindi le tre curve non sono confrontabili in valore assoluto: `scheme_a_jblock_rb` scala bene perché parte da un tempo tre volte più alto.

Lettura

La comunicazione non è mai il limite, e la campagna lo quantifica. Broadcast e reduce insieme non superano l'1,03% del tempo ufficiale in nessuna delle 60 configurazioni. È una conseguenza della griglia $P \times 1$: il comunicatore di riga contiene un solo processo, la reduce degenera in una copia locale, e il solo costo reale è il broadcast di X_{loc} , che vale al più 4 MB. Con $M = N = 16\,384$ e $P \leq 8$ il rapporto calcolo/comunicazione è troppo favorevole perché le collettive contino: qualunque degrado dell'efficienza osservato sotto va quindi attribuito al calcolo locale, non a MPI.

Il crollo di `scheme_a` a $P = 8$ e $k = 32$ è il risultato più informativo della fase. L'efficienza scende a 0,37 e il tempo *aumenta* passando da $P = 4$ a $P = 8$ ($1000,6 \rightarrow 1\,132,1$ ms): aggiungere processi peggiora le cose. La scomposizione esclude la comunicazione, che vale 2,4 ms su 1132. Con la griglia $P \times 1$ ogni rank riceve l'intera X_{loc} , quindi otto rank streammano otto copie da 4 MB della stessa X attraverso la cache condivisa: la banda che lo schema A consuma rileggendo X viene moltiplicata per P mentre la cache condivisa resta una. È la stessa causa della discontinuità a rank singolo, vista da un'altra direzione — e `scheme_a_jblock`, che quella causa la rimuove, a $P = 8$ e $k = 32$ mantiene $E = 0,79$ e un throughput $6,7\times$ superiore.

Lo speedup, da solo, mente. fig. 7.9 mostra `scheme_a_jblock_rb` come il backend che scala meglio ($6,69\times$ a $P = 8$). È vero e irrilevante: scala bene perché parte da un tempo a rank singolo $4,5\times$ peggiore, e a $P = 8$ resta il più lento dei tre in valore assoluto (24,07 contro 101,80 GFLOPS). È il motivo per cui la tabella 7.16 riporta il throughput e non solo l'efficienza: il confronto fra backend si legge orizzontalmente in quella tabella, mentre $S(P)$ ed $E(P)$ dicono soltanto quanto bene ciascun backend parallelizza sé stesso.

Il calo generale di efficienza a $P = 8$ ha una causa unica. Tutti e tre i backend perdono efficienza fra $P = 4$ e $P = 8$ (0,64–0,90), e poiché la comunicazione è trascurabile e il lavoro per rank è esattamente $1/P$, resta la banda di memoria condivisa fra i core. Il nucleo è memory-bound anche nella sua versione mattonellata: B_A a rank singolo vale da 2 GB/s a 5,7 GB/s per `scheme_a_jblock`, e otto core che vi accedono contemporaneamente saturano il canale prima di esaurire il calcolo. Sarebbe verificabile con una misura STREAM a uno e a otto core, che è fra i dati mancanti di ??.

In funzione delle fasi GPU. Il confronto fra le due piattaforme, a parità di problema, precisione e metrica, si legge accostando la tabella 7.16 alla tabella 7.7: a $k = 32$, $16\,384 \times 16\,384$ in doppia precisione, `cuda_warp` fa 358,3 GFLOPS contro i 16,09 del miglior backend CPU

a rank singolo ($22,3\times$) e i 101,80 a $P = 8$ ($3,5\times$). Il rapporto si riduce al crescere di P ma non si chiude, e va letto ricordando che il tempo GPU esclude i trasferimenti per costruzione (sezione 6.4): quanto pesino davvero è l'oggetto della sezione seguente.

7.6 Il costo dei dati: trasferimenti e preprocessing

Le voci di questa sezione non richiedono esecuzioni aggiuntive: ogni campagna le scrive in coda al proprio CSV. I valori riportati sono quelli di `cuda_warp` nella campagna 1.5 ($M = N = 16\,384$, FP64, $P = 1$), dove A occupa 2 GiB e il blocco di X trasferito a ogni invocazione va da 0,38 MiB a $k = 3$ a 4 MiB a $k = 32$.

Tabella 7.19: Scomposizione della fase locale su GPU secondo la eq. (5.1), in percentuale di t_{local} .

k	$t_{\text{H2D } X}$	t_{kernel}	$t_{\text{D2H } Y}$	t_{launch}	t_{local} [ms]
3	2,17%	96,05%	1,62%	0,168%	5,55
6	2,45%	95,66%	1,79%	0,101%	9,42
8	2,48%	95,68%	1,76%	0,080%	12,60
20	1,99%	96,41%	1,57%	0,035%	31,14
32	2,07%	96,33%	1,58%	0,023%	49,78

Tabella 7.20: Preprocessing e banda dei trasferimenti, `cuda_warp`, $M = N = 16\,384$, FP64. Le voci di setup sono pagate una volta sola.

Voce	Valore	Nota
t_{setup} totale	0,617 s	<code>local_gemm_create</code>
creazione del contesto CUDA	0,139 s	costo fisso, indipendente dalla taglia
<code>cudaMalloc</code> in VRAM	0,26 ms	trascurabile
H2D di A	0,475 s	il trasferimento tolto dal cammino misurato
<code>bw_h2d_A_gbs</code>	4,53 GB/s	2 GiB in un'unica copia
<code>bw_h2d_X_gbs</code>	da 3,27 GB/s a 4,23 GB/s	messaggi da da 0,38 MiB a 4 MiB
<code>bw_d2h_Y_gbs</code>	da 4,38 GB/s a 5,36 GB/s	idem, in uscita
t_{prep} generazione di A	0,68 s	esclusa da T
t_{prep} distribuzione di A	0 s	con <code>-a-mode local</code>
t_{prep} conversione di X	da 0,26 ms a 3,32 ms	solo con X column-major
t_{prep} totale	1,30 s	somma locale, poi massimo fra i rank
t_{io} scrittura del CSV	0,19 ms	unico I/O del driver

Lettura

I trasferimenti per invocazione pesano circa il 4%, e il peso non dipende da k . H2D di X e D2H di Y sommano fra il 3,6% e il 4,2% di t_{local} su tutto l'intervallo. Il risultato non era scontato: i due trasferimenti scalano con $n_{\text{loc}}k$ e $m_{\text{loc}}k$, cioè linearmente in k , ma anche il kernel scala linearmente in k nel regime compute-bound, e il rapporto resta costante. È la conferma che a $16\,384 \times 16\,384$ il problema è abbastanza grande da rendere il PCIe un contorno.

L'overhead di lancio si ammortizza, come deve. t_{launch} vale da 9 μs a 12 μs in assoluto, cioè un valore che non dipende da k ; in percentuale scende quindi dallo 0,168% a $k = 3$ allo 0,023% a $k = 32$. Le due voci si muovono in direzioni opposte proprio perché una scala con il lavoro e l'altra no, ed è ciò che la scomposizione permette di verificare invece di asserire.

La banda misurata è un quarto del bus, e questo è un risultato azionabile. La copia di A raggiunge 4,53 GB/s su un PCIe 3.0 $\times 16$ il cui picco teorico è circa 15,75 GB/s. Il valore è coerente con l'uso di memoria host *pageable*: il driver deve passare per un buffer

di staging pinnato interno, dimezzando o peggio la banda utile. Allocare i buffer host con `cudaHostAlloc` è quindi l'intervento che ridurrebbe i 0,475 s di setup, e non richiede di toccare né i kernel né `mpi_matmul`.

Il ciclo di vita a tre fasi si ripaga in una decina di invocazioni. Il trasferimento iniziale di A costa 0,475 s, contro i 48 ms di un kernel a $k = 32$: copiare A a ogni invocazione — che è ciò che un'interfaccia senza `create/destroy` imporrebbe — moltiplicherebbe per undici il tempo di ogni prodotto. La scelta di sezione 2.6.1 non è quindi una comodità di progetto ma la condizione perché la misura riguardi la GPU e non il bus.

In funzione dei lavori futuri. I due trasferimenti per invocazione sommano, a $k = 32$, 1,82 ms su una fase locale di 49,78 ms. È il tetto esatto del guadagno ottenibile da un MPI CUDA-aware, che eliminerebbe H2D di X e D2H di Y passando puntatori device direttamente alle collettive: meno del 4% sulla fase locale a rank singolo. Il beneficio vero di quell'intervento va quindi cercato nella Fase 5, dove i trasferimenti di P rank competono sullo stesso bus, e non qui.

7.7 Sintesi

Tabella 7.21: Migliore configurazione misurata per ciascun regime, a $M = N = 16\,384$.

Regime	Backend migliore	GFLOPS	% tetto	Riferimento
GPU FP64, $k = 3$	<code>cuda_warp</code>	302,1	86,3	tabella 7.7
GPU FP64, $k \geq 6$	<code>cuda_warp</code>	da 356 a 358	≈ 102	tabella 7.7
GPU FP32, $k \leq 8$	<code>cuda_warp</code>	da 604 a 1414	da 79 a 90	tabella 7.13
GPU FP32, $k = 20$	<code>cuda_warp_smem</code>	1726,9	38,5	tabella 7.13
GPU FP32, $k = 32$	<code>cublas</code>	4791,9	66,9	tabella 7.13
CPU FP64, $P = 1$	<code>scheme_a_jblock</code>	17,93 ($k = 20$)	—	tabella 7.16
CPU FP64, $P = 8$	<code>scheme_a_jblock</code>	105,46 ($k = 20$)	—	tabella 7.16

Le tre conclusioni che il capitolo sostiene, ciascuna appoggiata su più di una campagna:

- 1. Il modello roofline ha previsto correttamente il regime in entrambe le precisioni.** In FP64 il plateau al tetto per $k \geq 6$ (campagna 1.5), la sua indipendenza da taglia e forma alle scale sufficienti (Fase 2) e la crescita di $S_{32/64}$ con k (Fase 3) sono tre verifiche indipendenti della stessa previsione. Il modello sovrastima però il tetto FP32 ai k grandi, e la Fase 3 individua la ragione nel traffico su X che il roofline a un livello non contempla.
- 2. Il collo di bottiglia del nucleo di CPU è la rilettura di X , e il j-blocking lo rimuove.** L'ipotesi formulata sulla base della sola discontinuità in k è confermata dall'esperimento che ne rimuove la causa (Fase 4, $P = 1$) e di nuovo, indirettamente, dal crollo di `scheme_a` a $P = 8$, dove la stessa banda è contesa da otto core.
- 3. Il tuning vale quanto la scelta del kernel.** La differenza fra la peggiore e la migliore configurazione di `cuda_warp_smem` (38,8% di perdita contro 1,5%) è dello stesso ordine della differenza fra i kernel custom, e molto maggiore della differenza fra `cuda_warp` e `cuda_warp_smem`. È la giustificazione a posteriori dell'ordine delle fasi.

Capitolo 8

Conclusioni

8.1 Che cosa è stato realizzato

Il progetto implementa il prodotto $Y \leftarrow AX$ per matrice densa e multivettore stretto, distribuito su una griglia di processi bidimensionale con MPI e accelerato all'interno del singolo processo con CUDA. Il codice è in C11 per la parte host e distribuita, in CUDA C++ per i kernel di device, e copre tutti i requisiti della traccia elencati in ??.

Le scelte che hanno avuto l'effetto maggiore, e che sono anche quelle su cui poggia l'analisi:

- **lo schema A** ($i \rightarrow j \rightarrow c$), che legge ogni elemento di A una volta sola e lo riusa nei k accumulatori in registro, portando l'intensità aritmetica da $2/s$ a $2k/s$ FLOP/B — il massimo ottenibile leggendo A una volta;
- **la griglia 2D**, che riduce il volume comunicato da $\Theta(kM)$ o $\Theta(kN)$ delle decomposizioni monodimensionali a $\Theta(k\sqrt{MN}/\sqrt{P})$;
- **il ciclo di vita a tre fasi** del kernel locale, che sposta fuori dal cronometro tutto ciò che riguarda A — inclusa la copia H2D, che altrimenti misurerebbe il PCIe invece della GPU — rendendo la prescrizione della traccia una proprietà strutturale e non una sottrazione a posteriori;
- **una variabile per volta** fra le varianti di kernel, che è la condizione perché ogni differenza misurata sia attribuibile;
- **la strumentazione completa dei tempi esclusi** (sezione 6.4): la traccia permette di non metterli in T , e il progetto li misura comunque, scomposti per fase. La fase locale su GPU è separata nei suoi quattro addendi (eq. (5.1)), il preprocessing del backend nelle sue tre voci, e i trasferimenti riportano anche i byte, così che un tempo di copia si possa giudicare e non solo constatare.

8.2 Che cosa dicono i dati finora

Da completare con i dati della campagna

Questa sezione va riscritta a raccolta ultimata. Al momento l'unica campagna disponibile è C3, e il suo risultato principale è riportato qui sotto.

Il nucleo di CPU raggiunge 10,9 GFLOP/s a $k = 8$ su $10\,000 \times 10\,000$ in doppia precisione a rank singolo, e presenta una discontinuità netta fra $k = 8$ e $k = 20$: il costo per elemento di A passa da 1,47 ns a 7,68 ns, mentre il lavoro cresce solo di $2,5\times$. L'analisi di sezione 7.5 attribuisce il fenomeno alla rilettura di X , che oltre una certa soglia esce dalla cache privata del core, e propone tre controlli per falsificare l'ipotesi. La firma a sostegno è un plateau

di banda effettiva su X intorno a da 17 GB/s a 21 GB/s, costante su cinque valori di k che coprono un fattore 3,2.

Il modello roofline prevede inoltre che sulla GPU, in doppia precisione, il nucleo sia compute-bound per ogni $k \geq 6$, con tetto a 350 GFLOP/s indipendente da k , mentre in singola precisione resti memory-bound per tutti i k della traccia con tetto proporzionale a k . È una previsione forte e falsificabile, e le campagne C1, C2 e soprattutto C7 la mettono alla prova: quest'ultima ne isola la conseguenza più netta — il guadagno della singola precisione deve crescere con k — e la accompagna con i dati di `ptxas` che dicono se una parte del guadagno venga invece dalla pressione sui registri.

8.3 Lavori futuri

Blocking del ciclo su j sul nucleo di CPU. È la conseguenza diretta dell'analisi di sezione 7.5: percorrere X a fette che stiano nella cache privata, riuscendo ogni fetta su tutte le righe di A prima di passare alla successiva. Non cambia lo schema, cambia solo l'ordine di visita, ed è lo stesso principio che `cuda_warp_smem` applica sulla GPU con la shared memory. Se l'ipotesi sulla soglia di cache regge, è l'intervento con il rapporto guadagno/costo migliore dell'intero progetto per $k \geq 20$.

Parallelizzazione OpenMP interna al processo. La traccia ammette OpenMP oppure CUDA e il progetto ha scelto CUDA. Un backend OpenMP dietro la stessa interfaccia `local_gemm` permetterebbe di usare i circa venti core del nodo anche quando la GPU è occupata, e di misurare il regime ibrido MPI+OpenMP con lo stesso cronometro degli altri.

MPI CUDA-aware. L'interfaccia `local_gemm` è stata progettata agnostica rispetto alla posizione della memoria proprio per consentirlo: passando puntatori device direttamente a `MPI_Bcast` e `MPI_Reduce` si eliminerebbero H2D di X e D2H di Y dal cammino di ogni invocazione, senza riscrivere né `mpi_matmul` né i kernel. Il primo passo è verificare il supporto sul nodo di calcolo con `ompi_info | grep cuda`; il secondo è già fatto, perché la scomposizione di sezione 7.6 dice esattamente quanto ci sarebbe da guadagnare — $t_{H2D} X$ e $t_{D2H} Y$ misurati sono il tetto di quel guadagno, e senza quei due numeri l'intervento sarebbe una scommessa.

MPS per la condivisione della GPU. Con MPS attivo i contesti di più rank non si alternerebbero sulla scheda (sezione 5.10), e i numeri multi-rank su GPU tornerebbero interpretabili come tempo di kernel invece che come throughput aggregato. È anche il modo per replicare, con analisi esplicita della serializzazione, i benchmark multi-griglia su GPU — un punto che i lavori di confronto lasciano scoperto.

Profilazione con `ncu`. Le ipotesi formulate nei capitoli precedenti hanno tutte un contatore hardware che le decide: occupancy e banda L2 per `cuda_warp_smem`, conflitti di banco per lo sweep su `SMEM_PAD`, registri per warp per `cuda_warp_tiled`, kernel interno selezionato per `cublas`. È il passo che trasforma le spiegazioni proposte in spiegazioni verificate.

Appendice A

Interfaccia a riga di comando e formato dei dati

A.1 Opzioni del driver

Opzione	Default	Significato
-M <int>	1024	righe di A
-N <int>	1024	colonne di A (e righe di X)
-k <int>	8	colonne del multivettore
-pr <int>	più quadrata	righe della griglia di processi
-pc <int>	più quadrata	colonne della griglia di processi
-reps <int>	10	repetition cronometrate
-warmup <int>	2	repetition di riscaldamento, non cronometrate
-seed <u64>	fisso	seme del generatore
-a-mode <mode>	local	local: ogni processo genera il proprio blocco; global: il rank 0 materializza A e la distribuisce
-x-mode <mode>	local	come sopra per X , sulla sola riga 0 della griglia
-check	off	valida contro il riferimento seriale
-csv	off	stampa una riga CSV invece del report leggibile
-csv-header	—	stampa l'intestazione CSV ed esce
-csv-raw-file <path>	—	appende una riga per repetition a un CSV “raw”
-h, -help	—	elenco delle opzioni

Tabella A.1: Opzioni di bin/matmul_mpi.

Le quattro combinazioni di `-a-mode` e `-x-mode` sono tutte valide e, a parità di seed, producono gli stessi elementi globali.

`-help` stampa anche il layout di X della build corrente (`X_LAYOUT=row|column`): non è un'opzione di riga di comando, ma è la prima cosa da verificare quando due binari danno tempi diversi sullo stesso problema.

A.2 Colonne del CSV

L'intestazione è emessa dal binario stesso (`-csv-header`), quindi non può divergere dalle colonne effettivamente scritte. È la ragione per cui tutti i CSV di una campagna si possono concatenare senza rischio.

Gruppo di colonne	Contenuto
kernel, scalar, a_mode, x_mode	identificazione della build e della modalità; kernel include i parametri che cambiano il codice generato
M, N, k, P, pr, pc, reps	configurazione del problema
t_bcast_*, t_local_*, t_reduce_*	tempi delle tre fasi, media e deviazione standard
t_total_*	tempo end-to-end reale: media, mediana, minimo, deviazione, CV%
t_official_*	metrica ufficiale della ?? , stesse statistiche
t_kernel_*	solo kernel, misurato con cudaEvent ; vale -1 sui backend di CPU
t_transfer_runtime_overhead_*	$t_{\text{local}} - t_{\text{kernel}}$: trasferimenti e overhead del runtime host
t_setup_s	preprocessing del backend, fuori da tutte le metriche
gflops, gflops_compute, gflops_kernel	le tre metriche di sezione 6.3
blocks_per_sm, x_rows_per_tile	piano di esecuzione scelto a runtime dal backend; -1 dove il concetto non esiste (sezione 5.7.4)
rel_err	errore relativo contro l'oracolo, oppure -1 senza -check
<i>da qui in poi: voci ESCLUSE dalla metrica ufficiale (sezione 6.4), in coda così che le colonne storiche non si spostino</i>	
t_setup_device_init_s, t_setup_device_alloc_s, t_setup_h2d_A_s, bw_h2d_A_gbs	scomposizione del preprocessing del backend e banda della copia di A
t_h2d_X_*, bw_h2d_X_gbs	H2D di X per invocazione
t_d2h_Y_*, bw_d2h_Y_gbs	D2H di Y per invocazione
t_launch_overhead_*	residuo della eq. (5.1)
t_prep_*	le sei fasi del preprocessing del driver e il loro totale
t_io_csv_raw_s	unico I/O del driver
x_layout	row o column (sezione 5.6)
t_prep_convert_X_s	costo della conversione di layout, 0 in row

Tabella A.2: Struttura dell'intestazione CSV.

Il CSV *raw* ha un'altra intestazione — una riga per repetition, senza statistiche, con **t_h2d_X_s**, **t_d2h_Y_s**, **t_launch_overhead_s** e **x_layout** — e va unito separatamente da quello aggregato. Il driver rifiuta di appendere a un file la cui intestazione non coincide con la propria: un CSV misto fra due build sarebbe ambiguo senza dare alcun errore.

A.3 Opzioni di build

Alcune scelte non sono opzioni di riga di comando ma di *compilazione*, perché cambiano il codice generato: metterle a runtime introdurrebbe rami nel percorso caldo e renderebbe impossibile sapere, guardando un binario, che cosa stia misurando. Ognuna entra nel nome del binario e in **kernel_name()** (**??**).

Variabile	Default	Effetto
KERNEL	scheme_a	implementazione di <code>local_gemm</code> ; <code>.cu</code> ha la precedenza su <code>.c</code> e attiva <code>nvcc</code>
PREC	double	tipo scalare (<code>-DUSE_FLOAT</code>)
FORCE_GENERIC_K	0	disattiva le specializzazioni su k di <code>scheme_a</code>
TEST_A_PADDING	0	impone $lda = n_{loc} + n$
BLOCK	256	thread per blocco dei backend CUDA
SMEM_PAD	1	scalari di padding per riga del tile (sezione 5.7.3)
TILE_GRANULARITY	32	arrotondamento delle righe per tile
SMEM_BUDGET_BYTES	derivato	forza il budget di shared memory invece di derivarlo dall'occupancy
WARP_COL_TILE	8	colonne per warp in <code>cuda_warp_tiled</code>
X_LAYOUT	row	<code>column</code> rende X compatta per colonne; solo <code>cuda_warp</code> (sezione 5.6)
NVCC_ARCH	sm_75	architettura di destinazione

Tabella A.3: Variabili del Makefile.

Appendice B

Riproduzione dei risultati

B.1 Build

```
make                                     # bin/matmul_mpi (double, scheme_a)
make FORCE_GENERIC_K=1                  # bin/matmul_mpi-generic
make PREC=float                         # bin/matmul_mpi-float
make KERNEL=cuda_naive                 # richiede nvcc: solo sul server
make KERNEL=cuda_warp
make KERNEL=cuda_warp X_LAYOUT=column # X compatta per colonne (solo cuda_warp)
make KERNEL=cuda_warp_smem
make KERNEL=cuda_warp_smem SMEM_PAD=0
make KERNEL=cuda_warp_smem TILE_GRANULARITY=8
make KERNEL=cuda_warp_smem SMEM_BUDGET_BYTES=16384
make KERNEL=cublas                     # aggiunge -lcublas da solo
```

Listato B.1: Compilazione delle configurazioni usate nelle campagne.

La riga finale di ogni `make` ricorda quale binario ha prodotto e con quali variabili, budget di shared memory incluso (derivato quando non è forzato).

Ogni comando stampa in chiusura quale binario ha prodotto e con quali variabili. Su una macchina priva di `nvcc` le build CUDA si fermano con un messaggio esplicito e tutto il resto continua a funzionare.

B.2 Validazione

Da eseguire su taglie piccole, prima delle campagne e per ogni combinazione di backend e precisione che si intende misurare.

```
make test                             # funzioni indice, senza MPI
make check-cxx                         # kernel.h e util.h includibili da C++
make check                             # prodotto distribuito contro oracolo, double
make PREC=float check                  # stessa validazione in singola precisione
make check-padding                     # lda = n_loc + 8
make KERNEL=cuda_warp check
make KERNEL=cuda_warp_smem check
make KERNEL=cublas check
```

B.3 Esecuzione singola

```
# CPU, 4 rank su griglia 2x2
mpirun -np 4 --bind-to core --map-by core \
    ./bin/matmul_mpi -M 8000 -N 8000 -k 8 --pr 2 --pc 2 --reps 10

# GPU, rank singolo: la configurazione con cui si caratterizza un kernel
mpirun -np 1 --bind-to core --map-by core ./bin/matmul_mpi-cuda_warp \
    -M 20000 -N 20000 -k 8 --pr 1 --pc 1 --a-mode local --warmup 2 --reps 10
```

Il binding non è facoltativo sulle esecuzioni multi-rank: senza, le misure sono rumore.

B.4 Campagne

```
./script/run_cuda_experiments.sh --suite experiments/c3_cpu_baseline.txt
./script/run_cuda_experiments.sh --suite experiments/c2_k_sweep.txt
./script/run_cuda_experiments.sh --suite experiments/c1_size_ratio_cpu.txt
./script/run_cuda_experiments.sh --suite experiments/c1_size_ratio_gpu.txt
./script/run_cuda_experiments.sh --suite experiments/c1_size_ratio_mpi20.txt
./script/run_cuda_experiments.sh --suite experiments/c6_grid_shape.txt
./script/run_cuda_experiments.sh --suite experiments/c4_strong_scaling.txt
./script/run_cuda_experiments.sh --suite experiments/c5_weak_scaling.txt
./script/run_cuda_experiments.sh --suite experiments/c7_1_precision_k.txt
./script/run_cuda_experiments.sh --suite experiments/c7_2_precision_resources.txt
```

C7.2 non esegue benchmark: ricompila con `-Xptxas -v` e raccoglie i log delle risorse. I casi k vanno selezionati dal log completo `*_ptxas_*.txt`, non dal solo `*_registers.txt`, che omette i nomi delle funzioni e quindi non permette di attribuire i registri al k giusto.

Prima di rilanciare una campagna

Rilanciare sovrascrive i CSV della campagna. Archiviare la cartella:

```
mv results/c4_strong_scaling results/c4_strong_scaling.$(date +%F_%H%M)
```

B.5 Unione dei CSV di una campagna

Tutti i CSV aggregati di una cartella condividono l'intestazione:

```
find results/c1_size_ratio_cpu -name '*.csv' \
    ! -name '*_raw.csv' ! -name '*_failures.csv' \
    | sort | xargs awk 'FNR==1 && NR!=1 {next} {print}' \
    > results/c1_size_ratio_cpu/merged.csv
```

I file `*_raw.csv` hanno un'altra intestazione e vanno uniti separatamente.

B.6 Note operative sul server

- **Nodo di calcolo, non frontend.** Il nodo di login non ha accesso diretto alla GPU: `nvcc -version`, `ompi_info | grep cuda`, `deviceQuery` e `nvidia-smi` vanno eseguiti sui nodi di calcolo attraverso lo scheduler, e così tutti i benchmark.
- **Trasporto MPI.** Il runner usa `btl=self,sm` per default. Il componente `sm` non esiste in Open MPI 3.x/4.x, dove si chiama `vader`: se le esecuzioni multi-rank falliscono con un

errore di BTL, verificare con `ompi_info -param btl all` e aggiungere `-btl self,vader` sulla riga di comando, che ha la precedenza sul `.conf`.

- **bash $\geq$ 4.4.** Il runner espande array potenzialmente vuoti sotto `set -u`: su bash 3.2 (macOS) si ferma con `unbound variable`. Sul server Linux non si presenta.
- **Memoria della GPU.** Un blocco locale $40\,000^2$ in doppia precisione richiede 12,8 GiB contro i 15,5 GiB della scheda: il programma si ferma prima di allocare, indicando quanta memoria serve e quanta è libera.

B.7 Compilazione di questa relazione

```
cd report && ./compila.sh    # oppure: latexmk -pdf main.tex
```

Per la versione di consegna, commentare la riga `\todovisibiletrue` in `preambolo.tex`: i marcatori dei dati mancanti spariscono dal PDF e restano nel sorgente.